

DIEGO MAURICIO GARCÍA JIMENEZ

MARCO DE TRABAJO DE REDES BAYESIANAS PARA ANÁLISIS
DE CONJUNTOS DE GENES DE INTERÉS BIOLÓGICO A PARTIR
DE DATOS DE EXPRESIÓN GENERADOS POR MICRO-ARREGLOS

DIRECTORA: IRENE TISCHER

DOCTORADO EN INGENIERÍA

ÉNFASIS EN CIENCIAS DE LA COMPUTACIÓN

UNIVERSIDAD DEL VALLE

FACULTAD DE INGENIERÍA

Cali, Noviembre 2019

Diego Mauricio Garcia Jimenez: *Marco de trabajo de redes Bayesianas para análisis de conjuntos de genes de interés biológico a partir de datos de expresión generados por micro-arreglos*
Noviembre 2019

DIRECTORA:
Irene Tischer

COMITÉ EVALUADOR:
José Tovar
Jorge Finke
Julio Freyre

DEFENSA PÚBLICA: Santiago de Cali, Febrero 10 de 2020

Mi familia.

Por su apoyo incondicional y paciencia.

— Luz Elena, Christopher, Belén y Terecita de Jesus

Dedicado a la memoria de José Luis García Ramirez. 1940 – 2009

Abstract

Identification and analysis of signature genes are keys for pharmacist design processes, physiological of plants improvement and research of diseases as for instance oncogenesis.

To identify signature genes, one may analyze the collective behavior of genes using models that represent the interaction between them. Some of these models are gene co-expression networks and gene regulatory networks; where we can observe the expression patterns that obey a group under given biological conditions and the impact of the behavior of one group of genes over other. The networks in question have been inferred with neural networks (Poswar et al. 2015), correlation networks (Zhang and Horvath 2005) and (Prestat et al. 2013), contact maps (Beyer, Bandyopadhyay and Ideker 2007), variability analysis (Moreno et al. 2011), Bayesian networks (Faming 2010). This inference remains an open problem (Friedman and Koller 2003, Neapolitan 2009, Pearl 1988).

To address this inference problem, our framework first constructs a gene co-expression network from microarray gene expression data with Weighted Gene Co-expression Network Analysis (Zhang and Horvath 2005). For clusters of this network, a Bayesian network for gene interactions is learned adopting an Markov Chain Monte Carlo simulation approach. In this way we optimize the exploration of the search space for learning the Bayesian network. In addition, to complement the knowledge about the signature genes found from analysis of interactions network, we use gene ontology where we query properties like the location of the gene within the chromosome and the gene function. With this external knowledge, we structure the findings from the training simulations, giving a higher priority to the genes that are more interesting given their function.

In general terms, we propose here a framework for Bayesian networks that will contribute to the modeling of gene interaction networks and analysis of signature genes, as well as an workflow that facilitates the use of our framework. The workflow is adopted for some case studies taken from the *E. coli* bacterium.

Resumen

La identificación y el análisis de genes de interés biológico son claves en procesos de diseño de fármacos, mejoramiento fisiológico de plantas e investigación de patologías como la oncogénesis en humanos y encontrar interacciones que permiten concluir sobre grupos de genes asociados a proteínas que se necesitan en concentraciones similares y que trabajan coordinadamente en vías metabólicas es relevante para estas disciplinas.

Para identificar dichos genes, se puede analizar el comportamiento colectivo de los genes, a través de modelos que representen la interacción entre ellos. Algunos de estos modelos son las redes de co-expresión y las redes de regulación de genes; en donde se pueden observar tanto los patrones de expresión a los que obedece un grupo bajo unas condiciones biológicas dadas, como también, el impacto del comportamiento de un gen o grupo de genes sobre otros. Las redes en mención han sido abordadas desde diferentes modelos como las redes neuronales (Poswar et al. 2015), redes de correlación (Zhang y Horvath 2005) y (Prestat et al. 2013), mapas de contacto (Beyer, Bandyopadhyay y Ideker 2007), análisis de variabilidad (Moreno et al. 2011), redes Bayesianas (Faming 2010), etc. A pesar que existen en cada modelo diversos enfoques para el aprendizaje o construcción de la red a partir de datos de muestra (Friedman y Koller 2003, Neapolitan 2009, Pearl 1988), la construcción y utilización efectiva de los modelos en condiciones de incertidumbre para un interés biológico particular, continúa siendo un problema abierto de estudio.

Nuestra propuesta para abordar esta problemática consiste en construir inicialmente una red de co-expresión a partir de datos generados por micro-arreglos siguiendo el método WGCNA (del inglés Weighted Gene Co-expression Network Analysis) desarrollado por (Zhang y Horvath 2005). A partir de los clusters identificados con el método WGCNA se propone aprender una red Bayesiana de interacción de genes adoptando el enfoque clásico de simulación MCMC, de esta manera se optimiza la exploración del espacio de búsqueda para el aprendizaje de la red Bayesiana, ya que solo se analiza un grupo de genes y no la red completa. Además, para complementar el conocimiento acerca de los genes de interés que resultan del análisis de estas redes de interacción, empleamos bases de datos biológicas u “Ontologías de los genes”, donde consultamos entre otras propiedades, la ubicación del gen dentro del cromosoma, la función génica, etc. Con este conocimiento externo estructuramos los hallazgos encontrados en las simulaciones de entrenamiento, dando mayor prelación a los genes que resulten más interesantes dado su función.

En términos generales, lo que aquí proponemos es un marco de trabajo de redes Bayesianas que contribuirá a la bioinformática en el modelamiento de redes de interacción de genes, análisis e identificación de genes de interés biológico, y un flujo de trabajo que facilita el uso del marco Bayesiano. Este flujo de trabajo se adopta en el estudio de alguno casos tomados del organismo bacteriano *E. coli*.

Agradecimientos

A los profesores Irene Tischer, Pedro A. Moreno, Oscar Bedoya, Victor Bucheli de la Escuela de ingeniería de sistemas y computación (EISC) en la Universidad del Valle. Al profesor Julio Freyre por haberme recibido en su laboratorio de Sistemas Regulatorios en el Centro de Ciencias Genómicas en la UNAM, al Comité Evaluador por su tiempo y comentarios muy apreciados para mejorar esta tesis, Doctores José Tovar y Jorge Finke.

Índice general

1	Introducción	1
1.1	Descripción general del proyecto	1
1.2	Justificación	2
1.3	Alcance	3
1.4	Objetivos	3
1.4.1	Pregunta de investigación e hipótesis	3
1.4.2	Objetivo General	4
1.4.3	Objetivos Específicos	4
1.5	Estructura del documento	4
2	Marco teórico y estado del arte	5
2.1	Ontología de genes (Gene Ontology - GO)	5
2.1.1	Introducción	5
2.1.2	Estado del arte	7
2.2	Datos de expresión de genes en micro-arreglos	7
2.2.1	Definición y función	8
2.2.2	Introducción al procesamiento de imágenes, transformación y normalización	9
2.2.3	Análisis de datos de expresión de genes	12
2.3	Redes complejas	14
2.3.1	Introducción a las redes complejas	14
2.3.2	Análisis de redes complejas	17
2.3.3	Estado del arte	18
2.4	Redes de co-expresión de genes	19
2.4.1	Introducción a las redes de co-expresión de genes	19
2.4.2	Estado del arte	19
2.5	Aprendizaje Bayesiano fundamentos y estado de arte	22
2.5.1	Definición y representación de una red Bayesiana	22
2.5.2	Tipos de razonamiento en redes Bayesianas	24
2.5.3	Principio de la máxima verosimilitud (maximum likelihood)	24
2.5.4	MLE para redes Bayesianas	25
2.5.5	Aprendizaje de la estructura de una red Bayesiana	28
2.5.6	Estado del arte	32
2.5.7	Markov Chain Monte Carlo (MCMC)	34
2.6	Relaciones entre las redes de co-expresión (CGN) y las redes Bayesianas de interacción de genes (BIN)	34
2.7	Marcos de trabajo de redes Bayesianas	35
3	Desarrollo del marco de trabajo	37
3.1	Metodología general	37
3.1.1	Construcción y visualización de redes de co-expresión de genes	38
3.1.2	Construcción de la arquitectura óptima de una red Bayesiana y sus parámetros, a partir de los datos de expresión de genes	38

Índice general

3.1.3	Implementación de las herramientas para el análisis de redes complejas y Bayesianas de expresión de genes y sus relaciones	38
3.1.4	Caso de estudio: Análisis de datos de expresión de genes de microarreglos de DNA de transcriptomas	39
3.2	Implementación del marco de trabajo	39
3.2.1	Arquitectura general	40
3.2.2	Especificación funcional	42
3.3	Flujo de trabajo para el uso y adopción del marco Bayesiano	42
3.4	Comentario final	45
4	Método para construir redes de co-expresión	47
4.1	Introducción	47
4.2	Materiales y métodos	48
4.2.1	Preparación de los datos	48
4.2.2	Construcción de las redes de co-expresión génica	49
4.2.3	Análisis de redes complejas	50
4.3	Resultados	50
4.3.1	Construcción de la red	50
4.3.2	Identificación de clusters y anotaciones GO	51
4.3.3	Validación de los clusters identificados	52
4.4	Discusión	56
4.5	Comentarios concluyentes	57
5	Aprendizaje de redes Bayesianas	59
5.1	Introducción	59
5.2	Caracterización de un método general de aprendizaje de redes Bayesianas y sus parámetros.	59
5.2.1	La red Bayesiana inicial e inicialización de la matriz de adyacencia	60
5.2.2	La función de <i>verosimilitud</i> para el modelo de la red Bayesiana	60
5.2.3	El <i>vecindario</i> de la red Bayesiana <i>actual</i>	61
5.2.4	Evaluación de la función de <i>verosimilitud</i> para la red Bayesiana <i>candidata</i>	62
5.2.5	La probabilidad de aceptación de la red Bayesiana candidata dada la red Bayesiana actual	62
5.2.6	Aplicación del <i>criterio de aceptación</i> de la red Bayesiana <i>candidata</i> basado en el algoritmo de <i>Metropolis Hasting</i>	63
5.3	Caso discreto	63
5.3.1	Verosimilitud	63
5.3.2	Posterior	64
5.3.3	Prior	65
5.3.4	Complejidad	66
5.4	Simulación iterativa	66
5.5	Sobre-entrenamiento	67
5.6	Construcción de redes para el análisis	70
5.6.1	Red Ponderada (del inglés Weighted network)	70
5.6.2	Red Bayesiana minimal	71
5.6.3	Red Bayesiana reducida	75
5.7	Comentarios concluyentes	75

Índice general

6	Casos de estudio: modularidad en algunos clusters de genes de Escherichia coli.	78
6.1	Introducción	78
6.2	Los casos y su análisis	78
6.2.1	Transporte de maltosa	79
6.2.2	Transporte de L-arabinosa	83
6.2.3	Transporte de lactosa	84
6.2.4	Ensamble de hierro-azufre	85
6.3	Resumen aspectos computacionales	87
6.4	Comentarios concluyentes	87
7	Conclusiones y trabajo futuro	89
7.1	Conclusiones	89
7.2	Trabajo futuro	90
	Bibliografía	92

Índice de figuras

1.1	Entender como los rasgos moleculares de diferentes dominios biológicos se conectan en redes es crítico para el progreso de la biología del cancer. Tomado de (Blair, Kliebenstein y Churchill 2012)	2
2.1	El explorador de ontología de genes AmiGO. (A) Entrada a la página del portal. (B) Muestra de salida de una búsqueda rápida de un término GO. (C) Despliegue gráfico. (D) Vista de árbol del término GO y su lugar en la ontología. Tomado de Gene Ontology 2015a	7
2.2	Un micro-arreglo puede contener miles de "spots". Cada spot contiene muchas copias de la misma secuencia de ADN que únicamente representa un gen de un organismo. Tomado de M. Babu 2004	10
2.3	Esquema del protocolo experimental para estudiar expresión diferencial de genes. Tomado de M. Babu 2004	11
2.4	Datos de expresión de genes antes y después del procedimiento de normalización. Tomado de M. Babu 2004	12
2.5	Red o grafo	15
2.6	Red no dirigida	16
2.7	Red dirigida	16
2.8	Redes dirigidas y ponderadas	16
2.9	Estructura de una red	17
2.10	Propiedad del mundo pequeño(Watts & Strogatz, 1998)	18
2.11	Red de co-expresión con 7221 genes para 18 pacientes de cáncer gástrico	20
2.12	Patrón de regulación negativo o invertido	20
2.13	Mezcla de patrones de regulación	21
2.14	Una red bayesiana para el problema de cáncer de pulmón. Tomado de K. B. Korb y Nicholson 2010	23
2.15	Ejemplo de una búsqueda que requiere eliminación de arista. Tomado de Daphne Koller y Nir Friedman 2009	31
2.16	Ejemplo de búsqueda que requiere invertir. Tomado de Daphne Koller y Nir Friedman 2009	31
2.17	Red de co-expresión de genes (CGN) vs. red bayesiana de interacción de genes (BIN)	35
3.1	Diagrama de flujo de los pasos metodológicos.	38
3.2	Draft de arquitectura marco de trabajo de redes Bayesianas.	40
3.3	Diagrama de la arquitectura general.	41
3.4	Caso de uso "Identificar módulos"	43
3.5	Caso de uso "Identificar genes de interés biológico"	44
3.6	Flujo de trabajo para la experimentación del marco con E.coli	46
4.1	Ajuste al modelo de topología libre de escala y conectividad media.	52
4.2	Dendrograma de los módulos identificados en la red de E.coli construida con e método WGCNA.	55

Índice de figuras

4.3	Plot mapa de calor de la matriz de solapamiento topológico (TOM del inglés Topological Overlap Matrix)	55
4.4	Módulo de transporte de lactosa. Tomado de Santos-Zavaleta y col. 2019	57
5.1	Simulación MCMC con 1,000 iteraciones para el cluster de transporte de maltose en E.coli. En esta figura puede verse el número de aristas, el máximo grado de entrada y la función acumulada del cambio en el logaritmo de la posterior de cada red procesada.	67
5.2	Simulación iterativa con 18,470 iteraciones para el cluster de transporte de maltosa en E.coli. En esta figura puede verse el número de aristas, el máximo grado de entrada y la función acumulada del cambio en el logaritmo de la posterior de cada red procesada.	67
5.3	Tendencia a sobre-entrenamiento en el aprendizaje cuando se incluyen genes de diferentes clusters de E.coli en una misma simulación MCMC.	69
5.4	Comparación entre 3 redes Bayesianas minimales con 9 genes.	74
5.5	Red Bayesiana minimal reducida de los genes del cluster de transporte de maltosa en E.coli. Las etiquetas en la figura corresponden al orden en que la arista fue seleccionada seguido de la frecuencia de ocurrencia en el conjunto de redes Bayesianas dentro del rango del nivel óptimo. Los nodos fueron etiquetados con el gen.	76
6.1	Cluster de transporte de maltosa en la red de co-expresión de E.coli.	79
6.2	Resultados de la experimentación con el cluster de genes relacionado con el transporte de Maltosa. Las etiquetas en la figura corresponden al orden en que la arista fue seleccionada seguido de la frecuencia de ocurrencia en el conjunto de redes Bayesianas dentro del rango del nivel óptimo.	80
6.3	Causalidad encontrada en el resultado del modelo de red Bayesiana del cluster asociado con transporte de maltosa.	81
6.4	Identificación del operón malPQ en el cluster relacionado con transporte de maltosa.	81
6.5	Identificación del operón malK-lamB en el cluster relacionado con transporte de maltosa	82
6.6	Resultado sub-red del operón malEFG y malK y sus funciones génicas.	82
6.7	Cluster de transporte de L-arabinosa en la red de co-expresión de E.coli.	83
6.8	Identificación del operón araFGH en el cluster relacionado con transporte de arabinosa.	84
6.9	Regulación del operón araFGH por parte del gen araC.	84
6.10	Identificación del operón lacZYA en el cluster relacionado con metabolismo y transporte de lactosa.	85
6.11	Identificación del operón iscRSUA en el cluster relacionado con ensamble de hierro-azufre.	86
6.12	Tiempos de ejecución de las simulaciones para los clusters analizados. Se agregó el número de modelos en el rango del nivel óptimo que se encontraron en cada experimento.	87

Índice de cuadros

2.1	Matriz de expresión de genes que contiene filas para representar genes y columnas para representar condiciones biológicas.	13
2.2	Datos de expresión de genes por medida relativa. Tomado de M. Babu 2004	14
2.3	Datos de expresión por $\log_2(\text{tasadeexpresión})$. Tomado de M. Babu 2004	14
2.4	Datos expresión por valores discretos. Tomado de M. Babu 2004	14
2.5	Selección preliminar de nodos y valores para el ejemplo de cáncer de pulmón. Tomado de Murphy 2012	22
4.1	Valores de ajuste al modelo de topología libre de escala y conectividad media de la red construida.	51
4.2	Resumen de los clusters identificados.	52
4.3	Propiedades topológicas de la red y algunos clusters detectados.	53
4.4	Clusters identificados en la red de co-expresión génica.	53
4.5	Genes con función biológica afín dentro de los cluster validados. La columna k corresponde a la conectividad media de cada gen.	54
4.6	Resultado de validación de clusters empleando el índice Jaccard.	56
5.1	Rango del nivel óptimo para el ejemplo de la simulación iterativa con el cluster de transporte de maltosa en E.coli. La columna Máx log-posterior corresponde al valor máximo de la función acumulada del logaritmo de los cambios en la posterior para cada intervalo de la simulación.	72
5.2	Matriz de adyacencia de la red ponderada para el ejemplo de la simulación iterativa con el cluster de transporte de maltosa en E.coli.	73

1 Introducción

1.1. Descripción general del proyecto

Los experimentos de micro-arreglos de DNA miden simultáneamente los niveles de expresión de miles de genes. Un problema importante en biología molecular es descubrir las redes de interacción y las características biológicas claves de los sistemas celulares a partir de las medidas de niveles de expresión de Micro-arreglos (Dey, D.K. and Ghosh, S. and Mallick, B.K. 2010). Uno de los enfoques usados para este problema es aprender una red bayesiana desde los datos de expresión (Pearl 1988) y (Cowell s.f.) .

La propuesta para abordar este problema es desarrollar un marco de trabajo de redes Bayesianas para análisis de conjuntos de genes de interés biológico a partir de datos de expresión generados por micro-arreglos.

Los micro-arreglos de DNA han sido la herramienta más utilizada para explorar transcritomas (conjunto de todas las moléculas de mRNA de una célula o población de células). En cáncer de mama, por ejemplo, esta tecnología tuvo éxito mejorando el sistema de clasificación, para proponer nuevos genes importantes en proceso de oncogénesis. Sin embargo, aún hay margen para mejorar el diagnóstico y la predicción de la enfermedad (Emmanuel Prestat y col. 2013).

En el descubrimiento de redes de interacción a través de la teoría de redes y análisis de redes complejas (Network sciences), se han podido modelar eventos complejos de biología molecular con el objetivo de abordar su estudio desde una perspectiva sistémica observando relaciones e interacciones en conjunto en lugar de ver elementos de manera aislada. Usando puntos y líneas se construyen redes que recrean matemáticamente distintas relaciones entre biomoléculas (proteínas o genes), como por ejemplo, interacciones entre proteínas o mecanismos regulatorios y de expresión; de manera que cada nodo corresponde a un gen o una proteína y las aristas representan algún tipo de interacción entre ellos.


En el marco de trabajo de redes Bayesianas que se propone, nos interesa inicialmente, construir un tipo de red de interacción de genes, llamado redes de co-expresión de Genes (GCN). Las GCN se definen como un grafo no dirigido en el que cada nodo corresponde a un gen, más exactamente a su perfil de expresión, y las aristas que los conectan representan relaciones de co-expresión, entendiéndose esta relación como la expresión de dos o más genes de manera simultánea. De esta manera, dos genes se conectan si sus perfiles de expresión están asociados entre las perturbaciones estudiadas.

Una vez se tiene la GCN, el paso a seguir es construir otro tipo de red de interacción; una red de regulación de genes, por medio de una red Bayesiana. Las redes de Bayes son una poderosa herramienta de representación de conocimiento y razonamiento bajo condiciones de incertidumbre que son típicas en aplicaciones del mundo real. Una red bayesiana es un grafo acíclico dirigido, en el cual los nodos representan las variables de un dominio, como, por ejemplo, en una red bayesiana de interacción de genes, los nodos representan genes. Las aristas corresponden a la dirección de dependencias probabilísticas entre ellos, y siguiendo con el ejemplo, las aristas representan relaciones de interacción (co-expresión y/o regulación) entre genes.

En este marco de trabajo Bayesiano, se articulará el análisis de redes complejas con

1 Introducción

Figura 1.1: Entender como los rasgos moleculares de diferentes dominios biológicos se conectan en redes es crítico para el progreso de la biología del cancer. Tomado de (Blair, Kliebenstein y Churchill 2012)



el aprendizaje basado en la simulación de Markov Chain Monte Carlo (MCMC), para aprender una red Bayesiana de interacción de genes (BIN). Muchos enfoques han sido desarrollados para el aprendizaje de redes Bayesianas. Uno de estos enfoques está basado en la simulación de MCMC. Aunque este enfoque resulta interesante, trabaja bien sólo para problemas con un número muy pequeño de variables (Dey, D.K. and Ghosh, S. and Mallick, B.K. 2010), sin embargo, definiendo una cadena de Markov sobre el espacio de posibles estructuras de la red bayesiana, es posible generar un conjunto de estructuras viables probabilísticamente (es decir que la estructura y los parámetros de la red se ajustan a los datos) para el grafo, haciendo una caminata aleatoria en la cadena de Markov asociada (Daphne Koller y Nir Friedman 2009) .

Finalmente, para darle coherencia (es decir, que los resultados tengan sentido desde la biología) y significancia (que los resultados sean pertinentes) biológica a los hallazgos del marco Bayesiano propuesto, con base en la BIN aprendida y los perfiles de expresión de genes analizados en la GCN, se vinculará información externa para comprender mejor los procesos biológicos, y poder realizar nuevos descubrimientos (M. Babu 2004) . Gene ontology (GO) es la principal iniciativa bioinformática para unificar la representación del gen y los atributos de los productos del gen, en todas las especies (The Gene Ontology 2008) . Las GO comprenden diversas bases de datos de anotaciones (por ejemplo, GeneMANIA (Warde-Farley y col. 2010) que permiten caracterizar a nivel funcional los genes, y con esta caracterización se asocian posibles funcionalidades para un conjunto de genes dado, y obtener información de interés biológico para los mismos.

1.2. Justificación

“Todos los modelos son incorrectos, pero algunos son útiles”(Box & Draper, 1987).

La motivación principal del trabajo es la de contribuir al entendimiento de algunas características claves de los sistemas celulares y como diferentes dominios biológicos se conectan y dan origen a un fenotipo o enfermedad.

En biología del cáncer, la integración de los datos es de vital importancia debido a la compleja interacción entre la genética, la señalización celular y las rutas metabólicas (ver Figura 1.1).

El descubrimiento de redes de interacción desde datos de expresión de genes y las características biológicas claves de los sistemas celulares es en general un problema abierto (Dey, D.K. and Ghosh, S. and Mallick, B.K. 2010).

El desarrollo de modelos matemáticos que sean consistentes y predictivos de los reales mecanismos biológicos subyacentes es un objetivo central de la biología de sistemas, ya que los modelos en mención pueden dirigir el diseño y ejecución de experimentos y estudios poco probables de éxito, y de paso ahorrar un poco de tiempo y dinero. La evaluación y

mejora de la utilidad de tales modelos continuará siendo un área activa de investigación, como afirma Blair en (Blair, Kliebenstein y Churchill 2012).

En ese sentido la justificación del trabajo se apoya en contribuir computacionalmente en la solución de problemas abiertos actuales en biología molecular y biología de sistemas.

1.3. Alcance

En este trabajo, se propone construir en principio una red de co-expresión de genes (GCN), a partir de datos de expresión de micro-arreglos. Después, a la red de co-expresión de genes se aplicará análisis de redes complejas para detectar módulos o agrupamientos (clusters) de genes que se co-expresan para construir entonces una red bayesiana de interacción de genes por simulación de Markov Chain Monte Carlo. Posteriormente, se identificarán conjuntos de genes de interés biológico (signature gene); analizando las relaciones entre ambas redes y su importancia biológica a través bases de datos de anotación de ontologías de genes (GO). Por último, se someterá el marco de trabajo Bayesiano a experimentación a través de algunos casos de estudio para explorar el transcriptoma del *E. coli*.

En el marco Bayesiano propuesto, después de construir las redes de co-expresión y redes Bayesianas de interacción de genes, y de analizar estas redes y sus relaciones, se pretende inferir en los perfiles de expresión, patrones que complementados con conocimiento biológico de las GO, aporten en el descubrimiento de funciones de genes o interacciones de genes de importancia biológica.

Para la construcción de redes de co-expresión se propone emplear el Análisis de Redes Ponderadas de Co-expresión de Genes (WGCNA del inglés Weighted Gene Coexpression Network Analysis) como un método para identificar módulos y sus relaciones con otros módulos, con fenotipos externos e identificar genes hub, es decir, altamente conectados con módulos (Langfelder y Steve Horvath 2008). Este método será usado para identificar módulos de co-expresión.

La construcción de la red bayesiana de interacción de genes se hará por simulación MCMC, usado el algoritmo Metropolis Hasting (MH). Una ventaja de este algoritmo es su habilidad para muestrear a partir de distribuciones probabilísticas de alta dimensionalidad.

Después, se llevará a cabo el análisis de ambas redes y sus relaciones, aplicando análisis de redes complejas, y además, se incorporarán anotaciones de GO, con el objetivo de descubrir en los perfiles de expresión, funciones y/o interacciones de genes de interés biológico.

Finalmente, se validará este marco de trabajo a través de un caso de estudio en *Escherichia coli*.

1.4. Objetivos

En esta sección presentamos por una parte la pregunta de investigación y la hipótesis del trabajo y por otra parte los objetivos que nos ayudaran a responder dicha pregunta desde este proyecto.

1.4.1. Pregunta de investigación e hipótesis

Que pueden las redes de co-expresión y las redes Bayesianas de interacción de genes construidas a partir de datos de expresión generados por micro-arreglos, decirnos acerca de genes de interés biológico y las características biológicas claves en los sistemas celulares ?

1 Introducción

La hipótesis de este trabajo es que existe una relación entre (1) las redes de co-expresión y las redes bayesiana de interacción de genes construidas a partir de datos de expresión generados por micro-arreglos, con respecto al (2) proceso biológico que dio origen a los datos de expresión de genes generados por micro-arreglos.

Usando datos reales y simulados es posible capturar relaciones entre las variables del modelo (nodos de la red) y los procesos biológicos subyacentes, entendiendo como procesos biológicos subyacentes, por ejemplo a una variedad de condiciones y topologías de rutas metabólicas; en una ruta bioquímica las reacciones son organizadas en rutas las cuales pueden converger, ramificarse o intersectarse para formar redes complejas (Blair, Kliebenstein y Churchill 2012).

1.4.2. Objetivo General

Desarrollar un marco de trabajo de redes Bayesianas para análisis de conjuntos de genes de interés biológico a partir de datos de expresión generados por micro-arreglos.

1.4.3. Objetivos Específicos

1. Revisar y adaptar computacionalmente la construcción y visualización de redes de co-expresión de genes.
2. Desarrollar la construcción automática de la arquitectura óptima de una red bayesiana y sus parámetros a partir de los datos de expresión de genes.
3. Conceptualizar, diseñar e implementar las herramientas de análisis de redes complejas y Bayesianas de expresión de genes y sus relaciones.
4. Someter el marco de trabajo construido a experimentación y análisis de datos de expresión de genes de micro-arreglos a través de un caso de estudio.

1.5. Estructura del documento

La organización de esta tesis es la siguiente. En el capítulo 2 se presenta el marco teórico y estado del arte del mismo.

En el capítulo 3 se presenta el desarrollo del marco de trabajo con los pasos metodológicos, la implementación y el flujo de trabajo para su uso y adopción. Aquí unimos todos los puntos de acuerdo al lineamiento de los pasos metodológicos presentados para dar cumplimiento a los tres primeros objetivos específicos del proyecto.

Los siguientes capítulos se refieren al desarrollo de los objetivos del proyecto: Capítulo 4 contiene la adopción del método WGCNA para la construcción de redes de co-expresión e identificación de clusters por medio del análisis de redes complejas. En capítulo 5, se presenta la caracterización del aprendizaje de redes Bayesianas, el capítulo 6 está enfocado al estudio de casos sobre el organismo *E. coli* con el flujo de trabajo de la experimentación y los análisis de los resultados, para dar cumplimiento al cuarto objetivo de la validación del marco de trabajo por medio de casos de estudio.

Finalmente, en la parte de las conclusiones y trabajo futuro se presentan las conclusiones de la tesis y la dirección para futuras investigaciones.

2 Marco teórico y estado del arte

Como preparación para el desarrollo del proyecto se elaboró un cubrimiento de ontologías de los genes (GO), datos de expresión de genes de micro-arreglos, redes de co-expresión, redes Bayesianas y sus métodos de aprendizaje y el análisis de las relaciones entre ambas redes. Se busca con este marco teórico y estado del arte desde lo que se encuentra en la literatura científica, preparar las bases para caracterizar los procesos de la construcción de una red de co-expresión, el aprendizaje de de redes Bayesianas de interacción de genes a partir de los datos de expresión generados por micro-arreglos y la consulta de bases de datos biológicas de anotaciones y un caso de estudio de exploración de transcriptomas.

Ya que no hace parte del alcance de este trabajo revisar la biología del gen, se recomienda ver Watson y col. 2013; Nguyen y col. 2002; Tözeren y Byers 2004 para mayor información.

2.1. Ontología de genes (Gene Ontology - GO)

2.1.1. Introducción

Los perfiles de expresión de genes pueden vincularse con información externa para comprender mejor los procesos biológicos y poder realizar nuevos descubrimientos M. Babu 2004. Gene ontology (GO) es la principal iniciativa bioinformática para unificar la representación del gen y los atributos de los productos del gen, en todas las especies The Gene Ontology 2008.

Definición

Pragmáticamente, una ontología es una representación de algo, acerca de lo cual, tenemos interés en saber. Así, la ontología representa algo que es detectable o directamente observable y sus relaciones. Aunque la nomenclatura del gen en sí misma pretende mantener y desarrollar vocabulario controlado del gen y sus productos, GO extiende el esfuerzo usando lenguaje etiquetado para que los datos sean legibles por una máquina, y hacerlo de manera unificada para todas las especies.

Objetivos

Los objetivos principales de GO son:

1. Mantener y desarrollar su vocabulario controlado del gen los atributos de los productos del gen (RNA - proteínas).
2. Anotar los genes y los productos del gen, y asimilar y diseminar sobre los datos anotados.
3. Proveer herramientas para fácil acceso a todos los aspectos de los datos provistos por GO, y permitir la interpretación funcional de datos experimentales usando GO, por ejemplo, mediante el análisis de enriquecimiento (enrichment analysis)

Dominios

La ontología cubre tres dominios:

1. Componente celular: Partes de la célula o su ambiente extra-celular.
2. Función molecular: Actividades elementales de un producto de un gen a nivel molecular, por ejemplo, la catálisis.
3. Proceso biológico: Operaciones o conjunto de eventos moleculares con un comienzo y fin definido, pertinente para el funcionamiento de unidades vivas integradas: células, tejidos, órganos y organismos.

Términos

Cada término GO en la ontología tiene un nombre, el cual puede ser una palabra o varias palabras, un identificador alfanumérico único, una definición con fuentes citadas y un espacio de nombres que indica el dominio al cual pertenece. Un término también puede tener sinónimos.

Ejemplo

Los archivos de ontologías GO están disponibles libremente, y un término puede verse así The Gene Ontology 2018:

```
id: GO:0000016
name: lactase activity
namespace: molecular_function
def: "Catalysis of the reaction: lactose + H2O = D-glucose + D-galactose."
synonym: "lactase-phlorizin hydrolase activity" BROAD [EC:3.2.1.108]
synonym: "lactose galactohydrolase activity" EXACT [EC:3.2.1.108]
xref: EC:3.2.1.108
xref: MetaCyc:LACTASE-RXN
xref: Reactome:20536
is_a: GO:0004553 ! hydrolase activity, hydrolyzing O-glycosyl compounds
```


Estructura

La ontología GO está estructurada como un grafo a-cíclico dirigido, y cada término tiene relaciones con uno o más términos en el mismo dominio, y algunas veces de otros dominios. El vocabulario GO está diseñado para ser neutral-especies e incluir términos aplicables a eucariotas, procariotas y organismos unicelulares y multicelulares.

Anotaciones

La anotación del genoma es la práctica de capturar datos sobre el producto de un gen, y las anotaciones de GO emplean términos de la ontología de GO para hacer esto. Los miembros del consorcio GO envían sus anotaciones para la integración y disseminación en el sitio Web GO, donde se pueden acceder en línea. Además del identificador del producto del gen y el término relevante de GO, las anotaciones GO tienen los siguientes datos: La referencia usada para la anotación, la fecha y el creador de la anotación.

Figura 2.1: El explorador de ontología de genes AmiGO. (A) Entrada a la página del portal. (B) Muestra de salida de una búsqueda rápida de un término GO. (C) Despliegue gráfico. (D) Vista de árbol del término GO y su lugar en la ontología. Tomado de Gene Ontology 2015a



2.1.2. Estado del arte

Existe varias herramientas disponibles en línea y para descargar que usan los datos proporcionados por GO, la gran mayoría proporcionada por terceros. El consorcio GO desarrolló y soporta dos herramientas:

1. AmiGO: Es una aplicación basada en web que permite a los usuarios consultar, explorar y visualizar ontologías y datos de anotación de producto de genes. Adicionalmente, tiene una herramienta BLAST, que permite análisis de conjuntos de grandes conjuntos de datos y una interfaz para consultar directamente la base de datos GO, ver figura 2.1.
1. EBO-Edit: Es un editor de ontologías de código abierto independiente de la plataforma, desarrollado y mantenido por el consorcio GO. Esta implementado en Java, y usa un enfoque orientado a grafos para desplegar y editar ontologías. Incluye búsqueda exhaustiva e interfaz de filtros con la opción de procesar subconjuntos de términos para hacer una visualización distinta. La herramienta también proporciona, un analizador (reasoner) que puede inferir enlaces que no se han definido explícitamente, basándose en las relaciones existentes y sus propiedades. A pesar de que fue desarrollada para ontologías biomédicas, está puede usarse para ver, buscar y editar cualquier ontología. Se encuentra disponible para descargar en The Gene Ontology 2014.

2.2. Datos de expresión de genes en micro-arreglos

A continuación, se presenta un breve resumen de los conceptos básicos sobre experimentos de micro-arreglos y una percepción de lo que los datos representan realmente, por

ejemplo, en la sección 4 , se proporcionará información de varios métodos computacionales que se pueden emplear para derivar resultados significativos de tales experimentos.

La tecnología de micro-arreglos se ha convertido en una herramienta indispensable que muchos biólogos usan para monitorear amplios niveles de expresión de genes del genoma en un organismo dado.

2.2.1. Definición y función

Un micro-arreglo es frecuentemente una lámina o platina de vidrio (glass slide) en la cual se fijan de manera ordenada, moléculas de DNA a una localización específica llamada spots (o features).

Un micro-arreglo puede contener miles de spots y cada spot, puede contener unos pocos millones de copias de moléculas idénticas de DNA, que corresponden únicamente a un gen (ver figura 2.2).

El DNA en un spot puede ser genómico (gDNA) o un tramo corto de hebras oligonucleótido que corresponden a un gen.

Los micro-arreglos pueden ser usados para medir expresión de genes de muchas maneras, pero una de las aplicaciones más populares es para comparar expresión de un conjunto de genes de una célula en una condición particular A (condition A) con respecto al mismo conjunto de genes de la célula referencia bajo condiciones normales (condition B) (ver figura 2.3):

- Primero el RNA es extraído de las células. Paso a seguir, las moléculas de RNA se transcriben de forma inversa en cDNA usando una enzima transcriptasa inversa y los nucleótidos son marcados con tintas fluorescentes diferentes. Por ejemplo, el cDNA del cultivo de células en condición A puede ser etiquetado con tinta roja, y el cultivo de células en condición B con tinta verde.
- Los spots son pintados en la platina de vidrio (glass slide) por un robot o sintetizados por el proceso de fotolitografía.
- Una vez las muestras han sido marcadas, se les permite hibridar en la misma lámina de vidrio (glass slide). En este punto, cualquier secuencia cDNA en la muestra hibridará con spots específicos en la lámina de vidrio que contengan su secuencia complementaria.
- Como premisa se tiene que la cantidad de cDNA ligado a spots será directamente proporcional al número inicial de moléculas RNA presentes para el gen en ambas muestras.
- El siguiente al paso a la hibridación, una vez los spots en el micro-arreglo han hibridado, son excitados por láser y escaneados a longitudes de onda apropiados para detectar los colorantes rojo y verde.
- La cantidad de fluorescente emitido bajo excitación corresponde a la cantidad de ácido nucleico ligado. Por ejemplo, si el cDNA de la condición A para un gen particular está en mayor abundancia que el de condición B, se podría encontrar el spot en rojo. Si el gen fue expresado en el mismo grado en ambas condiciones, el spot podría estar amarillo, y si el gen no fue expresado en ninguna condición, el spot podría estar en negro.

- Así, lo que se ve al final del experimento es una imagen del micro-arreglo, en la cual cada spot que corresponde a un gen tiene un valor fluorescente asociado que representa el nivel relativo de expresión de dicho gen.

2.2.2. Introducción al procesamiento de imágenes, transformación y normalización

Procesamiento de imágenes y análisis

El primer paso en el análisis de datos de micro-arreglos es procesar la imagen que almacena el nivel relativo de expresión de cada gen, resultado del proceso que se mencionó en el numeral anterior.

El procesamiento de imágenes comprende los siguientes pasos, para mayor detalle ver M. Babu 2004 :

1. Identificación de los spots y diferenciación de los mismos contra falsas señales.
2. Determinación del área de spot a ser estudiado y determinación de la región local para estimar el fondo de la hibridación.
3. Informe de resumen estadístico y asignación de intensidad de spot después de restar la intensidad de fondo.

Transformaciones de la tasa de expresión

La tasa de expresión (expression ratios) es una métrica frecuentemente usada para medir el nivel de expresión relativo para un gen, el cual puede ser medido como la cantidad de luz roja o verde emitida durante la excitación.

La tasa de expresión de un gen esta definida como:

$$T_k = \frac{R_K}{G_K} \quad (2.1)$$

Para cada gen k en el arreglo, donde R_k representa a métrica de intensidad de spot para la muestra de prueba y G_k representa la métrica de intensidad de spot para la muestra de referencia.

Aunque la tasa de expresión puede revelar patrones inherentes en los datos, también, puede eliminar toda la información acerca de los niveles de expresión absoluta de los genes, y los problemas asociados aparecerán cuando se intente identificar genes regulados diferencialmente. Algunas técnicas para mitigar la eliminación (perdida de niveles de expresión absoluta) que se acaba de mencionar se pueden ver en M. Babu 2004.

La normalización de datos

La normalización es un término usado para describir la eliminación de variaciones causadas por la eficiencia en el marcado diferencial de los dos colorantes fluorescentes o variaciones causadas por diferentes cantidades de material mRNA en las dos muestras. Así, la normalización permite la comparación apropiada de los datos obtenidos de las muestras.

1. El primer paso en un procedimiento de normalización es elegir un conjunto de genes (gene-set); el cual consiste de genes para los cuales el nivel de expresión podría no cambiar bajo las condiciones estudiadas, es decir, la tasa de expresión para todos los genes del conjunto se espera sea igual a 1.

Figura 2.2: Un micro-arreglo puede contener miles de "spots". Cada spot contiene muchas copias de la misma secuencia de ADN que únicamente representa un gen de un organismo. Tomado de M. Babu 2004




Figura 2.3: Esquema del protocolo experimental para estudiar expresión diferencial de genes. Tomado de M. Babu 2004





Figura 2.4: Datos de expresión de genes antes y después del procedimiento de normalización. Tomado de M. Babu 2004



2. Desde el conjunto de genes seleccionado, se calcula un factor de normalización (normalization factor), el cual es un número que cuenta la variabilidad observada en dicho conjunto.
3. Este procedimiento se aplica para los otros genes de una condición biológica (condición A o B) en el experimento de micro-arreglos.

El procedimiento de normalización genera un cambio de los datos. La figura 2.4, presenta datos de expresión antes y después de un procedimiento de normalización para mayor detalle ver M. Babu 2004.

2.2.3. Análisis de datos de expresión de genes

Los datos procesados, después del procedimiento de normalización, pueden ser representados en forma de matriz, por medio de una matriz de expresión de genes (Ver cuadro 2.1)

Cada fila de la matriz corresponde a un gen y cada columna podría corresponder a una condición experimental o punto de tiempo específico en el cual la expresión del gen correspondiente ha sido medido.

El perfil de expresión de un gen (gene expression profile) es el nivel acumulado de expresión de dicho gen, en diferentes condiciones experimentales. El perfil de expresión de la muestra es el nivel acumulado de expresión para todos los genes bajo una condición experimental.

Cuadro 2.1: Matriz de expresión de genes que contiene filas para representar genes y columnas para representar condiciones biológicas.

	C1	C2	C3	C4
Gen A	10	80	40	20
Gen B	100	200	400	200
Gen C	30	240	60	60
Gen D	20	160	80	80

Adicional a los niveles, se puede agregar anotación al gen o a la muestra. Por ejemplo, se puede proporcionar la función del gen o el detalle biológico de la muestra (estado “normal” y estado “enfermo”).

Dependiendo de si se utiliza anotaciones o no, el análisis de datos de expresión de genes puede ser clasificado en dos tipos: (1) aprendizaje supervisado y (2) aprendizaje no-supervisado.

En el caso del aprendizaje no-supervisado, los datos de expresión son analizados para identificar patrones que pueden agrupar genes o muestras en grupos (clusters) sin emplear anotaciones. Por ejemplo: los genes con perfil de expresión similar pueden ser agrupados sin usar anotaciones, y posteriormente, la información de anotaciones puede ser tomada en cuenta después para dar hacer inferencias biológicas significativas, para mayor detalle ver M. Babu 2004 o la sección 4.

Representación de datos de expresión de genes

Para hacer útil cualquier comparación o análisis biológico debemos saber lo que representan los datos de la matriz de expresión de genes. Estos datos pueden ser representados de cinco diferentes maneras (para más detalle ver M. Babu 2004):

1. Medida absoluta: Cada celda de la matriz representa el nivel de expresión del gen en unidades abstractas, ver cuadro 2.1.
2. Medida relativa o tasa de expresión: El nivel del gen en unidades abstractas es normalizado con respecto a su expresión en una condición biológica de referencia, como se muestra en el cuadro 2.2.
3. $\log_2(\text{tasadeexpresión})$: La medida relativa o tasa de expresión es mapeada de manera simétrica por la función logaritmo de base 2, como puede verse en el cuadro 2.3.
4. Valores discretos: La representación $\log_2(\text{tasadeexpresión})$ se convierte a números discretos. Por ejemplo, se puede usar una matriz binaria de 1 y 0, donde 1 significa que el gen correspondiente se expresó por encima de un umbral y 0 por debajo, como puede observarse en el cuadro 2.4.
5. Representación de perfiles de expresión como vectores: Un perfil de expresión (de un gen o de una muestra) puede ser pensado como un vector y representado en el espacio del vector. Así, el perfil de expresión de un gen i puede ser representado como el vector fila:

$$G_i = [x_{i1}, x_{i2}, x_{i3}, \dots, x_{in}]$$

Y, el perfil de expresión de una muestra j puede ser representado como el vector columna:

Cuadro 2.2: Datos de expresión de genes por medida relativa. Tomado de M. Babu 2004

	C1/C4	C2/C4	C3/C4
Gen A	0.50	4.00	2.00
Gen B	0.50	1.00	2.00
Gen C	0.50	4.00	1.00
Gen D	0.25	2.00	1.00

Cuadro 2.3: Datos de expresión por $\log_2(\text{tasadeexpresión})$. Tomado de M. Babu 2004

	$\log_2(C1/C4)$	$\log_2(C2/C4)$	$\log_2(C3/C4)$
Gen A	-1	2	1
Gen B	-1	0	1
Gen C	-1	2	0
Gen D	-2	1	0

$$G_j = \begin{bmatrix} x_{1j} \\ \vdots \\ x_{mj} \end{bmatrix}$$

Estado del arte

La Secuenciación de Alto Rendimiento de ARN (RNA-Seq del inglés RNA Sequencing) es una tecnología más reciente que los micro-arreglos, para detectar miles de genes expresados (transcritos) en un solo experimento, y se basa en las nuevas técnicas de Secuenciación de Segunda Generación (NGS del inglés Next Generation Sequencing) que ofrecen la ventaja de producción de grandes cantidades de secuencias a un bajo costo Metzker 2010 y Mardis 2013.

En la técnica RNA-Seq las secuencias producidas son proporcionales a la expresión, hecho que permite la detección y medición de esta última. En comparación con los micro-arreglos de ADN, el RNA-Seq permite determinar la expresión de manera más precisa Young y col. 2012 , y además no está limitada a la detección de transcritos basado en un genoma conocido lo que permite su aplicación en el estudio de organismos no modelo.

2.3. Redes complejas


2.3.1. Introducción a las redes complejas

El análisis de redes complejas (network science) es un campo académico interdisciplinario que estudia redes complejas (complex networks) como redes de telecomunicaciones, redes

Cuadro 2.4: Datos expresión por valores discretos. Tomado de M. Babu 2004

	$D[\log_2(C1/C4)]$	$D[\log_2(C2/C4)]$	$D[\log_2(C3/C4)]$
Gen A	0	1	0
Gen B	0	0	0
Gen C	0	1	0
Gen D	-1	0	0

Figura 2.5: Red o grafo



de computadores, redes biológicas, redes cognitivas y semánticas y redes sociales. Este campo se apoya en teorías y métodos incluyendo teoría de grafos desde la matemática, mecánica estadística desde la física, minería de datos y visualización de información desde las ciencias de la computación, modelamiento inferencial desde la estadística y estructura social desde la sociología. El concejo de investigación nacional de los Estados Unidos, lo define como “el estudio de las redes que representan fenómenos físicos, biológicos y sociales, dirigido a la construcción de modelos predictivos de dichos fenómenos”.

Recientemente a través de la teoría de redes se han podido modelar eventos complejos de biología molecular con el objetivo de abordar su estudio desde una perspectiva sistémica observando relaciones e interacciones en conjunto en lugar de ver elementos de manera aislada.

Usando puntos y líneas se construyen redes que recrean matemáticamente distintas relaciones entre biomoléculas (proteínas o genes) como por ejemplo interacciones entre proteínas o mecanismos regulatorios y de expresión. Las redes de co-expresión de genes (NCG) son un ejemplo de aplicación de este enfoque para estudiar la complejidad de las relaciones entre perfiles de expresión génica obtenidos masivamente mediante tecnologías como los micro-arreglos de ADN o técnicas NGS (ver numeral 5.4).

Una red o grafo es un conjunto de nodos (vértices), con conexiones entre ellos, llamados arcos (aristas).

Matemáticamente, un grafo H es un par ordenado $G = (V, E)$, donde V es un conjunto de vértices o nodos y E es un conjunto de aristas o arcos, que relacionan estos nodos. Normalmente V suele ser finito, y se llama ordinal del grafo G a su número de vértices $|V|$.

El grado de un vértice o nodo en V es igual al número de arcos E que se encuentran en él. Un bucle es una arista que relaciona al mismo nodo.

Existen diferentes tipos de redes:

1. Redes No dirigidas: En las cuales no hay un origen y un destino en la relación, este tipo de relaciones son simétricas

Como puede observarse en siguiente figura, las redes se pueden representar por medio de una matriz de adyacencia, indicando para cada posición $g_{ij} = 1$, si el nodo i está relacionado con el nodo j por medio de una arista.

Figura 2.6: Red no dirigida



Figura 2.7: Red dirigida



1. Redes dirigidas: En estas redes para cada arista o arco, puede haber una dirección en un sentido, pero no necesariamente en el otro sentido.

1. Redes dirigidas y ponderadas: Es una red dirigida que además tiene asociada un peso en la relación representada por el arco o arista.

La estructura de una red es la forma o topología de la misma. Existen diversas topologías para una red como se muestra en la figura 2.9.

Un camino es ir desde el nodo i_1 a i_k : compuesto de una secuencia de nodos $(i_1, \dots, i_k)$ y una secuencia de aristas $(i_1i_2, \dots, i_{(k-1)}i_k)$ de tal forma que existe $i_{(k-1)}i_k$ en G para cada k .

Un componente es el máximo sub-grafo conectado (V', E') subconjunto de (V, E) , Algunas propiedades de las redes se describen a continuación:

1. Densidad: Proporción de aristas presentes en la red sobre el número máximo posible.
2. Reciprocidad: Proporción de aristas o arcos que son recíprocos en la red (aplica para redes dirigidas).

Figura 2.8: Redes dirigidas y ponderadas





Figura 2.9: Estructura de una red



3. Distancia: La distancia entre un par de nodos, es el número de nodos que debe recorrerse para unirlos.
4. Distancia geodésica: Es la distancia del camino más corto entre un par de nodos.
5. Diámetro: Es la longitud de la distancia geodésica más larga entre cualquier par de nodos de la red


Algunas medidas de centralidad y prestigio de las redes, son las siguientes:

1. Grado de entrada: Número de aristas totales que un nodo recibe de otros en la red.
2. Grado de salida: Número de aristas totales que un nodo envía a otros en la red.
3. Intermediación (betweenness): Medida de frecuencia con la que un nodo aparece en el camino más corto entre dos nodos.
4. Cercanía (closeness): Que tan cerca está un nodo de los demás nodos en la red basados en la distancia geodésica (camino de longitud más corta).
5. Excentricidad (eccentricity): La distancia de un nodo al nodo más alejado de él en la red.
6. Coeficiente de agrupamiento (clustering) de cada nodo: Número de conexiones entre los amigos (nodos que se relacionan) de un nodo sobre el total de posibles conexiones entre los amigos del nodo (es decir mide la transitividad).

2.3.2. Análisis de redes complejas

Un análisis común en redes complejas es validar la propiedad del mundo pequeño. Esta propiedad se da cuando la red presenta un elevado promedio (C) de agrupamiento (clustering) y un bajo promedio de la distancia geodésica (L) al mismo tiempo. Una interpretación

Figura 2.10: Propiedad del mundo pequeño(Watts & Strogatz, 1998)



intuitiva de la propiedad del mundo pequeño indicaría que fracción de mis amigos (nodos que se relacionan) son amigos unos de otros?

Como puede verse en la figura anterior el análisis de una red que presenta propiedad de mundo pequeño, revela que pocos nodos (Hubs) tienen muchas relaciones (aristas) con otros nodos, sin embargo, la mayoría de nodos están pobremente relacionados con respecto al total de nodos de la red.

Con las redes complejas se disminuye la complejidad de conjuntos grandes de datos de expresión, y mediante su análisis topológico se pueden detectar patrones de expresión subyacentes, inferir funcionalidades biológicas e identificar genes relevantes en procesos biológicos de interés como enfermedades o estímulos ambientales.

En el análisis topológico de las redes y módulos, se pueden identificar genes sobresalientes por su alta conectividad y/o centralidad de intermediación, los cuales podrían ser relevantes en los procesos de los sistemas celulares.

2.3.3. Estado del arte

Por ejemplo, la conectividad, que denota el grado de conexión de los genes, y la centralidad de intermediación (betweenness centrality), que indica el grado en que un nodo actúa como puente entre otros, son propiedades importantes biológicamente Prifti y col. 2010 pues permiten detectar hubs (genes altamente conectados) y bottlenecks (genes con alta intermediación), respectivamente, los cuales tienden a estar relacionados con la esencialidad en procesos funcionales. De esta manera se pueden elegir los genes más llamativos desde el punto de vista topológico y que a la vez tengan relevancia biológica. Dong y S. Horvath 2007 y S. Horvath y Dong 2008 explican varias propiedades de las redes de co-expresión que tienen un significado biológico importante.

2.4. Redes de co-expresión de genes

2.4.1. Introducción a las redes de co-expresión de genes

Las redes de co-expresión de Genes (GCN), se definen como un grafo no dirigido en el que cada nodo corresponde a un gen, más exactamente a su perfil de expresión, y las aristas que los conectan representan relaciones de co-expresión, entendiéndose esta relación como la expresión de dos o más genes de manera simultánea. De esta manera, dos genes se conectan si sus perfiles de expresión están asociados entre las perturbaciones estudiadas.

Estas redes proveen información de relaciones de asociación, similitud de expresión y vecindad entre genes que eventualmente permiten inferir interacciones entre las proteínas que codifican. Generalmente estas redes se construyen a partir de datos de expresión provenientes de micro-arreglos de ADN y pueden ser de dos tipos según la conexión entre los nodos: sin pesos, en las que sus aristas denotan si hay una asociación entre un par de nodos, y con pesos, en las que se cuantifica el grado de asociación entre los nodos por medio de un atributo llamado peso, el cual corresponde comúnmente a un valor en el rango $[0, 1]$.

2.4.2. Estado del arte

Una de las aplicaciones de estas redes es la identificación de grupos de nodos altamente co-expresados denominados módulos, los cuales indican funcionalidades comunes entre los genes que los conforman. B. Zhang y S. Horvath 2005a definen en un método para la construcción de redes con pesos denominado Análisis de Redes Ponderadas de Co-expresión de Genes (WGCNA del inglés Weighted Gene Coexpression Network Analysis) en donde se usa el coeficiente de correlación de Pearson como medida de co-expresión entre los genes (nodos).

Básicamente este método consiste en la creación de una matriz que codifica el grado o fuerza de conexión entre pares de nodos. De manera general el método comprende los siguientes pasos: (1) preparación de los datos de expresión, (2) definición de una medida de similitud entre nodos, (3) definición de una función de adyacencia entre nodos, (4) definición de los parámetros de adyacencia, (5) definición de una medida de disimilitud entre los nodos, y finalmente, (6) identificación de los módulos. Los autores del método han desarrollado WGCNA, un paquete de lenguaje R que cuenta con diferentes funciones para la construcción y análisis de las GCN.


La visualización de estas redes se puede lograr con aplicaciones como Cytoscape (<http://www.cytoscape.org/>), Gephi (<http://gephi.github.io/>), o gViz (<http://urbm-cluster.urbm.fundp.ac.be/webapps/gviz/>) ver figura 2.11.

Por ejemplo, Xue y col. 2013a usan las CGN para identificar y seleccionar genes candidatos claves en el proceso de desarrollo embrionario en humanos y ratones. Por su parte Davidson y col. 2011a identifican genes candidatos para estudios sobre desarrollo reproductivo y mejoramiento del potencial de producción en maíz. Finalmente se puede mencionar a Hollender y col. 2014a, quienes a través del análisis de las CGN, identifican genes y rutas metabólicas involucrados en la floración y desarrollo de frutos en fresa silvestre.

Por otra parte, dos genes pueden estar relacionados el uno con el otro aun cuando sus patrones de expresión muestren comportamiento negativo o invertido Yu y col. 2003. En la Figura 2.12, los patrones de expresión de genes de rata *Mrps26* y *Pfn2*, tomados del conjunto de datos de NCBI, GDS3702, claramente muestran comportamiento negativo. Las ontologías de los genes sugieren que ambos son responsables de la regulación de producción de interferón-beta.


También, se han observado en los conjuntos de datos de levadura dados en Cheng

Figura 2.11: Red de co-expresión con 7221 genes para 18 pacientes de cáncer gástrico




Ref.S. Mohammad H. Oloomi - I have created the network by programming in R and then I have created the network image using Cytoscape.

Figura 2.12: Patrón de regulación negativo o invertido



Ref.Roy et al. BMC Bioinformatics 2014 15(Suppl 7):S10
doi:10.1186/1471-2105-15-S7-S10.

Figura 2.13: Mezcla de patrones de regulación



Ref. Roy et al. BMC Bioinformatics 2014 15(Suppl 7):S10
doi:10.1186/1471-2105-15-S7-S10.

y Church 2000, los genes YBL002W y YBL003C con patrón similar y el gen YBL006W con patrón invertido con respecto a los otros dos genes. Como se observa en la Figura 15, los patrones de expresión también comparten regulación mezclada.

La ontología de los genes sugiere que los tres genes en mención están involucrados en la organización de nucleosomas, DNA, cromatina y cromosoma y sub-unidades macromoleculares celulares. Un grupo de genes puede compartir una combinación de co-regulación positiva y negativa en pocas condiciones o en pocos puntos de tiempo. Computacionalmente, muchas técnicas no consideran los patrones de regulación positivos y negativos para presentar co-expresión o interacción de genes con importancia biológica asociada Roy, Bhattacharyya y Kalita 2014.

Trabajos relacionados

Xue et al. en Xue y col. 2013b usan las CGN para identificar y seleccionar genes candidatos claves en el proceso de desarrollo embrionario en humanos y ratones. Por otra parte, Davidson et al. en Davidson y col. 2011b identifican genes candidatos para estudios sobre desarrollo reproductivo y mejoramiento del potencial de producción en maíz. También, Hollender et al. en Hollender y col. 2014b a través del análisis de las CGN, identifican genes y rutas metabólicas involucrados en la floración y desarrollo de frutos en fresa silvestre. Además, Liu et al. en W. Liu y col. 2018 empleando la base de datos de Kim y col. 2015 y WGCNA, construyen exitosamente una red de co-expresión génica de *E. coli* e identifican diversos clusters y los comparan con el trabajo previo de Treviño et al. en Treviño y col. 2012, encontrando genes de interés biológico en sus predicciones. Por último, una plataforma de análisis y visualización de redes para analizar diversos datos de las Omicas (ciencias genómicas) que ha surgido en los últimos es presentada por Jang et al. en Jang y col. 2016.

Cuadro 2.5: Selección preliminar de nodos y valores para el ejemplo de cáncer de pulmón.
Tomado de Murphy 2012

Variable	Valores
Pollution	low, high
Smoker	T, F
Cancer	T, F
Dyspnoea	T, F
X-ray	pos, neg

2.5. Aprendizaje Bayesiano fundamentos y estado de arte

2.5.1. Definición y representación de una red Bayesiana

Un modelo de red bayesiana puede ser definido como un par $B = (G, \rho)$. Aquí $G = (\nu, \varepsilon)$ es un grafo a-cíclico dirigido que representa la estructura de la red, ν denota un conjunto de nodos y ε un conjunto de aristas. Igualmente, cada elemento del vector ρ representa una probabilidad condicional Faming 2010.

Ejemplo: problema de cáncer de pulmón

Tomado de K. B. Korb y Nicholson 2010, un paciente ha estado sufriendo de dificultad para respirar (dyspnoea), y visita al doctor preocupado de tener cáncer de pulmón. El doctor sabe que otras enfermedades como tuberculosis, bronquitis son posibles causas del síntoma, además del cáncer de pulmón. También, el doctor sabe qué otra información relevante incluir: si el paciente es o no fumador (incrementa la probabilidad de cáncer o bronquitis), y que tanta exposición a aire contaminado ha tenido el paciente. Un examen de rayos X positivo podría también indicar TB o cáncer.

Representando la problemática del ejemplo, por medio de una red bayesiana, el conjunto de nodos ν del grafo G podrían ser los que se muestran en la tabla 2.5.

La estructura o topología de una red Bayesiana captura las relaciones entre los nodos. Continuando con el ejemplo, nos preguntamos qué factores afectan la probabilidad de que el paciente tenga cáncer? Si la respuesta es contaminación y cigarrillo (pollution and smoking), entonces deberíamos tener aristas desde estos nodos a cáncer. Igualmente, tener cáncer produce dificultad respiratoria en el paciente (dyspnoea) y aumenta la probabilidad de un examen de rayos X (X-ray) positivo, por lo tanto, debemos tener aristas desde el nodo cáncer a los nodos Dyspnoea y X-ray. El conjunto de aristas ε se muestra a continuación, en la figura 2.14.


Para un nodo $\nu_i \in \nu$, un padre de ν_i es un nodo desde el cual existe una arista que va dirigida a ν_i . El conjunto de padres de ν_i se denota $pa(\nu_i)$. Así, de acuerdo a la Figura 2.14, si hacemos $\nu_i = \text{Cancer}$, entonces $pa(\nu_i) = [\text{Pollution}, \text{Smoker}]$

En el ejemplo (caso discreto) ν_i es una variable aleatoria con distribución categórica que toma valores en un conjunto finito $[\nu_1, \dots, \nu_{r_i}]$, Según el cuadro 2.5, si tomamos $\nu_i = \text{Pollution}$, entonces, el conjunto finito es $set(\nu_i) = [\text{low}, \text{high}]$

Existen $q_i = \prod_{\nu_j \in pa(\nu_i)} r_j$ posibles valores conjuntos (joint states) de los padres de ν_i . Haciendo de nuevo $\nu_i = \text{Cancer}$, y $pa(\nu_i) = [\text{Pollution}, \text{Smoker}]$, (ver figura 2.14), entonces $q_i = \prod_{\nu_j \in pa(\nu_i)} r_j = r_{\text{Pollution}} * r_{\text{Smoker}} = (2) * (2) = 4$

Es decir, que en la tabla asociada al nodo Cancer, existen cuatro posibles valores conjuntos (joint states), a saber:

Figura 2.14: Una red bayesiana para el problema de cáncer de pulmón. Tomado de K. B. Korb y Nicholson 2010



1. $Pollution = High, Smoker = True$
2. $Pollution = High, Smoker = False$
3. $Pollution = Low, Smoker = True$
4. $Pollution = Low, Smoker = False$

Volviendo de nuevo al par $B = (G, \rho)$ que define la red Bayesiana, dijimos que cada elemento del vector ρ representa una probabilidad condicional; es decir, p_{ijk} es la probabilidad de que la variable v_i sea igual a j dado que su padre $pa(v_i)$ es igual a k . Así, haciendo $p_{ijk} = p_{XRay, pos, True} = 0,90$ (ver figura 2.14).

Naturalmente, ρ tiene las siguientes restricciones $p_{ijk} \geq 0$ y $\sum_{j=1}^{r_i} p_{ijk} = 1$.

En una red Bayesiana, la distribución de probabilidad conjunta de las variables $\nu = [\nu_1, \dots, \nu_d]$ puede ser especificada de la siguiente forma:

$$P(\nu) = \prod_{i=1}^d P(\nu_i | pa(\nu_i)) \quad (2.2)$$

Siguiendo con el ejemplo de cáncer de pulmón, podríamos calcular la probabilidad conjunta, para un caso particular, así (ver figura 2.14):

$$\begin{aligned}
 &P(Pollution = L \wedge Smoker = F \wedge Cancer = T \wedge Xray = pos \wedge Dyspnoea = T) = \\
 &= P(Pollution = L) * P(Smoker = F) * P(Cancer = T | Pollution = L, Smoker = F) \\
 & * P(Xray = pos | Cancer = T) * P(Dyspnoea = T | Cancer = T) \\
 &= (0,90) * (0,70) * (0,001) * (0,90) * (0,65) = 0,00036855
 \end{aligned}$$

Ahora, sea $D = [\nu_1, \dots, \nu_N]$ un conjunto de muestras independientes e idénticamente distribuidas (iid), obtenidas de $P(\nu)$, y sea n_{ijk} el número de muestras para las cuales, la variable ν_i es igual a j dado que su padre $pa(\nu_i)$ es igual a k , entonces, los contadores de muestras $(n, \dots, n_{ir_ik})$ siguen una distribución multinomial. Es decir,

$$(n_{i1k}, \dots, n_{ir_ik}) \sim \text{Multinomial}(\sum_{j=1}^{r_i} n_{ijk}, \rho_{ik}); \rho_{ik} = (\rho_{i1k}, \dots, \rho_{ir_ik})$$

2.5.2. Tipos de razonamiento en redes Bayesianas

Las redes Bayesianas proveen representaciones completas de distribuciones de probabilidad sobre sus variables. Esto implica que ellas pueden ser condicionadas sobre cualquier conjunto de sus variables, soportando cualquier dirección de razonamiento:

- Por ejemplo, uno puede realizar diagnóstico, razonando desde el síntoma a la causa, como cuando el doctor (en el ejemplo del cáncer de pulmón) observó disnea y entonces, cambió su creencia sobre el cáncer, si el paciente es fumador. Note que este razonamiento ocurre en la dirección opuesta de la arista de la red.
- También, podemos realizar predicción, razonando desde nueva información acerca de la causa hacia nuevas creencias acerca del efecto, siguiendo la dirección de las aristas. Por ejemplo, el paciente puede decir a su médico que es fumador, aun antes de que cualquier síntoma haya sido juzgado, el doctor sabe que aumentará la probabilidad de que el paciente tenga cáncer K. B. Korb y Nicholson 2010.

2.5.3. Principio de la máxima verosimilitud (maximum likelihood)

Contexto del problema del aprendizaje

Supongamos que observamos un conjunto de muestras independientes e idénticamente distribuidas (iid) de un conjunto de variables aleatorias X a partir de una distribución desconocida $P^*(X)$. Asumimos que conocemos el espacio muestral con el que estamos tratando.

Ahora, definimos el conjunto de muestras para entrenamiento como D y consideramos que este consiste de instancias de $X : \xi[1], \dots, \xi[M]$.

Lo siguiente que necesitamos considerar es exactamente qué deseamos aprender?

Supongamos ahora que se nos da un modelo paramétrico para el cual deseamos estimar los parámetros. Formalmente un modelo paramétrico es definido por una función $P(\xi : \theta)$, especificado en términos de un conjunto de parámetros.

Dado un conjunto particular de valores de parámetros θ y una instancia ξ de X , el modelo asigna una probabilidad a ξ . Adicionalmente, para cada elección de parámetros θ , $P(\xi : \theta)$ debe ser una distribución válida; es decir, esta debe ser positiva y

$$\sum_{\xi} P(\xi : \theta) = 1$$

En general, para cada modelo, no todos los valores de parámetros son válidos. Así, necesitamos definir el espacio de parámetros Θ , el cual será el conjunto de parámetros permitidos.

La función de verosimilitud

El siguiente paso para la estimación de máxima verosimilitud es definir la función de verosimilitud. Esta función, para una elección de parámetros θ es la probabilidad que el modelo instancie los datos de entrenamiento:

$$\ell(\theta : D) = \prod_m P(\xi[m] : \theta)$$

Estimación de máxima verosimilitud (MLE)

Una vez definida la función likelihood, podemos usar la estimación de máxima verosimilitud para elegir los valores de los parámetros. Dado un conjunto de datos D , elegir los parámetros $\hat{\theta}$ que satisfaga

$$\ell(\hat{\theta} : D) = \max_{\theta \in \Theta} \ell(\theta : D)$$

2.5.4. MLE para redes Bayesianas

En un plano más general del problema, ahora revisamos la estimación de parámetros para una red Bayesiana. Para hacerlo posible, la estructura de las redes Bayesianas nos permite reducir el problema de estimación de parámetros a un conjunto de sub-problemas independientes que se pueden resolver usando MLE.

Un ejemplo simple

El ejemplo más simple es imaginar una red consistente de dos variables binarias X y Y , con una arista $X \rightarrow Y$:

- El objetivo aplicando MLE es maximizar la función de verosimilitud o su logaritmo (log-likelihood).
- En este caso, la red en mención es parametrizada por un vector de parámetros θ , el cual define el conjunto de parámetros para todas las distribuciones de probabilidad condicional (CPDs) en dicha red.
- En este ejemplo, la parametrización podría consistir de los siguientes parámetros:
 - θ_{x^1} y θ_{x^0} especifican la probabilidad de los dos valores de X
 - $\theta_{y^1|x^1}$ y $\theta_{y^0|x^1}$ especifican la probabilidad de Y dado $X = x^1$
 - $\theta_{y^1|x^0}$ y $\theta_{y^0|x^0}$ especifican la probabilidad de Y dado $X = x^0$
 - Para abreviar usaremos $\theta_{Y|x^0}$ para referirnos al conjunto $\theta_{y^1|x^0}, \theta_{y^0|x^0}$ y $\theta_{Y|x^1}$ para referirnos a $\theta_{Y|x^0} \cup \theta_{Y|x^1}$
- En este ejemplo, cada instancia de entrenamiento es una tupla $\langle x[m], y[m] \rangle$ que describe una asignación particular a X y Y .
- Así, la función de verosimilitud se define así:

$$\ell(\theta : D) = \prod_{m=1}^M P(x[m], y[m] : \theta)$$

- El modelo de red especifica que $P(X, Y : \theta)$ tiene forma de producto, Así, podemos escribir

$$\ell(\theta : D) = \prod_{m=1}^M P(x[m] : \theta) P(y[m]|x[m] : \theta)$$

- Cambiando el orden de la multiplicación, podemos escribir equivalentemente el termino como se muestra a continuación, donde la función de verosimilitud sufre una descomposición en dos términos, uno por variable y cada término es una función de verosimilitud local que mide el grado de predicción de una variable dado sus padres:

$$\ell(\theta : D) = \left(\prod_{m=1}^M P(x[m] : \theta) \right) \left(\prod_{m=1}^M P(y[m]|x[m] : \theta) \right)$$

- Considerando los términos individuales de la ecuación, podemos descomponer el segundo término, así, la función de verosimilitud se descompone en un producto de términos, uno por cada grupo de parámetros en θ . Esta propiedad es la capacidad de descomponer la función de verosimilitud:

$$\prod_{m=1}^M P(y[m]|x[m] : \theta_{Y|X}) = \prod_{m=1}^M P(y[m]|x[m] = x^0 : \theta_{Y|x^0}) \prod_{m=1}^M P(y[m]|x[m] = x^1 : \theta_{Y|x^1})$$

- De la anterior expresión, consideremos uno de los términos:

$$\prod_{m=1}^M P(y[m]|x[m] = x^0 : \theta_{Y|x^0})$$

- Cada uno de los términos individuales $P(y[m]|x[m] = x^0 : \theta_{Y|x^0})$ puede tomar uno de dos valores, dependiendo del valor de $y[m]$.

- Si $[m] = y^1$, el termino individual toma $\theta_{y^1|x^0}$
- Si $[m] = y^0$, el termino individual toma $\theta_{y^0|x^0}$
- ¿Cuántos casos de cada tipo podemos tener?
- Fijemos primero aquellos casos donde $x[m] = x^0$. Estos a su vez se particionan en dos categorías:
 - Obtenemos $\theta_{y^1|x^0}$ en cuyos casos de datos donde $[m] = x^0$ and $y[m] = y^1$, usaremos $M[x^0, y^1]$ para denotar el número de casos.
 - Obtenemos $\theta_{y^0|x^0}$ en cuyos casos de datos donde $[m] = x^0$ and $y[m] = y^0$, usaremos $M[x^0, y^0]$ para denotar el número de casos.
- Así, el termino es igual a:

$$\prod_{m=1}^M P(y[m]|x[m] = x^0 : \theta_{Y|x^0}) = \theta_{y^1|x^0}^{M[x^0, y^1]} \theta_{y^0|x^0}^{M[x^0, y^0]}$$

- Maximizaremos $\theta_{Y|x^0}$ por medio de:

$$\theta_{y^1|x^0} = \frac{M[x^0, y^1]}{M[x^0, y^1] + M[x^0, y^0]} = \frac{M[x^0, y^1]}{M[x^0]}$$

similarmente para $\theta_{Y|x^1}$.

- En conclusión, podemos encontrar la máxima verosimilitud de los parámetros en esta distribución de probabilidad condicional (CPD), simplemente contando cuantas veces cada una de las posibles asignaciones de X and Y aparecen en los datos de entrenamiento.

Descomposición global de la verosimilitud Iniciemos examinando la función de verosimilitud de una red Bayesiana:

- Supongamos que queremos aprender los parámetros para una red Bayesiana con estructura G , y parámetros θ .
- Esto significa que acordamos el tipo de CPDs que vamos a aprender.
- Sea también, un conjunto dado D de muestras.
- Escribiendo la función de verosimilitud y repitiendo los pasos realizados en el ejemplo anterior, obtenemos:

$$\begin{aligned} \ell(\theta : D) &= \prod_m P(D[m] : \theta) \\ &= \prod_m \prod_i P(x_i[m] | pa_{x_i}[m] : \theta) \\ &= \prod_i \left[\prod_m P(x_i[m] | pa_{x_i}[m] : \theta) \right] \end{aligned}$$

- Observemos que cada uno de los términos entre corchetes se refiere a la verosimilitud condicional de una variable dado sus padres en la red.

Usaremos $\theta_{X_i|Pa_{X_i}}$ para denotar el subconjunto de parámetros que determinan $P(X_i | Pa_{X_i})$ en nuestro modelo. Entonces podemos escribir

$$\ell(\theta : D) = \prod_i \ell_i(\theta_{X_i|Pa_{X_i}} : D)$$

Donde la función de verosimilitud local para X_i es:

$$\ell_i(\theta_{X_i|Pa_{X_i}} : D) = \prod_m P(x_i[m] | pa_{x_i}[m] : \theta_{X_i|Pa_{X_i}}) \quad (2.3)$$

Esta forma es particularmente útil cuando los conjuntos de parámetros $\theta_{X_i|Pa_{X_i}}$ son disjuntos. Es decir, cada CPD es parametrizada por un conjunto separado de parámetros que no se solapa.

Por lo tanto, este análisis muestra que la verosimilitud (likelihood) se descompone como un producto de términos independientes, uno para cada CPD en la red. Esta propiedad es llamada descomposición global de la función de verosimilitud.

2.5.5. Aprendizaje de la estructura de una red Bayesiana

En esta sección, consideramos la tarea de aprendizaje donde no conocemos la estructura de la red Bayesiana y que nuestros datos son completamente observados.

Definición del problema

Supongamos que los datos D son generados IID de una distribución subyacente $P^*(X)$. También, asumimos que P^* es inducido por alguna red Bayesiana G^* sobre X .

Resumen de métodos

Existen tres enfoques para aprender sin una estructura pre-especificada:

- Un enfoque utiliza aprendizaje de estructuras basado en restricciones (constraint-based). Este enfoque ve una red Bayesiana como una representación de independencias. Se realizan pruebas de dependencia e independencia condicional a los datos, y entonces se encuentra una red que explica dichas dependencias e independencias. Este enfoque no hace parte del alcance de este trabajo. Se puede encontrar información relacionada en el numeral 18.2 de Daphne Koller y Nir Friedman 2009, así mismo, algunas aplicaciones en Emmanuel Prestat y col. 2013 .
- El segundo enfoque es el aprendizaje basado en puntaje (score-based). Los métodos basados en puntaje ven una red Bayesiana como una especificación de un modelo estadístico y entonces direcciona el aprendizaje como un problema de selección del modelo. Todo en este enfoque opera con el mismo principio:
 - Definir un espacio hipótesis de potenciales modelos.
 - Definir una función de puntuación (scoring), que mide que tan bien el modelo encaja con los datos.
 - Nuestra tarea computacional es entonces encontrar la más alta puntuación de estructuras de red.
- Por último, el tercer enfoque no intenta aprender una sola estructura; por el contrario, este genera un conjunto de posibles estructuras. Estos métodos de promedio de modelo Bayesiano (Bayesian model-averaging), extienden el razonamiento Bayesiano e intentan promediar la predicción de todas las posibles estructuras.

Puntajes de estructuras (scores)

Puntajes por verosimilitud Una elección natural para la función de puntaje es la función de verosimilitud, la cual revisamos en secciones anteriores para la estimación de parámetros. Esta función mide la probabilidad de los datos dado un modelo. Así, esta función intuitivamente encuentra un modelo podría hacer los datos tan probables como sea posible.

Asumimos que queremos maximizar la verosimilitud del modelo. En este caso, nuestro modelo es una pareja (G, θ_G) . El objetivo es encontrar un grafo G y los parámetros θ_G que maximicen la verosimilitud. Usaremos los parámetros $\hat{\theta}_G$ con la máxima verosimilitud para este grafo.

Para encontrar la pareja (G, θ_G) que maximiza la verosimilitud, debemos encontrar la estructura del grafo G que alcanza la más alta verosimilitud cuando usamos los parámetros MLE para G .

Definimos

$$SCORE_L(G : D) = \ell(\hat{\theta}_G : D)$$

donde $\ell(\hat{\theta}_G : D)$ es la función logaritmo de la verosimilitud (esto es usual, ya que se facilitan los cálculos con el logaritmo de la verosimilitud), y θ_G son los parámetros que maximizan la verosimilitud para G .

Puntajes Bayesianos Como una alternativa la función de puntuación con puntaje Bayesiano está basada en una perspectiva Bayesiana. Siempre que se tiene incertidumbre sobre algo, deberíamos poner una distribución ahí.

En este caso se tiene incertidumbre sobre la estructura y sus parámetros. Por lo tanto, definimos una distribución a priori $P(G)$, la cual pone una probabilidad a priori sobre las diferentes estructuras del grafo, y un parámetro a priori $P(\theta_G|G)$, que pone una probabilidad a las diferentes elecciones de parámetros una vez el grafo es dado. Aplicando la regla de Bayes, tenemos

$$P(G|D) = \frac{P(D|G)P(G)}{P(D)}$$

donde, como es usual, el denominador es simplemente un factor de normalización que no ayuda a distinguir entre diferentes estructuras.

En ese orden de ideas, definimos el puntaje Bayesiano como:

$$SCORE_B(G : D) = \log P(D|G) + \log P(G)$$

La habilidad de incluir una distribución a priori sobre las estructuras, nos da una manera de preferir algunas estructuras sobre otras. Observemos que aunque este término parece describir nuestras preferencias por ciertas estructuras, de hecho, este juega un papel relativamente menor.

Búsqueda de estructuras

Ahora miraremos como encontrar una estructura con un puntaje alto. Ya tenemos un problema de optimización bien definido con las siguientes entradas:

- Conjunto de entrenamiento D
- Función de puntuación (incluyendo distribuciones a priori, si se requieren)
- Un conjunto G de posibles estructuras de red (incorporando cualquier conocimiento a priori).

La salida deseada es una estructura de red (tomada del conjunto de estructuras posibles) que maximiza el puntaje.

El espacio de búsqueda Podemos pensar en el espacio de búsqueda como un grafo sobre las posibles soluciones candidatas, conectadas por posibles operadores, que el procedimiento de búsqueda puede ejecutar para moverse entre diferentes soluciones. En el contexto más simple, consideramos el espacio de búsqueda donde cada estado denota una estructura de red completa G sobre X .

Definimos la conectividad del espacio de búsqueda en términos de los siguientes operadores:

- Adicionar arista
- Eliminar arista
- Invertir arista

Es decir, los estados adyacentes a un estado G son aquellos donde cambiamos una arista, ya sea porque adicionamos una, eliminamos una o invertimos la dirección de la arista. Observamos que sólo consideraremos aristas que obtengan redes válidas. O sea, redes acíclicas que satisfagan las restricciones que nosotros hayamos incluido (por ejemplo, restricciones del grado de entrada Daphne Koller y Nir Friedman 2009).

Esta definición del espacio de búsqueda es natural y tiene las siguientes propiedades favorables:

- El diámetro del espacio de búsqueda es en el peor caso n^2 . Es decir, que existe una ruta relativamente corta entre cualesquier dos redes que elijamos.
- El puntaje de una red G es la suma de puntajes locales. Las operaciones ya resueltas cambian solo en un término de puntaje local.

Supongamos que la red original es la que muestra en la Figura 2.15a:

- A es altamente informativa sobre C y B.
- Empezando con una red vacía $G_{\emptyset}$ y adicionando aristas vorazmente, podríamos adicionar las aristas $A \rightarrow B$ y $A \rightarrow C$.
- En algunos conjuntos de datos, podríamos adicionar la arista $A \rightarrow D$; ya que B y C son los padres de D, también A es informativa sobre D.
- En este punto finalizamos con la red de la Figura 2.15b.
- Continuando la búsqueda, consideramos diferentes operadores, adicionar la arista $B \rightarrow D$, ya que B es un padre de D en la red original, este mejorara la predicción de D cuando se combine con A. Así, la calificación de A and B juntos como padres de D puede ser más grande que la calificación de solo A. Análogamente, adicionaremos también la arista $C \rightarrow D$, y alcanzaremos la estructura que se muestra en la Figura 2.15c.
- Esperamos que elegir B, C como padres de D tendrá una calificación mejor que elegir A, B, C.
- Después, eliminaremos la arista $A \rightarrow D$ para obtener la estructura original.

Para ver la utilidad del operador de invertir una arista, consideremos el siguiente ejemplo simple:

- Suponga la red real que genera los datos tiene la v-estructura mostrada en la Figura 2.16a.
- Suponga que la independencia entre A y C es más fuerte que entre B y C.
- La arista $A \rightarrow C$ tiene exactamente la misma calificación que la red con la arista $C \rightarrow A$. En este punto no podríamos distinguir entre las dos opciones. Concibamos que tenemos la estructura que se muestra en la Figura 2.16b.

Figura 2.15: Ejemplo de una búsqueda que requiere eliminación de arista. Tomado de Daphne Koller y Nir Friedman 2009





Figura 2.16: Ejemplo de búsqueda que requiere invertir. Tomado de Daphne Koller y Nir Friedman 2009



- El procedimiento voraz procede, y este decide adicionar la arista $B \rightarrow C$, dando como resultado la red de la Figura 2.16c.
- Ahora estamos listos para invertir la arista $C \rightarrow A$ y mejorar la puntuación. Sin embargo, si no tenemos la operación invertir, un procedimiento voraz podría no eliminar la arista $C \rightarrow A$, ya que disminuye el puntaje.
- Podríamos terminar con la red que se muestra en la Figura 2.16d. Así, B y C juntos hacen mejor predicción de A que sólo C.

El procedimiento de búsqueda Una vez definimos el espacio de búsqueda, necesitamos diseñar un procedimiento que lo explore y busque la estructura con mayor calificación. La gran mayoría de métodos de búsqueda usados en aprendizaje de estructuras son procedimientos de búsqueda local como por ejemplo el algoritmo “greedy hill climbing” Daphne Koller y Nir Friedman 2009. En el contexto del aprendizaje de estructuras:

- Tomamos una estructura de red inicial G como punto de partida; esta red puede ser vacía $G_\emptyset$, una elección aleatoria, un árbol, o una red obtenida de algún conocimiento previo.
- Calculamos el puntaje de la estructura de red inicial.
- Consideramos todos los vecinos de G en el espacio (todas las redes validas obtenidas aplicando un operador individual a G) y calculamos el puntaje de cada uno de ellos.
- Aplicamos el cambio que dirija al mejor incremento del puntaje.
- Continuamos el proceso hasta que ninguna modificación mejore el puntaje.

Existen dos preguntas que podemos hacer:

- Primera, cual es el costo de este proceso.
- Segundo, que podemos decir acerca de la red obtenida del proceso.

Descomposición del puntaje (score) y Búsqueda El factor dominante en el costo del algoritmo de búsqueda es la evaluación de redes vecinas en cada iteración del proceso. Para evaluar cada una de estas necesitamos calificarlas. Este proceso requiere que hagamos un recorrido de todos los diferentes casos de datos, para calcular las estadísticas suficientes para la nueva estructura. Esta computación puede ser bastante costosa en cualquier algoritmo de aprendizaje de estructuras.

El punto clave es donde la propiedad de descomposición del puntaje (score composability property) llega a ser útil:

- Como vimos en la sección 1.5.4, el puntaje que analizamos se descompone en una suma de términos, uno para cada variable X_i .
- Cada una de estas familias de puntajes (family scores) es calculada relativamente, solo para las variables de la familia de X_i .
- Un cambio local (adición, eliminación ó invertir una arista) mantiene casi todas las familias de la red sin cambios.

Para las familias cuya composición no cambió, el componente asociado del puntaje tampoco cambia.

Asumamos que la actual red candidata es G :

- Para cada operador, calculamos la mejora en el puntaje que podría resultar de este cambio.
- Definimos el Delta del puntaje para hacer el cambio del puntaje asociado con aplicar el operador o al grafo G .

$$\delta(G : o) = SCORE(o(G) : D) - SCORE(G : D) \quad (2.4)$$

Usando la descomposición del puntaje, podemos calcular esta cantidad de manera relativamente eficiente.

2.5.6. Estado del arte

Aprender automáticamente la estructura de un grafo de una red Bayesiana (BN) es un problema abierto en reconocimiento de patrones, que ha atraído la atención en los últimos años. Ampliamente hablando, existen dos principales enfoques para aprender estructuras de redes Bayesianas (ver Neapolitan 2009a y Darwiche 2009): el enfoque basado en restricciones y el enfoque basado en puntaje.

Enfoque basado en restricciones

Los enfoques descritos en Spirtes, Glymour y Scheines 2012; Wermuth y Lauritzen 1983; Campos y Huete 2000 pertenecen a esta categoría. Las redes construidas por este enfoque son usualmente asintóticamente correctas, pero como ha sido señalado por G. Cooper y Herskovits 1992 las pruebas de independencia condicional con conjuntos (condition-sets) grandes puede ser poco fiable a menos que el volumen de datos sea enorme. Debido a las limitaciones en los recursos de investigación, en los experimentos de micro-arreglos el tamaño de las muestras de datos de expresión de genes es usualmente pequeño (normalmente

el volumen de los datos de muestras por paciente, van de 3 a 20), por lo tanto, el enfoque incluido en esta categoría (conditional Independence tests), podría ser inadecuado para datos de expresión de genes.

Enfoque basado en puntaje

Las funciones (scoring) pueden ser formuladas basándose en diferentes principios, tales como entropía Herskovits y G. F. Cooper 2013, la mínima longitud de descripción Lam y Bacchus 1994 y puntajes Bayesianos (Bayesian scores) Heckerman, Geiger y D. M. Chickering 1995; G. Cooper y Herskovits 1992. Los procedimientos de optimización son usualmente heurísticas, tales como la búsqueda tabú Bouckaert 1995 y computación evolutiva Campos y Huete 2000; Neiland y K. Korb 1999. Desafortunadamente la tarea de encontrar una estructura de red que optimice la función scoring es un problema de optimización combinatoria, y es conocido como un problema de complejidad computacional NP-hard D. Chickering 1996. Por lo tanto, el proceso de optimización frecuentemente se detiene en una estructura óptima local. Por otra parte, para muchos conjuntos de datos de expresión, el tamaño de la muestra es típicamente pequeño con respecto al tamaño de la red. En este caso, la mayoría de las veces existe un número grande de redes con alto scoring, sin embargo, sus estructuras son bastante diferentes, así la inferencia de características de la red como presencia o ausencia de una arista particular, basado en una sola red es de alto riesgo Faming 2010.

Modelo promedio Bayesiano

Una lista no exhaustiva de los trabajos en esta categoría incluyen Madigan y Raftery 1994; Madigan, York y Allard 1995; Giudici y Green 1999; Daphne Koller y Nir Friedman 2009, donde la simulación es realizada usando el algoritmo de Metrópolis-Hasting (MH) Hastings 1970, y las características de las redes son inferidas promediando sobre un número grande de redes simuladas desde la distribución posterior. El promedio sobre diferentes redes puede reducir significativamente el riesgo sufrido por el procedimiento de inferencia basado en un solo modelo. Aunque el enfoque aparece atractivo, trabaja bien solo para los problemas con un número muy pequeño de variables (nodos). Esto es debido al comportamiento de la función de energía de la red bayesiana; la cual presenta altibajos con una cantidad de mínimos locales separados por altas barreras, especialmente cuando el tamaño de la red es grande (aquí la función de energía se refiere a la función de distribución log-posterior negativa de la red bayesiana). Como sabemos por muchos investigadores, el algoritmo MH es propenso a quedar atrapado en mínimos locales indefinidamente en un sistema con altibajos. Para aliviar esta dificultad Nir Friedman y Daphne Koller 2003a introducen un algoritmo en dos pasos:

1. Utilizar el algoritmo MH para muestrear un orden temporal de los nodos, y muestrear una estructura de red compatible con el orden dado (Para cualquier red bayesiana existe un orden temporal de los nodos, tal que, para cualquier par de nodos X , Y , si existe una arista de X a Y , entonces X debe preceder a Y en dicho orden).
2. El algoritmo mejora el mezclado sobre el espacio de estructuras de red, sin embargo, estas estructuras muestreadas no siguen la distribución posterior correcta, porque el orden temporal no induce una partición del espacio de estructuras de red. Es decir, una red puede ser compatible con más de un orden temporal.

Faming 2010 basado en Liang y J. Zhang 2009a describe como aprender redes Bayesianas usando el algoritmo de aproximación estocástica de Monte Carlo (SAMC) Liang, C. Liu

y Carroll 2007. Una notable característica del algoritmo SAMC es que posee un mecanismo de auto-ajuste, así no queda atrapado en un mínimo local. SAMC pertenece a la clase de algoritmos de ponderación dinámica (dynamic weighting algorithms) Wong y Liang 1997; J. S. Liu, Liang y Wong 2001, y las muestras generadas por este algoritmo pueden usarse para evaluar características de la red por medio del estimador de ponderación dinámica. Los estimadores de ponderación dinámica pueden tener mucho más bajo riesgo que el estimador basado en un solo modelo Faming 2010 .

2.5.7. Markov Chain Monte Carlo (MCMC)

MCMC corresponde a un área de la estadística, la cual suministra una respuesta al problema de simulación de distribuciones de probabilidad de alta dimensionalidad asociadas a modelos complejos.

Introducción

Una cadena de Markov (Markov chains) está definida en términos de los estados de una red o grafo, sobre los cuales un proceso estocástico (o Monte Carlo, es decir, no determinístico) realiza una caminata aleatoria. En muchos casos, este proceso tiende a un equilibrio y los estados siguen una distribución probabilística.

Las técnicas MCMC permiten la simulación de una distribución, embebiéndola en una distribución de una cadena de Markov, y entonces, realiza la simulación de dicha cadena hasta que tienda al equilibrio.

Un enfoque utilizado en el aprendizaje Bayesiano es la simulación MCMC, donde un conjunto de redes Bayesianas viables son exploradas por una caminata aleatoria que converge a una red optima, que se ajusta a los datos con respecto al puntaje (scoring) de una función de verosimilitud (likelihood) u otra función de evaluación como el puntaje (score) Bayesiano Nir Friedman y Daphne Koller 2003a.

Algoritmos


Metropolis Hasting es uno de los algoritmos MCMC el cual está basado en una cadena de Markov, cuya dependencia de los estados anteriores está dividida en dos partes: una distribución propuesta y una aceptación de la propuesta. La distribución propuesta sugiere un paso siguiente arbitrario en la trayectoria de la cadena. En la aceptación de la propuesta se mantiene la dirección apropiada en la caminata aleatoria, rechazando los movimientos no deseados de la cadena Hastings 1970.

Otro algoritmo en MCMC es el llamado “Gibbs sampling”, el cual está basado en una cadena de Markov cuya dependencia de los estados anteriores es gobernada por las distribuciones condicionales (CPD) que surgen a partir del modelo Murphy 2012.

2.6. Relaciones entre las redes de co-expresión (CGN) y las redes Bayesianas de interacción de genes (BIN)

La dirección y el tipo de relación de co-expresión no están determinadas en una red de co-expresión de genes. En este paso el tipo de redes que nos interesa construir son las redes Bayesianas de interacción de genes (BIN), en las cuales una arista dirigida conecta dos genes, representando un proceso bioquímico tal como una reacción, transformación, interacción, activación o inhibición.

Figura 2.17: Red de co-expresión de genes (CGN) vs. red bayesiana de interacción de genes (BIN)



Comparada con una GCN, una BIN intenta inferir las relaciones de causalidad entre genes, y las aristas representan no solo una correlación o relación de dependencia entre ellos. Los módulos o sub-grafos altamente conectados en las redes de co-expresión de genes (GCN) corresponden a agrupamientos (módulos / cluster) de genes que tienen una función similar o se involucran en un proceso biológico común, el cual causa muchas interacciones entre ellos mismos Roy, Bhattacharyya y Kalita 2014.

En la Figura 2.17, la dirección de las aristas es obviada en la co-expresión. Mientras los tres genes X, Y y Z están co-expresados, no se determina si X activa Y y Y activa Z o Y activa X y Z u otro gen activa a los tres.

Los genes con perfiles de expresión similar normalmente tienen funciones relacionadas. En lugar de analizar pares de genes, se podrían estudiar conjuntos de genes co-expresados que se sabe que interactúan como un módulo funcional envuelto en un proceso biológico particular M. M. Babu y col. 2004. Integrando esta información con la conservación evolutiva de las proteínas en más de dos organismos, provee conocimiento de la significancia de los módulos funcionales que han sido conservados en la evolución. Neapolitan 2009a muestra como un módulo de redes (module networks) puede ser empleado para analizar datos de expresión de genes, y también los resultados de experimentos de esta utilización.

Los datos de expresión de genes son usados para inferir relaciones regulatorias. Este enfoque es conocido como ingeniería inversa de redes regulatorias. A partir de datos de expresión se pueden hacer predicciones de los reguladores transcripcionales para un gen o conjunto de genes dados. En Segal y col. 2003, desarrollaron un modelo probabilístico para identificar módulos de genes co-regulados, sus reguladores transcripcionales y condiciones que influyen la regulación, permitiendo la generación hipótesis validables experimentalmente.

En Gardner y col. 2003 describieron un método llamado NIR (Network Identification by multiple Regression) para inferir relaciones regulatorias, el cual usa ecuaciones diferenciales no-lineales para modelar redes regulatorias. En este método, se infiere un modelo de conexiones entre genes en una red a partir de mediciones de la dinámica del sistema (por ejemplo, respuesta de genes y proteínas a perturbaciones).

2.7. Marcos de trabajo de redes Bayesianas

Existen buenos trabajos relacionados con redes Bayesianas y análisis de datos de expresión, por ejemplo, E. Prestat y col. 2013 presenta un algoritmo basado en restricciones para

el aprendizaje de la red Bayesiana, Nir Friedman y Daphne Koller 2003b se enfoca más en la utilización de los algoritmos de simulación de *Markov Chain Monte Carlo (MCMC)* para aprender la estructura de una red Bayesiana, Ellis y Wong 2008; Liang y J. Zhang 2009b hacen énfasis en el modelo estadístico empleado para evaluar el *score* de las estructuras en el *espacio de búsqueda*, mientras que Pearl 1988; Neapolitan 2009b son una buena referencia en la literatura con las bases teóricas de las redes Bayesianas y los fundamentos de su aprendizaje con aplicaciones en expresión génica. Desafortunadamente estos autores no mencionaron, ni documentaron la arquitectura computacional de la implementación que usaron para obtener sus resultados.

Por el contrario, en Arneson y col. 2016 se desarrolló *Mergeomics* una arquitectura computacional de estilo arquitectónico *pipeline* que integra datos multidimensionales de asociación de enfermedades con genómica funcional y redes moleculares para obtener rutas metabólicas, redes de genes y reguladores centrales críticos para el desarrollo de enfermedades. Por otra parte, en Wang y col. 2015 se desarrolló un nuevo método computacional Bayesiano con una búsqueda *MCMC* e implementado en el *Bayesian High-order Interaction Toolkit (BHIT)* para detectar interacciones epistáticas entre *Single Nucleotide Polymorphisms (SNPs)*. También en Vinh y col. 2011, se presentó el *GlobalMIT*, un *toolbox* para aprender la estructura óptima global de una red Bayesiana dinámica a partir de datos de expresión génica. Este método usa una métrica de *scoring* basado en teoría de la información llamada *Mutual Information Test (MIT)*, y con su utilización la tarea de aprendizaje es lograda en tiempo polinomial. Estos trabajos tienen en común que sus autores mencionaron y documentaron características arquitectónicas de las herramientas computacionales utilizadas en sus investigaciones y que están relacionados con este trabajo en temas como la simulación *MCMC* y las redes Bayesianas para detectar interacciones génicas a partir de datos de expresión o transcriptomas.

A diferencia de los trabajos relacionados que mencionamos en este marco de trabajo propuesto se integran además elementos importantes como el análisis de redes complejas a través de la construcción de redes de co-expresión y detección de clusters, que habilitan un aprendizaje de redes Bayesianas un poco más enfocado en grupos de genes que comparten alguna función génica ya que se encuentran co-expresados, y adicionalmente se incluyen filtros post-óptimos como estrategias para mitigar el sobre-entrenamiento de las redes Bayesianas.

3 Desarrollo del marco de trabajo

Este capítulo aborda el como se va a elaborar el marco de trabajo propuesto y como se puede adoptar para su uso. Consta de tres partes: la primera describe los pasos metodológicos que fueron seguidos en el desarrollo del proyecto, en la segunda parte se presenta la implementación del marco de trabajo propuesto, donde se detalla primero la arquitectura general y sus características externamente visibles y después la especificación funcional de la implementación. En la tercera parte se presenta un flujo de trabajo para el uso del marco Bayesiano.

3.1. Metodología general

Cuatro pasos metodológicos fueron seguidos en el desarrollo del proyecto, el marco metodológico comprende:


- La construcción y visualización de redes de co-expresión de genes (dando cumplimiento al objetivo 1 del proyecto).
- La construcción de la arquitectura óptima de una red Bayesiana y sus parámetros a partir de los datos de expresión de un cluster de genes (dando cumplimiento al objetivo 2).
- La implementación de herramientas para el análisis de redes complejas y Bayesianas de expresión de genes y sus relaciones (para dar cumplimiento al tercer objetivo)
- La validación de este marco de trabajo en un caso de estudio con varios escenarios para verificar la calidad de los resultados obtenidos en la experimentación (cumpliendo así el cuarto objetivo).

En la figura 3.1 se muestra el diagrama de flujo de los pasos metodológicos y se detallan algunas actividades necesarias en cada paso:

1. Parametrizar la construcción de redes de co-expresión de genes.
2. Realizar análisis de redes complejas para detectar clusters y filtrar los resultados con base en anotaciones de ontologías del gen (del inglés Gen Ontology o GO), así, se facilita el análisis de las redes obtenidas y las interpretaciones por parte de los expertos en el campo.
3. Construir la arquitectura óptima de una red Bayesiana y sus parámetros, a partir de los datos de expresión de un cluster de genes dado. Este paso incluye actividades como discretizar los datos de expresión génica, ejecutar las simulaciones MCMC y visualizar la estructura de las redes obtenidas.
4. Aplicar el marco de trabajo construido a un caso de estudio que permita los análisis e interpretaciones de genes de interés biológico a partir de datos de expresión génica (obtenidos de experimentos con micro-arreglos de DNA de transcriptomas).

En el resto del capítulo, se detalla cada paso del marco metodológico del proyecto.

Figura 3.1: Diagrama de flujo de los pasos metodológicos.



3.1.1. Construcción y visualización de redes de co-expresión de genes

Se adoptó un método general para construir y visualizar redes de co-expresión génica, a partir de los datos de expresión de genes generados por micro-arreglos, y después, se aplicó este método a datos de expresión de E.coli (para mayor detalle de este proceso ver el capítulo 4 y la sección 4.2).

3.1.2. Construcción de la arquitectura óptima de una red Bayesiana y sus parámetros, a partir de los datos de expresión de genes

Posteriormente, se caracterizará un método general de aprendizaje de redes Bayesianas y sus parámetros a partir de datos de expresión de genes (ver la sección 5.2). Este método se basó en el enfoque de simulación de Markov Chain Monte Carlo (MCMC), el cual define una cadena de Markov para realizar una caminata aleatoria en el espacio de posibles estructuras de la red Bayesiana. Después, se genera un conjunto de estructuras viables probabilísticamente (es decir, que mejor se ajustaron a los datos según una función de verosimilitud o una distribución posterior) para la red (para más detalle ver el capítulo 5). Finalmente, se filtran las redes Bayesianas con un score en el rango del nivel óptimo para mitigar el sobre-entrenamiento (overfitting, es decir, grafos con muchas aristas o estructuras muy complejas) inherente al proceso de aprendizaje (ver en el capítulo 5, en la sección de sobre-entrenamiento 5.5 y las sub-secciones de red Bayesiana minimal y reducida 5.6).

3.1.3. Implementación de las herramientas para el análisis de redes complejas y Bayesianas de expresión de genes y sus relaciones

En este paso metodológico por medio de análisis de redes complejas se detectan clusters a partir de la red de co-expresión (CGN) obtenida en el primer paso. Esto se logra

caracterizado la red topológicamente y midiendo algunas propiedades (como el coeficiente de clustering entre otras) que indican la relevancia biológica de los grupos de genes co-expresados y cruzando esta información con bases de datos de anotaciones de ontologías de los genes (GO del inglés gene ontology, ver Gene Ontology 2015b).

3.1.4. Caso de estudio: Análisis de datos de expresión de genes de micro-arreglos de DNA de transcriptomas

En el último paso, se somete el marco de trabajo construido a experimentación y análisis de datos de expresión de genes de micro-arreglos a través de un caso de estudio. Los pasos a seguir se describen a continuación.

Selección del problema

Se seleccionó para la experimentación del marco de trabajo Bayesiano la exploración de transcriptomas de *Escherichia coli*, ya que es un organismo que ha sido objeto de estudio y se encuentra documentado. Además, por ser un organismo bacteriano cuenta con un metabolismo más acelerado que otros organismos como humanos, chimpancés o ratas, y esto permite que en los experimentos de micro-arreglos para medir la expresión de sus genes, se haya capturado de manera más evidente la interacción entre transcriptomas en comparación de otros organismo con un metabolismo más lento. Esta última característica nos inclinó más hacia este estudio.

Selección de los datos

Se realizó el análisis de un conjunto de datos de expresión de genes de acuerdo a la problemática de aplicación escogida (ver capítulo 4, sección 4.2 de materiales y métodos). Entre otros bancos de datos se encuentran los descritos en la sección 4.2.1 de preparación de los datos.

Aplicación del marco de trabajo Bayesiano

Se aplicó el marco de trabajo de redes Bayesianas al conjunto de datos seleccionado, ver el capítulo 6.


Verificación de los resultados

Por último se realizó un análisis y discusión de los resultados obtenidos. Con la construcción de las redes de co-expresión (CGN) y las redes Bayesianas de interacción de genes (BIN), se procede con la selección de genes de interés biológico haciendo la interpretación de los módulos o agrupamientos (clusters) de genes en dichas redes. La tarea es identificar genes relevantes dentro de procesos biológicos de interés mediante la caracterización de los módulos a nivel funcional y de su forma (topología).

3.2. Implementación del marco de trabajo

Siguiendo los pasos metodológicos, se estructuró una arquitectura general para la solución de este marco de trabajo de redes Bayesianas, y se destacan en la solución los siguientes componentes:

Figura 3.2: Draft de arquitectura marco de trabajo de redes Bayesianas.



- El constructor de redes de co-expresión génica a partir de datos de micro-arreglos, adopta el método WGCNA (del inglés Weighted Gene Coexpression Networks Analysis) de Zhang y Horvath B. Zhang y S. Horvath 2005b.
- El detector de clusters emplea análisis de redes complejas y anotaciones GO Gene Ontology 2015b para detectar clusters presentes en la red de co-expresión generada por el componente anterior y usa el paquete R/Bioconductor llamado WGCNA de Langfelder, Zhang y Horvath Langfelder y Steve Horvath 2008.
- El constructor de redes Bayesianas dado un cluster co-expresado de genes obtiene una red Bayesiana minimal que se basa en las redes Bayesianas que se encuentran en un nivel óptimo, por medio del algoritmo de simulación MCMC (desarrollado en este proyecto).
- El componente identificador de genes de interés biológico (del inglés signature genes) con ayuda de las anotaciones GO y juicio de expertos (biólogos) obtiene una red Bayesiana reducida a partir de la red Bayesiana que pueda asistir al biólogo en las interpretaciones y hallazgos de interés para su estudio en particular.


En la figura 3.2 podemos observar estos componentes y sus interacciones, y en el resto de la sección entraremos en detalle.

3.2.1. Arquitectura general

El marco de trabajo propuesto se compone de elementos de diferente naturaleza: estadística, biológica e informática. El objetivo de esta sección consiste en especificar una arquitectura general del marco que capture sus elementos, las relaciones entre ellos y las propiedades externamente visibles Fielding y Taylor 2000, de tal manera que ésta pueda ser entendida por distintos interesados como estadísticos, biólogos e informáticos.

El diagrama de la arquitectura general en la figura 3.3, muestra los diferentes elementos, componentes, conectores y datos.

Figura 3.3: Diagrama de la arquitectura general.



Los elementos arquitectónicos incluyen datos, procesos y conexiones. El marco incluye tres elementos arquitectónicos fundamentales: las redes de co-expresión génica, las redes Bayesianas minimales de interacción de genes y redes reducidas de interacción génica.

Los componentes arquitectónicos proporcionan una transformación de los datos por medio de sus interfaces, aquí se incluyen el componente de análisis de redes de co-expresión génica, el componente de simulación MCMC y el componente de identificación de genes de interés biológico.

Los conectores arquitectónicos son los encargados de la coordinación, comunicación y cooperación entre componentes. Los principales conectores del marco Bayesiano son las interfaces de base de datos del componente de simulación MCMC, la interfaz de archivos de datos de expresión de micro-arreglos, la interfaz de visualización de redes génicas y la interfaz de base de datos de ontologías del gen.

Los datos arquitectónicos son los elementos transferidos entre dos componentes por medio de un conector. En el marco Bayesiano se trabajó con dos elementos de este tipo: los datos de expresión de genes de micro-arreglos y los datos de anotaciones de ontologías del gen.

3.2.2. Especificación funcional

En esta sección utilizamos el concepto de las vistas arquitectónicas para detallar la especificación del marco de trabajo. Las vistas son perspectivas o puntos de vista arquitecturales que capturan diferentes preocupaciones de los diferentes interesados en el sistema Rozanski y Woods 2005, dichas preocupaciones pueden ser la perspectiva lógica del sistema, el modelo de base de datos, la vista de despliegue o de casos de uso. Específicamente, seleccionamos la vista de casos de uso para caracterizar de forma general la capacidad de esta solución.

Así, en la figura 3.4 presentamos las capacidades para identificar clusters en redes de co-expresión génica por medio del análisis de redes complejas de la adopción del método WGCNA (ver el capítulo 4, para mayor detalle).

Por otra parte, la figura 3.5 muestra como se extiende el caso de uso para identificar genes de interés biológico por medio del aprendizaje de redes Bayesianas y algunos filtros post-óptimos para mitigar el sobre-entrenamiento (para mayor detalle ver el capítulo 5).

3.3. Flujo de trabajo para el uso y adopción del marco Bayesiano

Para adoptar este marco de trabajo se propone el flujo de trabajo que se muestra en la figura 3.6 y se detallan a continuación:

1. **Seleccionar el conjunto de datos** de expresión de micro-arreglos, ver la figura 3.6. Paso a seguir se procede con (2)
2. **Construir la red de co-expresión**, esta actividad y la que sigue deberían ser realizadas por un profesional bioinformático.
3. **Detectar y seleccionar clusters de genes co-expresados**, donde los resultados son analizados por medio de técnicas bioinformáticas como el análisis de redes complejas, se revisan las redes obtenidas y propiedades de la red como el coeficiente de clustering.

Figura 3.4: Caso de uso "Identificar módulos"





Figura 3.5: Caso de uso "Identificar genes de interés biológico"

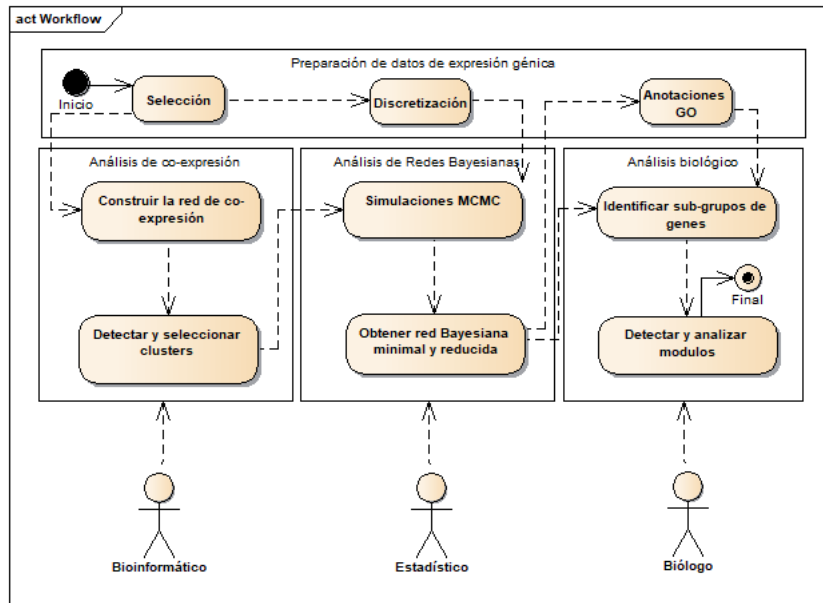


4. Continuando con este flujo de trabajo, cada vector de expresión génica debe ser sometido a un **proceso preliminar de discretización** por medio del método de cuantiles en donde se definen diferentes niveles de expresión (por ejemplo: alto, medio, bajo) o cuantiles, para mayor detalle consultar a Dey en su trabajo Dey, D.K. and Ghosh, S. and Mallick, B.K. 2010. Para cada gen del cluster donde se aplicará el marco de trabajo de redes Bayesianas, se cargan las muestras de los datos de expresión génica, previamente discretizadas.
5. Se ejecuta el proceso de aprendizaje de redes Bayesianas por medio de las **simulaciones MCMC**. A partir de los resultados de las simulaciones MCMC se revisan las redes obtenidas, el logaritmo de su función de distribución posterior y otras propiedades de la red como el valor máximo de grado de entrada (*máx. in-grade*) y el número de aristas de la red.
6. Luego de tomar los resultados de la actividad anterior, se filtran las redes encontradas con un procedimiento de transformación a una **red Bayesiana minimal** (ver el capítulo 5) mitigando el sobre-entrenamiento que podría darse en este tipo de aprendizaje y **reducimos** esta red Bayesiana minimal, mediante un proceso de poda de aristas menos frecuentes dentro del conjunto de redes en el nivel óptimo.
7. Se obtiene apoyo de conocimiento biológico (por ejemplo: la base de datos de interacción génica bacteriana en ABASY para Escherichia coli Ibarra-Arellano y col. 2016) consultando las **anotaciones GO**.
8. Se realiza una interpretación coherente de los resultados desde el punto de vista biológico, tratando de **identificar sub-grupos de genes** que den luces sobre la causalidad y coherencia con los procesos biológicos que se desean estudiar. Para estas últimas actividades se recomienda el apoyo o asistencia de un biólogo.
9. Con base en los sub-grupos identificados en el paso anterior **de detecta y valida** si estos obedecen a un **comportamiento modular**, es decir, como unidad funcional de un proceso biológico de interés.

3.4. Comentario final

La metodología aquí presentada, el marco Bayesiano resultante y el flujo de trabajo para su aplicación se validaron con éxito por la aplicación de los casos de estudio que se presenta en el capítulo 6.

Figura 3.6: Flujo de trabajo para la experimentación del marco con E.coli



4 Método para construir redes de co-expresión

4.1. Introducción

En este capítulo, revisaremos la definición de redes pero esta vez en un contexto biológico, así como las redes de co-expresión génica. Como ya mencionamos en la sección 2.3 una red o un grafo es un conjunto de puntos llamados *nodos* y enlazados a través de líneas llamadas *aristas*, las cuales representan algún tipo de relación. En el ámbito biológico es posible representar relaciones entre biomoléculas a través de estas redes, de manera que cada nodo represente un gen o una proteína y las aristas indican sus interacciones. Las redes han sido utilizadas en biología para representar rutas metabólicas, co-expresión génica, regulación génica e interacción de proteínas, entre otras aplicaciones, como mencionan Barabasi y Vibal en Barabási y Oltvai 2004; Vital-Lopez, M. y Dutta 2012.

Que es una red de co-expresion?

Las redes de co-expresión de Genes (GCN), se definen como un grafo no dirigido en el que cada nodo corresponde a un gen, más exactamente a su perfil de expresión, y las aristas que los conectan representan relaciones de co-expresión, entendiéndose esta relación como la expresión de dos o más genes de manera simultánea. Así, dos genes se conectan si sus perfiles de expresión están asociados entre las perturbaciones estudiadas.

Estas redes proveen información de relaciones de asociación, similitud de expresión y vecindad entre genes que eventualmente permiten inferir interacciones entre las proteínas que codifican. Generalmente estas redes se construyen a partir de datos de expresión provenientes de micro-arreglos de ADN y pueden ser de dos tipos según la conexión entre los nodos: (1) sin pesos (o no-ponderadas), en las que sus aristas denotan si hay una asociación entre un par de nodos, y (2) con pesos (o ponderadas), en las que se cuantifica el grado de asociación entre los nodos por medio de un atributo llamado peso, el cual corresponde comúnmente a un valor en el rango $[0, 1]$.

Una aplicación de las redes de co-expresión génica es la identificación de grupos de nodos latamente co-expresados llamados *módulos*. Estos módulos o *clusters* indican funciones génicas comunes .

Que es WGCNA?

Horvart y Zhang presentan en B. Zhang y S. Horvath 2005b, un método para la construcción de redes con pesos denominado Análisis de Redes Ponderadas de Co-expresión de Genes (WGCNA del inglés Weighted Gene Coexpression Network Analysis) en donde se usa el coeficiente de correlación de Pearson como medida de co-expresión entre los genes (nodos).

Como se construyen y visualizan?

Básicamente este método consiste en la creación de una matriz que codifica el grado o fuerza de conexión entre pares de nodos. De manera general el método WGCNA comprende los siguientes pasos (para mayor detalle ver la sección 4.2):

1. Preparación de los datos de expresión (ej: normalización).
2. Definición de una medida de similitud entre nodos (ej: coeficiente de correlación de Pearson).
3. Definición de una función de adyacencia entre nodos (ej: la función potencia).
4. Definición de los parámetros de adyacencia (ej: el exponente de la función de adyacencia).
5. Definición de una medida de disimilitud entre los nodos (ej: sobre-posición topológica TOM del inglés Topological Overlap Measure).
6. Identificación de los módulos (ej: el algoritmo de agrupamiento jerárquico llamado «poda dinámica de árbol», del inglés dynamic tree cut algorithm Langfelder, Bin Zhang y Steve Horvath 2007).

Los autores del método han desarrollado WGCNA (R / Bioconductor), un paquete de lenguaje R que cuenta con diferentes funciones para la construcción y análisis de las GCN Langfelder y Steve Horvath 2008. La visualización de estas redes se puede lograr con aplicaciones como Cytoscape (<http://www.cytoscape.org/>) presentada por Shannon en Shannon 2003, Gephi (<http://gephi.github.io/>), o gViz (<http://urbm-cluster.urbm.fundp.ac.be/webapps/gviz/>).

4.2. Materiales y métodos

A continuación, se detallan las fuentes de datos empleadas en la experimentación con *E.coli* y la caracterización del método WGCNA para la construcción y análisis de redes de co-expresión génica.

4.2.1. Preparación de los datos

Para construir la red de co-expresión génica de *Escherichia coli* (*E.coli*) fue utilizada la base de datos de expresión de genes denominada M^3D (del inglés Many Microbe Microarrays Database) Faith y col. 2008. Los conjuntos de datos contienen 524 arreglos medidos bajo 264 condiciones experimentales como confirma Allen en Allen y col. 2012. Estos datos fueron medidos usando micro-arreglos de ADN (GeneChip) de la compañía estadounidense Affymetrix diseñados para el organismo *E.coli* (con clasificación MG1655) midiendo la expresión de 4292 genes, por medio de sondas genéticas (o en inglés gene probes). Por último, se promediados los arreglos medidos bajo las mismas condiciones experimentales, estos experimentos reportan el efecto en la expresión génica de 380 perturbaciones diferentes, de las cuales 152 fueron repetidos al menos 3 veces. Los experimentos incluyen perturbaciones ambientales como niveles de PH, fase decrecimiento o propagación, presencia de antibióticos, temperatura, media de crecimiento o propagación y concentración de oxígeno, así como también, perturbaciones genéticas Treviño y col. 2012. Otras fuentes publicas de datos de expresión génica obtenidos a partir de micro-arreglos son: GEO Barrett y col. 2013, ArrayExpress Kolesnikov y col. 2015, Colombos Moretto y col. 2016.

4.2.2. Construcción de las redes de co-expresión génica

Para efectos de la construcción de la red en mención es posible calcular un coeficiente de correlación (como Pearson, Kendall o Spearman) entre cada par de vectores de expresión (ver la sección 2.2.3) de genes para obtener una matriz de correlación y seleccionar un método para determinar un umbral. Algunos métodos disponibles para esto podrían ser:

1. Elegir un umbral de corte (del inglés cutoff threshold) de correlación en donde si la entrada de la matriz tiene valores que excedan dicho umbral, entonces los genes correspondientes a dicha entrada se considerarán co-expresados.
2. La z-transformación de Fisher (del inglés Fisher's Z-transformation, la cual basado en el número de muestras calcula un puntaje llamado *z-score* para cada correlación) o una variación de este como la presentada por Weirauch en Weirauch 2011.

En este trabajo se adoptó el análisis de redes ponderadas de co-expresión génica (WGCNA del inglés Weighted Gene Co-expression Network Analysis) propuesto por Zhang y Horvath en B. Zhang y S. Horvath 2005b para pasar de un enfoque estadístico a uno sistémico que permite incluir conocimiento externo en contribución al logro de resultados de interés biológico. Para esto se utilizó el paquete de R/Bioconductor llamado WGCNA (para mayor detalle ver la documentación de Langfelder y Horvath en Langfelder y Steve Horvath 2008) presentado en la sección anterior. En WGCNA se definen los parámetros que se detallan a continuación:

- Se define la matriz de similitud entre los perfiles de expresión génica como el valor absoluto de la función de correlación de Pearson: $S_{ij} = |s_{ij}|$
- Se define la matriz de adyacencia como la transformación de la matriz de similitud ele vado a una potencia β , así: $A_{ij} = [a_{ij}]$, donde $a_{ij} = |corr(x_i, x_j)|^\beta = |s_{ij}|^\beta$.
- Cada entrada de la matriz de adyacencia se corresponde al peso o fuerza de conexión entre los genes correspondientes.
- El exponente o potencia β también llamado umbral suave (del inglés soft-threshold) se selecciona siguiendo el criterio de topología libre de escala presentado por Zhang y Horvath en B. Zhang y S. Horvath 2005b y se evalúa el ajuste de la red a la propiedad de independencia de escala (para más detalle ver el trabajo de Watts en Watts y Strogatz 1998) y los valores de conectividad media para diferentes valores de β .
- Se define la matriz de sobreposición topológica [TOM del inglés Topological Overlap Matrix] como una medida de similitud basada en la inter-conectividad relativa entre dos nodos (del inglés relative inter-connectedness), así: (TOM) $\Omega = [\omega_{ij}]$, donde

$$\omega_{ij} = \frac{l_{ij} + a_{ij}}{\min\{k_i, k_j\} + 1 - a_{ij}}$$

donde $l_{ij} = \sum_u a_{iu}a_{uj}$ y $k_i = \sum_u a_{iu}$. Es decir, que l_{ij} es el número de nodos para los cuales tanto i como j comparten arista. Osea que, si $\omega_{ij} = 1$ significa que todos los vecinos de i son también vecinos de j o de otra manera si $\omega_{ij} = 0$ significa que i y j están desconectados.

- La medida de no-similaridad se define como: $d_{i,j}^\omega = 1 - \omega_{ij}$

Para efectos prácticos se utilizó el paquete WGCNA (Versión 2.3.2) para construir la red e identificar los módulos. Los **parámetros** mas relevantes fueron: TOMType (se parametrizó con valor 'unsigned'), softPower (con valor 6), minModuleSize (con valor 4), powerVector (con valores 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 12, 14, 16, 18, 20) en sus funciones *pickSoftThreshold* y *blockwiseModules* (para mayor detalle revisar la documentación en Langfelder y Steve Horvath 2008).

4.2.3. Análisis de redes complejas

Identificación de clusters y anotaciones

Ya que el método WGCNA se basa en el criterio de topología libre de escala de la red, tanto para la construcción de la red como la identificación de clusters, se consideraron solo las redes que cumplen las siguientes condiciones:

- Se seleccionó un valor para $\beta = 6$ en el cual el $R^2 = 0,942$ de la regresión fue lo más cercano a 1 (lo recomendable es $R^2 \geq 0,8$) y la pendiente lo más cercana a -1 ($-1,55$, para el β escogido)
- Además, se encontró equilibrio entre el ajuste al modelo lineal y el número promedio de conexiones en la red (conectividad media) de 19,5, ya que valores de R^2 muy cercanos a 1, generan redes con muy pocas conexiones.

Por otra parte, por medio de AmiGO Gene Ontology 2015b, se encontraron los términos de la base de datos biológica de ontologías del gen (o GO del inglés Gene Ontology, para mayor detalle ver la sección 2.1) más representativos asociados a los módulos y genes encontrados y seleccionados según las condiciones establecidas en esta sección.

Como validar los resultados obtenidos con WGCNA en E.coli?

Una vez obtenidos los clusters con WGCNA se hizo una selección aleatoria de 10 clusters de diferentes tamaños entre 4 y 13. Después, cada cluster seleccionado fue comparado con su par en el atlas bacteriano ABASY (del inglés Across-bacteria system y con un 88 % de módulos anotados del genoma del organismo *Escherichia coli* str. K-12 substr. MG1655 - 2017, RDB16, Strong (término utilizado para clasificar las bases de datos cuyas interacciones han sido verificadas tanto en la bioinformática como en laboratorio), para mayor detalle ver Ibarra-Arellano y col. 2016).

Como mecanismo de comparación se empleó el *índice de Jaccard* también conocido como la intersección sobre la unión (del inglés Intersection over Union) definido como:

$$J(A, B) = \frac{|A \cap B|}{|A \cup B|} = \frac{|A \cap B|}{|A| + |B| - |A \cap B|}$$

, donde $0 \leq J(A, B) \leq 1$, siendo A : el conjunto de genes que corresponden a un módulo de E.coli en ABASY y B : el conjunto de genes obtenidos en un cluster analizado de la red de co-expresión obtenida.

4.3. Resultados

4.3.1. Construcción de la red

Un paso importante en la construcción de la red con el método WGCNA es la elección de una potencia β ó umbral ligero o liviano. La función *pickSoftThreshold* (mencionada

Cuadro 4.1: Valores de ajuste al modelo de topología libre de escala y conectividad media de la red construida.

<i>Potencia</i> β	R^2	<i>Pendiente</i>	<i>Conectividad (k) media</i>	<i>Máx.(k)</i>
1	0.220	1.150	929.000	1550.0
2	0.262	-0.638	312.000	776.0
3	0.738	-1.190	131.000	447.0
4	0.875	-1.410	63.100	282.0
5	0.921	-1.500	33.800	188.0
6	0.942	-1.550	19.500	133.0
7	0.958	-1.620	12.000	99.2
8	0.961	-1.660	7.770	77.2
9	0.962	-1.690	5.260	61.7
10	0.958	-1.720	3.690	50.5
12	0.929	-1.740	2.010	35.7
14	0.945	-1.680	1.210	26.6
16	0.965	-1.610	0.796	20.6
18	0.954	-1.540	0.559	16.4
20	0.979	-1.450	0.414	13.3


en la sección anterior) devuelve un conjunto de índices de redes que podrían ser seleccionados y de los cuales la potencia $\beta = 6$ fue seleccionada de acuerdo a las condiciones fijadas en la sección anterior. Los valores de ajuste para el parámetro del vector de potencias 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 12, 14, 16, 18, 20 para la función *pickSoftThreshold* (recomendado por el tutorial de Langfelder y Horvath Langfelder y Steve Horvath 2008) se muestra en el cuadro 4.1, y como puede observarse, la potencia 6 ajusta al modelo a $R^2 = 0,942$ cumpliendo la condición de cercanía a 1. Así mismo, esta potencia ajusta el modelo a una pendiente de $-1,55$ cumpliendo la condición de cercanía a -1 . Además, el valor de conectividad media para la selección da 19,5 para la cual la red resultante no es una red con pocas conexiones.

Por otra parte, la figura 4.1 muestra para las diferentes potencias el valor de ajuste R^2 . Igualmente, en la parte derecha de la figura en mención podemos ver la conectividad media para cada potencia del vector. En ambos gráficos se trazó una línea vertical para encerrar los valores de ajuste que convienen de acuerdo a las condiciones mencionadas en la sección anterior.

4.3.2. Identificación de clusters y anotaciones GO

Después de aplicar el marco de trabajo WGCNA para los datos de E. coli se obtuvieron 90 clusters en total para la red obtenida como se muestra en el cuadro 4.2. De estos 8 clusters fueron validados de acuerdo a las condiciones de la sección anterior. El cuadro 4.4 presenta los módulos identificados y validados en la red construida, con un color titulado en inglés, el tamaño expresado en número de genes y la conectividad media para toda la

Figura 4.1: Ajuste al modelo de topología libre de escala y conectividad media.



Cuadro 4.2: Resumen de los clusters identificados.

Condición	Dataset	Identificados	Validados
264 condiciones experimentales	M^{3D}	90	8

red.

Un indicador de que el análisis del genoma del E.coli con WGCNA fue coherente se observa en el cuadro 4.3 y 4.5, donde los clusters (*90-antiquewhite2*) correspondientes a genes Intermodulares (*galE_b0759_14*, *galK_b0757_14*, *galM_b0756_15*, *galT_b0758_14*) presentan un índice de conectividad media más alto (11,7 para el cluster y entre 9,2 y 14,4 para los genes) que el de otros genes modulares como el de lactosa (0,8) o arabinosa (1,3).

Adicionalmente, por medio de AmiGO Gene Ontology 2015b, se encontraron los términos GO más representativos asociados a los 8 módulos y genes validados en la red. Los cuadros 4.4 y 4.5 presentan los resultados con los términos GO más significados según ABASY Ibarra-Arellano y col. 2016.

Finalmente, las gráficas generadas con el paquete WGCNA (R/Bioconductor) incluyen el dendrograma de los 90 clusters identificados y etiquetados con colores (ver figura 4.2) así como el mapa de calor (del inglés Heat Map) correspondiente a la función plot de la matriz TOM (ver figura 4.3). En este mapa de calor vemos mapeados los dendrogramas correspondientes a los 90 clusters detectados (en diferentes colores) y también, podemos apreciar los puntos en rojo (calor) por la diagonal donde precisamente se presentan las concentraciones de grupos de genes co-expresados.

4.3.3. Validación de los clusters identificados

Además de la verificación en GO de los genes de los clusters identificados, solo aquellos con índice de Jaccard mayor o igual a 0.8 (80 %) fueron considerados como validos. En el cuadro 4.6, mostramos 4 clusters que seleccionamos dado su rol en el metabolismo de carbohidratos, y que serán objeto de análisis en el capítulo 6, en estos clusters se cruzó información de ABASY (anotaciones GO) para filtrar los genes específicos relacionados con metabolismo de carbohidratos en E.coli, a excepción del cluster 0-gray de donde se

4 Método para construir redes de co-expresión

Cuadro 4.3: Propiedades topológicas de la red y algunos clusters detectados.

No.	Cluster	Tamaño (# Genes)	Conectividad (k) media
	Toda la red	4296	19.5
0	gray	69	0.836
81	salmon2	4	1.37
90	antiquewhite2	4	11.77
73	firebrick4	5	3.67
40	mediumpurple3	12	3.72
34	darkmagenta	13	7.05
35	sienna3	13	18.15
36	yellowgreen	13	8.54

Cuadro 4.4: Clusters identificados en la red de co-expresión génica.

Cluster	Término GO	Genes Anotados	Genes Observados
0 - gray	lactose transport	4	69
81 - salmon2	D-ribose transport D-xylose transport arabinose catabolic process L-arabinose catabolic process to xylulose 5-phosphate D-xylose catabolic process L-arabinose transport carbohydrate phosphorylation	16	4
90 - antiquewhite2	galactose metabolic process	4	4
73 - firebrick4	Protein transport Transporter activity Integral component of membrane ATP binding	5	5
40 - mediumpurple3	cellular protein modification process protein maturation	9	12
34 - darkmagenta	carbohydrate transport maltose transport maltodextrin transport	9	13
35 - sienna3	cysteine metabolic process iron-sulfur cluster assembly	9	13
36 - yellowgreen	Pyrimidine nucleobase catabolic process Uracil catabolic process Nitrogen utilization	223	13

4 Método para construir redes de co-expresión

Cuadro 4.5: Genes con función biológica afín dentro de los cluster validados. La columna k corresponde a la conectividad media de cada gen.

#	Cluster	Id. Gen	Descripción	k
0	gray	lacA_b0342_15	galactoside O-acetyltransferase monomer	0.647
		lacY_b0343_15	lactose / melibiose: H^+ symporter LacY	0.6
		lacZ_b0344_15	β -galactosidase monomer	0.19
81	salmon2	araC_b0064_15	Regulator	0.6
		araF_b1901_15	arabinose ABC transporter- periplasmic binding protein	1.9
		araG_b1900_15	arabinose ABC transporter - ATP binding subunit	1.5
		araH_b4460_28	arabinose ABC transporter - membrane subunit	1.4
34	darkmagenta	lamB_b4036_15	Maltoporine	6.2
		malE_b4034_14	maltose ABC transporter - periplasmic binding protein	6.6
		malF_b4033_14	maltose ABC transporter - membrane subunit	4.1
		malG_b4032_15	maltose ABC transporter - membrane subunit	3.2
		malK_b4035_15	maltose ABC transporter - ATP binding subunit	6.5
		malP_b3417_14	maltodextrin phosphorylase monomer	10.99
		malQ_b3416_14	amylomaltase	4.59
		malT_b3418_15	transcriptional activator	2.9
35	sienna3	iscA_b2528_14	iron-sulfur cluster assembly protein	3.42
		iscR_b2531_14	DNA-binding transcriptional dual regulator	3.45
		iscS_b2530_14	cysteine desulfurase monomer	4.19
		iscU_b2529_15	scaffold protein for iron-sulfur cluster	4.15

4 Método para construir redes de co-expresión

Figura 4.2: Dendograma de los módulos identificados en la red de E.coli construida con el método WGCNA.





Figura 4.3: Plot mapa de calor de la matriz de solapamiento topológico (TOM del inglés Topological Overlap Matrix)



Cuadro 4.6: Resultado de validación de clusters empleando el índice Jaccard.

Cluster	Genes identificados	Genes Anotados	Índice Jaccard
34-darkmagenta	8	9	0,88
0-gray	69	3	<i>No aplica</i>
35-sienna3	4	5	0,80
81-salmon2	4	5	0,80

obtendrá el cluster de metabolismo y transporte de lactosa y donde no aplica el índice de Jaccard ya que corresponde al cluster sin clasificación por el método de detección de clusters utilizado.

4.4. Discusión

En este trabajo se tiene mucho cuidado con la elección de los parámetros del método WGCNA para la construcción de la red en comparación con otros trabajos como el de Liu W. Liu y col. 2018, donde se seleccionan el tamaño de cluster mínimo muy grade (30), que para el análisis global de la red acertadamente se extraen las características y propiedades esenciales, sin embargo, para estudios mas focalizados como las interacciones regulatorios o causales (grafo dirigido) se queda corto, ya que como indica ABASY Ibarra-Arellano y col. 2016 para el organismo E.coli existen módulos como Lactosa (4 genes, LacA, LacZ, LacY) o Maltosa (9 genes), entre otros, que no quedarían filtrados con la parametrización de Liu.

Los 8 grupos o clusters de genes que se mostraron en el cuadro 4.3, fueron seleccionados aleatoriamente entre los 90 clusters identificados por WGCNA para el genoma de E.coli (ver cuadro 4.2 y sección 4.3.1). Adicionalmente, los genes de cada uno de los 8 cluster fueron consultados en GO y filtrados por la afinidad de su función biológica (como se mostró en los cuadros 4.4 y 4.5). A continuación, se detallarán algunos de ellos con una breve reseña biológica:

- Uno de los módulos más estudiados de E.coli es el de la lactosa (del inglés lactose), el cual se entiende y es un punto de referencia para el estudio del sistema regulatorio bacteriano (ver figura 4.4), el cual es controlado por 4 promotores: P1 (promotor principal) y p2,p3,p4 promotores más débiles. La transcripción de este módulo es regulada positiva (activación) y negativamente (represión). La regulación negativa ocurre cuando el lac represor (lacI) se liga al operador previniendo la transcripción por la polimerasa RNA (encima). Por otra parte, la regulación positiva es mediada por la proteína receptora cAMP, CRP (CAP del inglés catabolite activator protein). En presencia de glucosa la expresión de lactosa no es necesaria y ocurre un mecanismo de control llamado represión (del inglés catabolite repression), es decir, que la glucosa tiene la habilidad de inhibir la expresión de lactosa; como los niveles de cAMP bajan en respuesta a que la glucosa no es tomada, entonces CRP no se activa y la expresión se inhibe. De otra manera, en ausencia de glucosa, los niveles de cAMP se incrementan y estos metabolitos se ligan a CRP, el cual se activa y se liga al DNA cerca de la región promotora facilitando la expresión de lactosa. En resumen, la proteínas de lactosa son inducidas cuando en E.coli hay un incremento de lactosa en ausencia de glucosa y CRP es el principal activador de expresión y estimula la transcripción de P2. De la misma manera CRP solapa completamente P1 y P3 evitando que la polimerasa RNA se ligue, como se dijo anteriormente, previniendo la transcripción de estos promotores.

4 Método para construir redes de co-expresión

- Con los resultados de la red de co-expresión y los cluster detectados y analizados con la ayuda de WGCNA damos cumplimiento a los objetivos específicos de revisar y adaptar computacionalmente la construcción y visualización de redes de co-expresión de genes y conceptualizar, diseñar e implementar las herramientas de análisis de redes complejas de expresión de genes y sus relaciones.

5 Aprendizaje de redes Bayesianas

5.1. Introducción

La identificación y el análisis de genes de interés biológico y sus interacciones son claves en diseño de fármacos, mejoramiento fisiológico de plantas e investigación de enfermedades como la oncogénesis, entre otros. Es posible analizar el comportamiento colectivo de grupos de genes usando modelos que representen la interacción entre ellos. Algunos modelos son las redes de co-expresión génica y las redes regulatorias de genes, donde se observan patrones de expresión que siguen los grupos de genes bajo ciertas condiciones biológicas y el impacto del comportamiento de un grupo sobre otros. Estas redes han sido representadas con modelos de redes Bayesianas. Su estructura y parámetros han sido aprendidos con métodos estadísticos como las simulaciones de Markov Chain MonteCarlo (MCMC) e inferencia Bayesiana.

El propósito de este capítulo es caracterizar un método para el aprendizaje de una red Bayesiana y sus parámetros a partir de datos de expresión y mostrar su funcionamiento con algunos ejemplos de expresión génica de E.coli. Primero caracterizamos un método general de aprendizaje de redes Bayesianas adaptando el algoritmo de Metropolis Hasting, Luego presentamos una versión iterativa de esta adaptación para obtener conjuntos más amplios de redes en el nivel óptimo (de aquí en adelante llamadas "redes óptimas") . Posteriormente, trataremos el tema del sobre-entrenamiento de las redes obtenidas y presentamos diferentes métodos para seleccionar entre las redes óptimas una red más apropiada para el análisis. Estos métodos son orientados hacia la obtención de una red Bayesiana minimal (llamada así porque se obtiene como intersección de redes Bayesianas) donde se priorizan las aristas más frecuentes y una red reducida donde se eliminan las aristas menos frecuentes de la red minimal pero conservando la conectividad de la red. Estas redes faciliten los análisis y permitan dar con redes óptimas coherentes desde el punta de vista biológico para el caso del ejemplo con E.coli como será ilustrado en el capítulo 4. Finalmente proporcionamos unos comentarios concluyentes.

5.2. Caracterización de un método general de aprendizaje de redes Bayesianas y sus parámetros.

En esta sección se presenta la caracterización de un método de aprendizaje de redes Bayesianas y sus parámetros basados en el enfoque de simulaciones de Markov Chain MonteCarlo (MCMC, para mayor detalle ver Hastings 1970 y Friedman y Koller 2003). Este método será parte del marco de trabajo de redes Bayesianas que se propondrá y se compone de los siguientes pasos:

1. Definir la red Bayesiana inicial e inicializar la matriz de adyacencia $N \times N$ correspondiente, siendo N el número de variables o nodos de la red Bayesiana. Por defecto, la red se inicializa como una red totalmente desconectada y se convierte en *la red Bayesiana actual*.

2. Evaluar el ajuste de los datos dada la red Bayesiana *actual*, es decir, calcular la función de *verosimilitud* para el modelo de la red Bayesiana *actual*.
3. Buscar una estructura de red Bayesiana *candidata* en el vecindario de la red Bayesiana *actual*.
4. Evaluar la función *de verosimilitud* para la red Bayesiana *candidata*.
5. Calcular la probabilidad de aceptación de la red Bayesiana candidata dada la red Bayesiana actual.
6. Aplicar el *criterio de aceptación* de la red Bayesiana *candidata* basado en el algoritmo de *Metropolis Hasting*.
7. Iterar los pasos del 3. al 6. hasta alcanzar el *número máximo de simulaciones*, parametrizado previamente.

Para efectos de la caracterización de este método, se establecieron las siguientes consideraciones para la representación del modelo de una red Bayesiana y un conjunto de muestras subyacentes de este modelo. Sea B un modelo de red Bayesiana con $B = (G, \Theta)$, donde G es un grafo acíclico dirigido (GAD) cuyos nodos corresponden a un conjunto de variables aleatorias discretas $V = \{V_1, \dots, V_N\}$, Θ un vector, donde cada elemento representa una probabilidad condicional entre las variables aleatorias de G y $X = \{X_1, \dots, X_M\}$ un conjunto dado de M observaciones idéntica e independientemente distribuidas (*IID*), obtenidas a partir de un experimento estadístico cuyo modelo subyacente puede ser explicado por B . Adicionalmente:

- Sea $A = [a_{ij}]$ la matriz de adyacencia para representar la estructura de una red Bayesiana, donde a_{ij} toma el valor 1 si existe una arista entre los nodos i y j de la red ó 0 en caso contrario.
- Sea $P(X|G, \Theta)$ la función de verosimilitud correspondiente al modelo de la red Bayesiana B .
- Sea $P(G, \Theta|X)$ la distribución de la probabilidad del modelo de la red Bayesiana B , posterior a las observaciones X .

A continuación, se profundiza sobre algunos conceptos y operaciones involucrados en los diferentes pasos del método de aprendizaje de redes Bayesianas propuesto en esta investigación.

5.2.1. La red Bayesiana inicial e inicialización de la matriz de adyacencia

Ya que la estructura de la red Bayesiana inicial G será desconexa su respectiva matriz de adyacencia A de $N \times N$ deberá inicializarse así: $a_{ij} = 0$, para $i = 1 \dots N$ y $j = 1 \dots N$. Es posible iniciar la simulación con una red conectada, sin embargo, la estructura inicial dada podría sesgar la caminata aleatoria a través del espacio de búsqueda de estructuras.

5.2.2. La función de *verosimilitud* para el modelo de la red Bayesiana

Generalmente, se optimiza el cálculo computacional de las funciones de verosimilitud modificando la escala de su valores de evaluación usando la función logaritmo natural, en nuestro caso se reemplaza $P(X|G, \Theta)$ por $\ln(P(X|G, \Theta))$. La transformación a escala logarítmica mantiene el orden ($a < b$ implica $\ln a < \ln b$) y con eso los puntos óptimos. La

transformación facilita computacionalmente los cálculos ya que productos de variables se convierten en sumas, especialmente conveniente en el cálculo de las distribuciones conjuntas en redes Bayesianas, donde un producto de muchos valores menores que 1 puede resultar en valores muy cercanos a 0 con el riesgo de underflow computacional.

5.2.3. El vecindario de la red Bayesiana actual

La vecindad entre dos estructuras de red en el espacio de búsqueda está dada en términos de los siguientes operadores: (i) *agregar una arista* a la estructura de la red actual, (ii) *quitar una arista* a la estructura de red actual y (iii) *quitar una arista* a la estructura de la red actual y a la red resultante *agregar una arista* (*doble operación*). Este enfoque está basado en el trabajo de Friedman y Koller 2003. Sin embargo, se modificó este enfoque para poder determinar de antemano el número de vecinos de una estructura y seleccionar aleatoriamente una de ellas. Esto evita explorar algunas estructuras candidatas que al analizarlas presentan ciclos; lo que podría pasar con mayor frecuencia en la medida que se aumentan las aristas en la red. Por eso modificamos la operación (iii) que originalmente consiste en invertir una arista.. El procedimiento estocástico que aplicamos hace conteo del número de estructuras para cada operador (i), (ii) y (iii) y aleatoriamente selecciona una. La red Bayesiana *candidata* será obtenida aplicando uno de los tres operadores anteriores y se denotará como $B' = (G', \Theta')$ y su matriz de adyacencia A' . A continuación, se detallará cada una de las operaciones.

(i) Obtención de las posibles estructuras de redes acíclicas después de agregar una arista.

La matriz de adyacencia A indica los caminos de longitud 1 entre cada par de nodos i, j donde $a_{ij} = 1$, y se obtienen los caminos de longitud $2, \dots, N-1$ calculando las potencias de A , es decir, $A^2, \dots, A^{N-1}$. Al sumar estas matrices con la matriz identidad I de dimensión $N \times N$, se obtiene una matriz que indica (con un 1 en la posición (i, j)) la existencia de un camino de cualquier longitud entre i y j . Por eso, si se toman las traspuestas de las matrices potencias y se suman con la matriz identidad I , la matriz resultante C indica (con un 1 en la posición (i, j)) la existencia de un camino de cualquier longitud entre j y i :

$$C = [c_{ij}], c_{ij} = \begin{cases} 1 & \text{Existe camino entre } j, i \\ 0 & \text{No existe camino} \end{cases}$$

Así, al agregar una arista entre los nodos i y j donde $c_{ij} = 1$, se crea un bucle entre ellos. Por consiguiente, solo se debe tener en cuenta los nodos i y j donde $c_{ij} = 0$ al momento de agregar nuevas aristas, si se quiere generar una estructura acíclica. El cálculo de C está dado de la siguiente manera:

$$C = I + \text{Transpuesta}(A) + \text{Transpuesta}(A^2) + \dots + \text{Transpuesta}(A^{N-1})$$

y por eso el número de posibilidades de agregar una arista (manteniendo la red acíclica) es igual al número de 0's en C .

(ii) Eliminación de una arista.

Se debe tomar un par de nodos i, j tales que $a_{ij} = 1$ e invertir su valor $a_{ij} = 0$. El número de posibilidades de eliminar una arista entonces es igual al número de 1's en A .

(iii) La doble operación

Consiste en aplicar el operador (ii) y luego aplicar el operador (i) a la estructura resultante. El número de posibles estructuras vecinas acíclicas está dado por la suma de 0's en las matrices C^* que resultan de cada posible eliminación de una arista de la estructura original.

5.2.4. Evaluación de la función de verosimilitud para la red Bayesiana *candidata*

Teniendo en cuenta que la estructura de la red Bayesiana *candidata* cambia ligeramente con respecto a la red Bayesiana *actual* desde donde es generada, la evaluación de la función de verosimilitud para la red Bayesiana *candidata* $P(X|G', \Theta')$ se optimizó empleando una técnica de *cache* guardando los valores de la función calculados para la red Bayesiana *actual* y teniendo en cuenta la transformación de la función logaritmo natural $\ln$, que se mencionó anteriormente. En ese orden ideas se calcula la diferencia Δ entre los valores de evaluación de la función de la red Bayesiana *actual* versus la *candidata*, así, $\Delta = \ln(P(X|G', \Theta')) - \ln(P(X|G, \Theta))$, en este caso para la función de verosimilitud.

5.2.5. La probabilidad de aceptación de la red Bayesiana *candidata* dada la red Bayesiana *actual*

Tomando como base el algoritmo de *Metropolis Hasting (MH) Hastings 1970*, se calcula el factor α para efectos del criterio de aceptación que nos permite evaluar la red Bayesiana *candidata* de la siguiente manera, empleando la evaluación de la función de verosimilitud:

$$\alpha = \frac{P(X|G', \Theta') P(G, \Theta|G', \Theta')}{P(X|G, \Theta) P(G', \Theta'|G, \Theta)}$$

$P(G', \Theta'|G, \Theta)$ denota la probabilidad de la transición de la red Bayesiana *actual* a la red Bayesiana *candidata* $G, \Theta \rightarrow G', \Theta'$ y se calcula así:

$$P(G', \Theta'|G, \Theta) = \frac{1}{\text{númeroDeEstructurasVecinas}(G)}$$

, donde $\text{númeroDeEstructurasVecinas}(G)$ es el conteo del número de estructuras posibles al aplicar los operadores (i), (ii) y (iii), y ya que aleatoriamente se selecciona una estructura, tal probabilidad será 1 dividido por dicho conteo. Siguiendo un razonamiento similar se llega al siguiente cálculo:

$$\beta = \frac{P(G, \Theta|G', \Theta')}{P(G', \Theta'|G, \Theta)} = \frac{\text{númeroDeEstructurasVecinas}(G)}{\text{númeroDeEstructurasVecinas}(G')}$$

, y así se tiene que criterio α será entonces:

$$\alpha = \frac{P(X|G', \Theta')}{P(X|G, \Theta)} * \beta$$

Finalmente, teniendo en cuenta la transformación de la función a logaritmo natural el cálculo de la probabilidad de aceptación de la red Bayesiana *candidata*, se calculó de esta manera:

$$\ln(\alpha) = \ln(P(X|G', \Theta')) - \ln(P(X|G, \Theta)) + \ln(\beta)$$

5.2.6. Aplicación del *criterio de aceptación* de la red Bayesiana *candidata* basado en el algoritmo de *Metropolis Hasting*

El paso final del algoritmo MH es evaluar el *criterio de aceptación*. La evaluación en el algoritmo de *Metropolis Hasting* se hace para $r = \min(1, \alpha)$ y un aleatorio $u \sim U(0, 1)$: se acepta la transición $G, \Theta \rightarrow G', \Theta'$, si $(u < r)$, es decir:

$$G \rightarrow G', \Theta \rightarrow \Theta'; \text{ si } (u < r)$$

Para ajustar lo anterior al cálculo logarítmico se hace:

$$\ln(r) = \min(0, \ln(\alpha))$$

Y se acepta la transición a la red Bayesiana *candidata*, si $\ln(u) < \ln_r$ para un aleatorio u :

$$G \rightarrow G', \Theta \rightarrow \Theta'; \text{ si } (\ln(u) < \ln(r))$$

5.3. Caso discreto

Ya que las variables w_i de expresión del gen i son continuas, se hace necesario un procedimiento adicional de discretización. Para la variable aleatoria continua w_i se define su discretización en los valores (bajo 0, mediano 1, alto 2) con la variable aleatoria discreta v_i , tal que:

$$v_i = \begin{cases} 0 & , \text{ si } w_i < Q_{i, \frac{1}{3}} \\ 1 & , \text{ si } Q_{i, \frac{1}{3}} \leq w_i < Q_{i, \frac{2}{3}} \\ 2 & , \text{ si } w_i \geq Q_{i, \frac{2}{3}} \end{cases}$$

donde $Q_{i, \frac{1}{3}}$ y $Q_{i, \frac{2}{3}}$ son $\frac{1}{3}$ y $\frac{2}{3}$ cuantiles de la variable w_i .

5.3.1. Verosimilitud

En una red Bayesiana cada variable aleatoria v_i tiene asociada una tabla de probabilidad condicional (TPC). El número de filas en TPC de la variable v_i es $q_i = 3^{|Pa(v_i)|}$ porque discretizamos en 3 valores. Cada entrada en esta tabla asigna a la k -ésima combinación de valores de las variables padre de v_i , la probabilidad $\theta_{i,j,k}$ donde $v_i = j$ para $j = 0, 1, 2$. Por lo tanto, una red Bayesiana para una estructura G será parametrizada así: $\Theta = \{\theta_{ijk} > 0 : \sum_j \theta_{ijk} = 1\}$.

Dadas N observaciones independientes $X = \{X_1, \dots, X_N\}$ obtenidas de la distribución conjunta (ver la ecuación 2.2), estadístico suficiente para Θ es el conjunto de conteos $\{N_{ijk}\}$ donde N_{ijk} es el número de veces que $v_i = j$ dado que las variables $Pa(v_i)$ toman los valores especificados en la k -ésima entrada de la TPC de v_i (para mayor detalle ver el trabajo de Ellis y Wong en Ellis y Wong 2008). En ese orden de ideas los conteos $\{N_{ijk}, j = 0, 1, 2\}$ siguen una distribución *multinomial* con parámetros $N_{i,k} = N_{i0k} + N_{i1k} + N_{i2k}$ (intentos) y $\{\theta_{i0k}, \theta_{i1k}, \theta_{i2k}\}$ (vector de probabilidad). Por lo tanto, la función de verosimilitud del modelo de la red Bayesiana para el caso discreto es un producto de multinomiales:

$$P(X|G, \Theta) = \prod_{i=1}^d \prod_{k=1}^{q_i} Multinomial(N_{i,k}, \theta_{i0k}, \theta_{i1k}, \theta_{i2k}) \quad (5.1)$$

donde $Multinomial(N_{i,k}, \theta_{i0k}, \theta_{i1k}, \theta_{i2k}) = \binom{N_{i,k}}{N_{i0k}, N_{i1k}, N_{i2k}} \theta_{i0k}^{N_{i0k}} \cdot \theta_{i1k}^{N_{i1k}} \cdot \theta_{i2k}^{N_{i2k}}$.

5.3.2. Posterior

En la teoría de probabilidad Bayesiana, si las distribuciones *posteriores* $P(\Theta|X)$ están en la misma familia que la distribución de probabilidad *prior* $P(\Theta)$, la prior y la posterior son llamadas distribuciones conjugadas y la prior es llamada una prior conjugada para la función de verosimilitud (para mayor detalle ver los trabajos de Raiffa y Schlaifer 1961; Bernardo y Smith 2006; Gelman y col. 2003), volviendo al caso para una verosimilitud multinomial con parámetros $N_{i,k}$ (intentos) y $\{\theta_{i0k}, \theta_{i1k}, \theta_{i2k}\}$ (vector de probabilidad) según la teoría Bayesiana, la distribución prior conjugada es una *Dirichlet* con hiperparámetros $\alpha_{i,k} = \{\alpha_{i0k}, \alpha_{i1k}, \alpha_{i2k}\}$ y la posterior con hiperparámetros $\{N_{i0k} + \alpha_{i0k}, N_{i1k} + \alpha_{i1k}, N_{i2k} + \alpha_{i2k}\}$. Por consiguiente la posterior para el modelo de red Bayesiana es un producto de *Dirichlets* así:

$$P(G, \Theta|X) = \prod_{i=1}^d \prod_{k=1}^{q_i} Dirichlet(N_{i0k} + \alpha_{i0k}, N_{i1k} + \alpha_{i1k}, N_{i2k} + \alpha_{i2k}) \quad (5.2)$$

donde

$$\begin{aligned} Dirichlet(N_{i0k} + \alpha_{i0k}, N_{i1k} + \alpha_{i1k}, N_{i2k} + \alpha_{i2k}) &= \\ \frac{\theta_{i0k}^{N_{i0k} + \alpha_{i0k} - 1} \cdot \theta_{i1k}^{N_{i1k} + \alpha_{i1k} - 1} \cdot \theta_{i2k}^{N_{i2k} + \alpha_{i2k} - 1}}{\beta(N_{i0k} + \alpha_{i0k}, N_{i1k} + \alpha_{i1k}, N_{i2k} + \alpha_{i2k})}, \\ \theta_{i0k} \approx E[\theta_{i0k}] &= \frac{N_{i0k} + \alpha_{i0k}}{(N_{i0k} + \alpha_{i0k} + N_{i1k} + \alpha_{i1k} + N_{i2k} + \alpha_{i2k})}, \\ \theta_{i1k} \approx E[\theta_{i1k}] &= \frac{N_{i1k} + \alpha_{i1k}}{(N_{i0k} + \alpha_{i0k} + N_{i1k} + \alpha_{i1k} + N_{i2k} + \alpha_{i2k})}, \\ \theta_{i2k} \approx E[\theta_{i2k}] &= \frac{N_{i2k} + \alpha_{i2k}}{(N_{i0k} + \alpha_{i0k} + N_{i1k} + \alpha_{i1k} + N_{i2k} + \alpha_{i2k})} \end{aligned}$$

y

$$\begin{aligned} \beta(N_{i0k} + \alpha_{i0k}, N_{i1k} + \alpha_{i1k}, N_{i2k} + \alpha_{i2k}) &= \\ \frac{\Gamma(N_{i0k} + \alpha_{i0k}) \Gamma(N_{i1k} + \alpha_{i1k}) \Gamma(N_{i2k} + \alpha_{i2k})}{\Gamma(N_{i0k} + \alpha_{i0k} + N_{i1k} + \alpha_{i1k} + N_{i2k} + \alpha_{i2k})}. \end{aligned}$$

5.3.3. Prior

Como mencionamos en la sección anterior, en este trabajo se modeló una distribución prior conjugada *Dirichlet* con hiperparámetros $\alpha_{i,k} = \{\alpha_{i0k}, \alpha_{i1k}, \alpha_{i2k}\}$. Así, cada distribución posterior *Dirichlet*($N_{i0k} + \alpha_{i0k}, N_{i1k} + \alpha_{i1k}, N_{i2k} + \alpha_{i2k}$) en la ecuación 5.2, se define como la prior de la variable v_i y la k -ésima entrada de su tabla de probabilidad condicional (la cual corresponde a la k -ésima combinación de valores de las variables padre de v_i), pero actualizada por la información de los datos a través de los conteos $N_{i0k}, N_{i1k}, N_{i2k}$, ya que discretizamos en 3 valores $\{0, 1, 2\}$. Es decir, que a cada hiperparámetro de la prior en mención $\alpha_{i0k}, \alpha_{i1k}, \alpha_{i2k}$, se le suman sus conteos, respectivamente, como una pieza de información extra.

Distribución previa no informativa

En este marco de trabajo, no asumimos que siempre se pueda tener información palpable ni subjetiva, ni objetiva con respecto a la información muestral, por ejemplo, en el caso de las redes biológicas se pueden tener organismos bacterianos con más de 4000 genes y muchas más interacciones entre ellos, que no alcanzan a ser cubiertas en las bases de datos de anotaciones GO. Es decir, van a existir casos de análisis de estas redes en las que el conocimiento previo sea tan poco significativo, que incluso se considere vago o difuso, por esta razón se considera que en este trabajo trataremos con distribuciones previas no informativas. Sin embargo, la distribución previa no informativa servirá al usuario del marco para analizar los resultados de la posterior incluso cuando se tenga poco conocimiento previo sobre las variables o nodos de la red y sus interacciones.

Elicitación de los hiperparámetros de la distribución previa

El proceso de elicitación permite representar la información externa previa al experimento en términos de una distribución de probabilidad, y que pueda dialogar con los datos obtenidos posteriormente a través del experimento. En este marco de trabajo se aplicó el método de Bayes - Le Place. De acuerdo con el principio de razón insuficiente de Bayes - La Place, en ausencia de razón suficiente para privilegiar unas posibilidades en detrimento de otras, debido a la escasez de información a priori, se adopta la equiprobabilidad.

Ahora volviendo a la ecuación 5.2, y asumiendo que las cantidades aleatorias $\theta_{i0k}, \theta_{i1k}, \theta_{i2k}$ se distribuyen de manera uniforme en el intervalo $(0, 1)$, implica ajustar como a priori una *Dirichlet* con hiperparámetros $\alpha_{i0k} = 1, \alpha_{i1k} = 1, \alpha_{i2k} = 1$.

Elicitación de una distribución previa informativa

El proceso de elicitar una distribución previa informativa empleando este marco de trabajo es posible, si procedemos de la siguiente manera:

- Primero, ajustamos los hiperparámetros de la distribución previa no informativa empleando el método de Bayes-Le Place, como describimos en la sección anterior: $\alpha_{i0k} = 1, \alpha_{i1k} = 1, \alpha_{i2k} = 1$.
- Segundo, con base en la distribución previa no informativa, calculamos los parámetros de distribución posterior conjugada, como también se describió anteriormente: $Dirichlet(N_{i0k} + \alpha_{i0k}, N_{i1k} + \alpha_{i1k}, N_{i2k} + \alpha_{i2k}) = Dirichlet(N_{i0k} + 1, N_{i1k} + 1, N_{i2k} + 1)$.
- Tercero, para este procedimiento es mandatorio contar con un nuevo conjunto de datos de muestras que nos permitan realizar un conteo adicional: $N'_{i0k}, N'_{i1k}, N'_{i2k}$, para cada variable i .

- Cuarto, se definen los parámetros de la nueva posterior conjugada con la distribución previa informativa, así: $Diritchlet(N'_{i0k} + N_{i0k} + 1, N'_{i1k} + N_{i1k} + 1, N'_{i2k} + N_{i2k} + 1)$
- Quinto, repetir los pasos tercero y cuarto tantas veces como conjuntos de datos de muestras se tenga disponible y se desee refinar el modelo. de la red Bayesiana.

Agradecimientos al profesor Jose Rafael Tovar Cuevas por sus recomendaciones.

5.3.4. Complejidad

Como se mencionó previamente en el estado del arte, la tarea de encontrar una estructura de red que optimice la función de *scoring* es un problema de optimización combinatoria, y es conocido como un problema de complejidad computacional NP-hard D. Chickering 1996. Para ilustrar discutiremos el cálculo del resultado de la sección anterior $\theta_{i0k}, \theta_{i1k}$ y θ_{i2k} . Ya que k corresponde a la k -ésima combinación de valores de las variables padre de v_i y su calculo estará dado por $k = q_i = 3^{|Pa(v_i)|}$, donde se ve que el cálculo computacional además de estar afectado por el número de variables aleatorias i , también está afectado por la cantidad de padre de v_i . Así la complejidad que se observa aquí es $O(3^{N-1})$, donde 3 es el número de cuantiles en la discretización y $N - 1$ el máximo número de padres en los nodos de la red.

5.4. Simulación iterativa

La simulación MCMC realiza una caminata aleatoria en el espacio de búsqueda de modelos Bayesianos guiada por el criterio de optimización. Por naturaleza del proceso, los modelos obtenidos giran alrededor de un óptimo local y tienden a ser repetidos al final de la simulación. Para explorar mejor el espacio de búsqueda se aplica un algoritmo iterativo que repite varias veces la simulación MCMC a partir de la red desconectada, para lograr que se puedan tomar rutas alternas y así encontrar nuevas estructuras de red óptima. La iteración para, si sólo pocas nuevas soluciones son encontradas. Formalmente, la condición de parada del algoritmo iterativo de simulación MCMC es no encontrar un porcentaje mayor que P redes nuevas. En todas las experimentaciones de los casos de estudio que siguen se emplean la simulación iterativa que aplica 1000 pasos en cada iteración y para al encontrar solo $P = 10\%$ o menos soluciones nuevas.

Ejemplo de la aplicación de la simulación iterativa

Para ilustrar un poco la idea veremos una comparación entre la simulación MCMC y la simulación iterativa con datos de expresión génica de E.coli. Tomaremos uno de los cluster identificados en el capítulo anterior (4) cuando se construyó la red de co-expresión génica. El cluster esta compuesto por los genes: *malQ*, *malT*, *lamB*, *malG*, *malP*, *malM*, *malE*, *malF* y *malK* (ver en la tabla 4.5, del cluster 34-darkmagenta).

La simulación MCMC se realizó con 1,000 repeticiones y se obtuvieron 25 modelos distintos capturados desde 418 iteraciones que se encontraron en el rango del nivel óptimo ver la figura 5.1. En esta figura también puede verse el número de aristas, el máximo grado de entrada y la función acumulada del cambio en el logaritmo de la posterior de cada red procesada durante la simulación MCMC. Aquí también puede verse las similitudes en estas características de las redes que se encuentran en un rango del nivel óptimo.

Por otra parte, si realizamos el mismo ejercicio con el cluster de transporte de maltosa de E.coli pero esta vez con el algoritmo de simulación iterativa encontramos que se realizan 18,430 iteraciones y se obtienen 102 modelos diferentes. De la misma manera que para la

Figura 5.1: Simulación MCMC con 1,000 iteraciones para el cluster de transporte de maltose en E.coli. En esta figura puede verse el número de aristas, el máximo grado de entrada y la función acumulada del cambio en el logaritmo de la posterior de cada red procesada.





Figura 5.2: Simulación iterativa con 18,470 iteraciones para el cluster de transporte de maltosa en E.coli. En esta figura puede verse el número de aristas, el máximo grado de entrada y la función acumulada del cambio en el logaritmo de la posterior de cada red procesada.



simulación MCMC los resultados del experimento se muestran en la figura 5.2. En la figura puede verse también que después de 18 simulaciones MCMC de 1,000 repeticiones se alcanza la condición de parada (encontrar menos 10 % nuevas redes). Se nota que en cada nueva simulación MCMC se reinician todas las características analizadas (Acumulada, número de aristas y máx. grado de entrada). Para mostrar la ventaja de la simulación iterativa sobre la no iterada, se realizaron 18,430 iteraciones en una sola simulación utilizando los mismo datos. Obtuvimos solamente 30 modelos mientras que la simulación iterativa arroja 102 modelos. Entonces por la simulación iterativa pudimos obtener 72 modelos nuevos.

Por lo tanto, el algoritmo de simulación iterativa nos permite encontrar un número mayor de redes Bayesianas que se encuentran en el rango del nivel óptimo.

5.5. Sobre-entrenamiento

La tendencia del aprendizaje de redes Bayesianas al *sobre-entrenamiento* es evidente, ya que independiente de las funciones génicas anotadas en la ontología del gen (ver The Gene Ontology 2008) la red resultante relaciona el mayor número de genes posibles, por su naturaleza a optimizar el puntaje de evaluación (del inglés score, en este caso el la función

logaritmo natural de la posterior). El siguiente ejemplo ilustra esta situación:

Ejemplo para el sobre-entrenamiento


Se emplearon datos de expresión génica de E.coli tomados de M^{3D} (del inglés Many Microbe Microarrays Database), donde se seleccionaron aleatoriamente 5 clusters para control y 1 cluster para análisis (transporte de lactosa del inglés lactose transport) para un total de 16 genes del genoma de E.coli, que se listan a continuación con sus respectivas anotaciones de ontología del gen (las anotaciones GO fueron tomadas de Ibarra en Ibarra-Arellano y col. 2016):

- Lactose transport:
 - lacA – galactoside O-acetyltransferase monomer
 - lacI – LacI DNA-binding transcriptional repressor
 - lacY – lactose / melibiose:H⁺ symporter LacY
 - lacZ – β -galactosidase monomer
- Global regulators:
 - rpoD – RNA polymerase, sigma 70 (sigma D) factor
 - hns – H-NS DNA-binding transcriptional dual regulator
 - crp – CRP transcriptional dual regulator
- Zinc ion transport:
 - znuA – Zn²⁺ ABC transporter - periplasmic binding protein
- Sodium ion transport:
 - ttdA – L-tartrate dehydratase, α subunit
 - ttdB – L-tartrate dehydratase, β subunit
 - ttdR – Dan
 - ttdT – tartrate:succinate antiporter
- Phosphorelay signal transduction system:
 - zraP – zinc homeostasis protein
 - zraR – ZraR transcriptional activator
 - zraS – ZraS sensory histidine kinase
- Response to arsenic-containing substance:
 - arsB – ArsB


Se aplicó el proceso de aprendizaje de redes Bayesianas a este conjunto de genes, usando una simulación de 90,000 pasos. Se muestra uno de los modelos resultantes en la figura 5.3. Las etiquetas en las aristas corresponden a la frecuencia de ocurrencia en el conjunto de redes Bayesianas dentro del rango del nivel óptimo. Los nodos fueron etiquetados con el gen que representan.

La tendencia del aprendizaje de redes Bayesianas al *sobre-entrenamiento* es evidente: Se observa un gran número de aristas. Algunas de ellas pueden significar relaciones causales importantes, como por ejemplo las dependencias entre los genes del transporte de sodio (ttdA, ttdB, ttdR, ttdT) resaltados en la figura 5.4a en rojo). Otras aristas se pueden agregar porque se encuentra estadísticamente una dependencia débil entre dos nodos sin que exista una relación causal simplemente porque es posible y mejora el *score* del modelo. Un caso típico sería la situación donde una red causal tiene 2 nodos padre; el proceso de optimización agregará aquella arista entre los padres que mejora más el score. Se verifica

Figura 5.3: Tendencia a sobre-entrenamiento en el aprendizaje cuando se incluyen genes de diferentes clusters de E.coli en una misma simulación MCMC.



(a) Resaltando los genes del transporte de sodio (ttdA, ttdB, ttdR, ttdT).



(b) Adición de aristas en un nodo completamente independiente del resto de la red.

en la figura 5.4a que los nodos vecinos de *ttdR*, son nodos padres y el score del modelo se mejora si se agregan las aristas marcadas en verde con cualquier orientación. De la misma manera se comporta la red en caso de un nodo que realmente es completamente independiente del resto de la red. Es posible conectar este nodo con cualquier otro nodo de la red, sea como relación padre→hijo o hijo→padre, dando un aumento del score, probablemente considerable, sin ser originado de relaciones verdaderas, lo que se quiere ilustrar con la figura 5.4b. En general se puede decir que el proceso de optimización agrega todas las posibles aristas aunque el mejoramiento del score sea sólo pequeño.

Estas observaciones han conducido a dos recomendaciones importantes:

1. Es importante aplicar el análisis Bayesiano sólo a grupos de genes que se relacionan en alguna manera causalmente. Por eso nos restringimos a clusters co-expresados.
2. Para contrarrestar la tendencia del proceso de optimización de insertar aristas, hay que buscar maneras de filtrar las que tienen significado biológico de aquellas que no tienen importancia. A esta necesidad respondemos con la introducción de la red minimal y la red reducida que se describen más adelante.

5.6. Construcción de redes para el análisis

Todas las redes en el nivel óptimo que genera simulación iterativa pueden ser consideradas representaciones posibles de las relaciones causales entre los genes involucradas. Dada la gran cantidad de estas redes, es imperativo encontrar mecanismos que faciliten el análisis biológico. Una estrategia evidente es tener en cuenta las frecuencias con la cual una arista aparece en todos los modelos. Esto conduce a la introducción de las redes ponderadas con la cual se pueden resaltar las dependencias más importantes entre los genes considerados (*esta introducción fue sugerida por el director del laboratorio de biología de sistemas regulatorios en UNAM - Julio Augusto Freyre Gonzalez, durante una estancia doctoral*). Sin embargo, la red ponderada no es necesariamente una red Bayesiana, ya que al considerar todas las aristas que ocurren en las redes óptimas, se pueden producir ciclos. Por ende, al restringirse a redes ponderadas, se pierde la posibilidad de analizar las dependencias causales.

Una posibilidad de tener en cuenta las frecuencias es reconstruir una red Bayesiana por un proceso que agrega sucesivamente aristas respetando la frecuencia y manteniendo la red acíclica. La red resultante es la que llamamos red Bayesiana minimal, ya que se genera como intersección de conjuntos siempre más pequeños de redes Bayesianas y en consecuencia es por si mismo una red Bayesiana.

Como se verá más adelante, la red Bayesiana minimal es siempre una red completa en el sentido que contiene el número máximo de aristas. Para más claridad en el análisis tratamos a reducir esta red, eliminando una por una las aristas menos frecuentes mientras que la red se mantiene conectada, obteniendo la red que llamamos red Bayesiana reducida.

5.6.1. Red Ponderada (del inglés *Weighted network*)

Para decidir cuando una red se considera óptima, se requiere definir lo que significa computacionalmente "el nivel óptimo" (visualmente es muy claro, observe por ejemplo la figura 5.2). Se decidió describir el nivel óptimo por un rango de valores [*minLogPosterior*, *maxLogPosterior*] de la función de evaluación *LogPosterior*. Sólo las redes con un score dentro de este rango están en el nivel óptimo (las llamadas redes óptimas) son consideradas en la ponderación. La simulación iterativa fue usada para definir el rango:

- Se capturaron en cada iteración los valores del logaritmo de la distribución posterior de las redes encontradas y se determinó el valor máximo de la iteración, obteniendo el conjunto de los valores máximos de las iteraciones: $\{maxLogPos_1, \dots, maxLogPos_M\}$, siendo M la última iteración.
- Para determinar el valor de $maxLogPosterior$ se seleccionó el valor *mayor* del conjunto de valores máximos analizados anteriormente: $maxLogPosterior = \max\{maxLogPos_1, \dots, maxLogPos_M\}$.
- Para determinar el valor de $minLogPosterior$ se seleccionó el valor *menor* del conjunto de valores máximos analizados en el punto anterior: $minLogPosterior = \min\{maxLogPos_1, \dots, maxLogPos_M\}$.

Una vez que se obtiene el conjunto de redes óptimas, es decir, las redes con score en el rango $[minLogPosterior, maxLogPosterior]$, se descartan las redes repetidas y se obtienen los pesos de la siguiente manera:

- Se cuentan las ocurrencias de cada arista a lo largo del conjunto de redes óptimas
- Para cada arista, se divide el conteo realizado en el punto anterior sobre la cardinalidad del conjunto de redes óptimas.

Finalmente, se define la *red ponderada* como la red constituida de las aristas y los pesos obtenidos por el procedimiento descrito anteriormente. Bajo el supuesto que los genes incluidos en el estudio están relacionados biológicamente, es de esperar que las aristas más frecuentes reflejan las relaciones causales más importantes. Este supuesto se confirma en la experimentación.

Una desventaja de la red ponderada es que no es Bayesiana. Por eso, un análisis causal a través de la red causal es muy limitado. Sin embargo podemos basarnos en la frecuencia de las aristas para construir la red Bayesiana minimal como se muestra en la sección siguiente.

Ejemplo de la red ponderada

Basado en el ejemplo de la simulación iterativa (ver figura 5.2), se obtuvo el nivel óptimo en el rango $[19254, 19, 19274, 98]$, (ver tabla 5.1).

Al considerar las redes del nivel óptimo y descartando las redes repetidas, quedaron en total 102 redes óptimas, de las cuales se obtuvo la red ponderada del cuadro 5.2.

Se observa que la red no queda Bayesiana, porque en el ejemplo se forman ciclos entre cada gen y el resto. Por ejemplo, *malT* se relaciona con *lamB* con un peso de 0,81 y viceversa con un peso de 0,19.

Sin embargo, de la red ponderada podemos apreciar cuales de las aristas son muy frecuentes y concluir a una posible relación entre ellas. Por ejemplo, si observamos los pesos de las aristas desde *malT* hacia el resto vemos que sus pesos oscilan entre 0,66 y 0,97 lo cual es muy lógico tratándose de un gen que tiene una función de activación transcripcional con los demás, según GO.

5.6.2. Red Bayesiana minimal

Para realizar análisis causales sobre las variables de estudio, basados en los datos observados, es importante resumir los resultados del aprendizaje en una red Bayesiana. En esta sección presentamos un método para obtener la *red Bayesiana minimal* resultado del aprendizaje basado en los datos observados. Para este efecto, construimos a partir de la ponderación, una red bayesiana paso a paso:

Cuadro 5.1: Rango del nivel óptimo para el ejemplo de la simulación iterativa con el cluster de transporte de maltosa en E.coli. La columna Máx log-posterior corresponde al valor máximo de la función acumulada del logaritmo de los cambios en la posterior para cada intervalo de la simulación.

Iteración inicial	Iteración final	Máx log-Posterior
1	1000	19265.78
1001	2000	19272.74
2001	3000	19271.11
3001	4000	19274.36
4001	5000	19272.35
5001	6000	19268.84
6001	7000	19274.47
7001	8000	19274.90
8001	9000	19274.98
9001	10000	19266.96
10001	11000	19272.29
11001	12000	19271.63
12001	13000	19268.76
13001	14000	19267.32
14001	15000	19272.98
15001	16000	19274.97
16001	17000	19254.19
17001	18000	19270.68
18001	18430	19261.43

Cuadro 5.2: Matriz de adyacencia de la red ponderada para el ejemplo de la simulación iterativa con el cluster de transporte de maltosa en E.coli.

	<i>lamB</i>	<i>malE</i>	<i>malF</i>	<i>malG</i>	<i>malK</i>	<i>malM</i>	<i>malP</i>	<i>malQ</i>	<i>malT</i>
<i>lamB</i>	0	0.67	0.52	0.36	0.59	0.75	0.54	0.15	0.19
<i>malE</i>	0.33	0	0.44	0.19	0.48	0.38	0.22	0.21	0.11
<i>malF</i>	0.48	0.56	0	0.31	0.65	0.58	0.27	0.35	0.15
<i>malG</i>	0.64	0.81	0.69	0	0.80	0.83	0.76	0.25	0.21
<i>malK</i>	0.41	0.52	0.35	0.20	0	0.58	0.15	0.17	0.12
<i>malM</i>	0.25	0.62	0.42	0.17	0.42	0	0.20	0.07	0.03
<i>malP</i>	0.46	0.78	0.73	0.24	0.85	0.80	0	0.25	0.10
<i>malQ</i>	0.85	0.79	0.65	0.75	0.83	0.93	0.75	0	0.34
<i>malT</i>	0.81	0.89	0.85	0.79	0.88	0.97	0.90	0.66	0

1. Encontramos la arista con el mayor frecuencia de toda la red, es decir, la arista que tuvo más ocurrencias en el conjunto de redes óptimas, obtenido con el procedimiento de la sección anterior. El resultado de este paso será entonces los nodos origen y destino correspondientes a la arista: i, j que forma la primera arista de la red a construir.
2. Ahora se filtra el conjunto de redes óptimas dejando unicamente las redes donde aparece la arista i, j . Se ajustan las frecuencias de todas las aristas en el conjunto filtrado de redes óptimas.
3. Se repiten los pasos 1 y 2 hasta que todas las aristas en el conjunto filtrado tengan frecuencia 1.

La red Bayesiana resultante es una red que pertenece al conjunto inicial de redes óptimas y le llamamos *minimal*.

Ejemplo de la red Bayesiana minimal


Para ilustrar este procedimiento, retomaremos de nuevo el ejemplo usado en la sección 5.4. Adicionalmente, fueron seleccionados aleatoriamente dos conjuntos de genes de control, cada uno con 9 genes. Los resultados de esta experimentación pueden verse en la figura 5.4. El orden secuencial se detecta fácilmente usando la altura de la posición de los nodos. Se verifica que cada una de las redes es completa (las aristas salientes de un nodo tienen el mismo color). El número sobre una arista indica la iteración en que fue seleccionado. Los nodos fueron etiquetados con el gen. Observamos la secuencia:

$malQ \rightarrow malT \rightarrow lamB \rightarrow malG \rightarrow malP \rightarrow malM \rightarrow malE \rightarrow malF \rightarrow malK$.


Las aristas más frecuentes son $malT \rightarrow malM$ (la primera, frecuencia 99 en la red ponderada), $malQ \rightarrow malM$ (la segunda con una frecuencia de 95), $malT \rightarrow malP$ (la tercera, frecuencia 92). Las etiquetas en la figura corresponden al orden en que la arista fue seleccionada seguido de la frecuencia de ocurrencia en el conjunto de redes Bayesianas dentro del rango del nivel óptimo.

Las 3 redes tienen una estructura idéntica: siempre hay un nodo padre que tiene aristas con todos los demás nodos (8 nodos hijos), y en la jerarquía le sigue un hijo que es padre de los demás (7 nodos hijos), y así sucesivamente, observándose, que en esta jerarquía no se podrían tener más aristas ($8+7+\dots+1=36$ aristas) ya que cada arista adicional convertiría la red en un grafo cíclico. En conclusión, la optimización no puede dar con una estructura de


Figura 5.4: Comparación entre 3 redes Bayesianas minimales con 9 genes.



(a) Red Bayesiana minimal para los genes del cluster de transporte de maltosa.



(b) Red Bayesiana minimal para los genes del cluster de genes aleatorios del control 1.



(c) Red Bayesiana minimal para los genes del cluster de genes aleatorios del control 2.

red con más aristas, lo que permite caracterizar este tipo de red como una "red Bayesiana completa". Solo el orden secuencial de los nodos (del nodo con el máximo número de aristas salientes al nodo sin aristas salientes) determina la estructura de una red bayesiana completa. Como se verá más adelante en el capítulo del caso de estudio, esta situación se evidencia también en redes con 4 genes, 5 genes y 11 genes (ver en la tabla 4.5).

5.6.3. Red Bayesiana reducida

Para facilitar los análisis y encontrar características biológicamente interesantes en las redes Bayesianas minimales, aplicamos un procedimiento adicional para dar con una red Bayesiana minimal *reducida*, que consiste de los siguientes pasos:

1. Se parte de una red completamente desconectada, es decir, sin aristas.
2. Con base en la red Bayesiana minimal, se selecciona la arista con mayor frecuencia de ocurrencia en el conjunto de redes Bayesianas dentro del rango del nivel óptimo.
3. Se define un nuevo subconjunto con las redes Bayesianas dentro del rango del nivel óptimo pero además donde la arista seleccionada en el paso anterior esta presente en la red.
4. Se repite el paso (2) pero esta vez la frecuencias se calcula con base en el subconjunto definido en el paso anterior y cuidando que la arista seleccionada no haya sido ya procesada.
5. Se repite el paso (3) pero esta vez el bus-conjunto se calcula con las redes Bayesianas del último subconjunto y donde la arista seleccionada en el paso anterior este presente en la red.
6. El procedimiento terminal cuando al conectar la última arista transforma la red Bayesiana resultante en un red conectada, es decir, que no exista ningún nodo desconectado de la red

Ejemplo de la red Bayesiana reducida


Pasando a la práctica nuevamente con el ejemplo de datos de expresión génica de E.coli, pudimos ver en la sección anterior una red con muchas aristas, difícil aun de analizar biológicamente. Ahora aplicando el procedimiento de reducción podemos ver algunos ejemplos de resultados más prestos para un análisis causal entre genes según su función génica y anotaciones GO, ver la figura 5.5. Las etiquetas en la figura corresponden al orden en que la arista fue seleccionada seguido de la frecuencia de ocurrencia en el conjunto de redes Bayesianas dentro del rango del nivel óptimo

La red reducida tiene 4 padres (malQ, malT, lamP, malG) y 4 hojas (malM, malE, malF, malK); sólo el nodo malP queda intermedio. Esto confirma lo dicho en la sección 5.5 (de sobre-entrenamiento) sobre el la tendencia de agregar aristas nuevas entre padre para mejorar el score. La cantidad máxima de 36 aristas en la red minimal fue reducido a sólo 16 aristas en la red reducida.

5.7. Comentarios concluyentes

- Los tiempos computacionales de las simulaciones MCMC se verán afectados por el número de variables, ya que al evaluarse la posterior para el nodo hoja de la red

Figura 5.5: Red Bayesiana minimal reducida de los genes del cluster de transporte de maltosa en *E.coli*. Las etiquetas en la figura corresponden al orden en que la arista fue seleccionada seguido de la frecuencia de ocurrencia en el conjunto de redes Bayesianas dentro del rango del nivel óptimo. Los nodos fueron etiquetados con el gen.



Bayesiana minimal (que es una de las redes óptimas) la complejidad será exponencial como se discutió en la sección 5.3.4.

- Como una mejora de la simulación MCMC se propuso el método de simulación iterativa, después de analizar que los caminos de exploración del espacio de búsqueda en un punto de la simulación MCMC, pueden quedar restringidos por el rumbo tomado y por la consigna de no generación de bucles en las redes del conjunto solución, y encontramos un equilibrio (trade-off) entre el número de simulaciones suficientes para agregar nuevos modelos, pero sin impactar demasiado la complejidad del problema, estableciendo como criterio de parada de las iteraciones, el porcentaje mínimo de nuevos modelos para agregar al conjunto solución.
- Inherente al aprendizaje de redes Bayesianas es la tendencia a sobre-entrenar las redes, en todos los modelos se busca optimizar la función score (likelihood), la cual mejora cuando se agregan nuevas aristas. Entre más aristas se agregan, la red mejora su puntaje (o score), sin embargo no todas nuevas aristas tienen poder explicativo biológico como se mencionó en la sección 5.5. Por eso se recomienda la restricción de aplicar el aprendizaje de redes Bayesianas a clusters y la necesidad de emplear mecanismos capaces de mantener las relaciones biológicamente relevantes y eliminar aristas no importantes, lo que conduce a la introducción de redes minimales y reducidas (Secciones 5.6.2 y 5.6.3, respectivamente).
- La red ponderada se puede utilizar para analizar la frecuencia de ocurrencia de las aristas del conjunto de redes óptima. Dado que se consideran sólo las redes del nivel óptimo y se descartan las redes repetidas, la red ponderada aporta información para un análisis cuantitativo. La red ponderada no es Bayesiana, por eso, un análisis causal a partir de ella es limitada. Sin embargo resultó muy útil en la construcción de la red Bayesiana minimal y reducida. El uso de una red ponderada fue una sugerencia para análisis comparativos entre redes Bayesianas óptimas y redes regulatorias de *E.coli* durante la estancia doctoral en UNAM.
- El método para obtener la red Bayesiana minimal entrega una red Bayesiana que

consolida el conjunto de redes óptimas. Es importante resaltar que la red mínima es basada en la frecuencia de las aristas, de manera que se seleccionan las aristas más probables sobre aquellas que aparecen solo pocas veces.

- La red minimal aunque optima sigue pareciendo sobre-entrenada. La red Bayesiana reducida logra mitigar el sobre-entrenamiento eliminando las aristas con menos frecuencia de ocurrencia en los conjuntos de redes óptimas, pero sin dejar desconexa la red Bayesiana. Es una simplificación de la red minimal, que contiene las aristas estadísticamente más relevantes. Por esta razón es un modelo más apropiado para el análisis bioinformático.
- Con el resultado de la redes Bayesianas minimal después de seguir el debido procesos para el aprendizaje de la red, damos cumplimiento al objetivo específico de desarrollar la construcción automática de la arquitectura óptima de una red bayesiana y sus parámetros a partir de los datos de expresión de genes.

6 Casos de estudio: modularidad en algunos clusters de genes de *Escherichia coli*.

6.1. Introducción

La deducción de redes biológicas y el entendimiento de sus propiedades es una de las áreas desafiantes y de interés de la biología de sistemas y computacional, ya que dicho entendimiento nos da luces sobre la manera en que los organismos responden al ambiente y otras señales, y como el desarrollo de las enfermedades altera el funcionamiento de los sistemas biológicos. Por ejemplo: cerca del 20 % de los genes que han sido identificados en la bacteria *Escherichia coli* están involucrados en algún aspecto de transporte y el entendimiento de sus sistemas son de considerable interés médico, ya que podrían estar relacionados con bombeo de antibióticos u otras drogas hacia afuera de la célula haciéndola resistente al medicamento.

En esta área son fundamentales: (1) Identificar grupos de genes de proteínas que se expresan coordinadamente y que se necesitan en concentraciones similares en la célula, (2) Detectar la modularidad entendida como genes asociados con proteínas que actúan coordinadamente en una vía metabólica, y (3) Analizar los módulos detectados a la luz de conceptos biológicos como el operón, transportadores ABC o rutas metabólicas (de los que hablaremos más adelante), que parecen ser comunes en el metabolismo de carbohidratos.


En el resto del capítulo, primero haremos referencia a los clusters que detectamos y seleccionamos en el capítulo 4 e identificaremos algunos grupos de genes de cada cluster que comparten alguna función génica, y después, realizaremos el respectivo análisis bioinformático de los mismos para relacionar los módulos de dichos grupos con los modelos de redes obtenidos. Posteriormente, mencionamos el aspecto computacional donde relacionamos la complejidad que vimos en el capítulo 5 versus los tiempos ejecutados durante las simulaciones en la experimentación, y por último, haremos una breve discusión y comentarios concluyentes.

6.2. Los casos y su análisis

Seleccionamos algunos de los clusters obtenidos de acuerdo con su co-expresión como se describió en el capítulo 4 (ver la tabla 4.4): transporte de maltosa (cluster 34-darkmagenta en la tabla), transporte de L-arabinosa (81-salmon2), ensamble hierro-azufre (35-sienna3) y transporte y metabolismo de lactosa (0-gray). este último, muy documentado, y con el que se dio inicio a este estudio durante una estancia doctoral en el laboratorio de biología de sistemas del centro de ciencias genómicas de UNAM (Universidad Nacional Autónoma de México), a cargo del doctor Julio Augusto Freyre Gonzalez.

En lo que sigue se describen algunos grupos de genes de estos clusters, genes que los componen y se analizan los resultados desde la perspectiva de las redes de co-expresión y Bayesianas. Al final, se presentará algunos aspectos computacionales de la experimentación como: tiempos de procesamiento, número de modelos en el nivel óptimo y la complejidad.

Figura 6.1: Cluster de transporte de maltosa en la red de co-expresión de *E.coli*.



6.2.1. Transporte de maltosa

Descripción del cluster

El primer cluster que analizamos (34-darkmagenta) corresponde al transporte de maltosa que presentó las siguientes propiedades (ver la tabla 4.3): 13 genes expresados, 7.5 (conectividad media). Al cruzar la información de los genes del cluster con la base de datos regulonDB Santos-Zavaleta y col. 2019 y el atlas bacteriano ABASY Ibarra-Arellano y col. 2016, encontramos relación con 9 genes de interés entre los 13 del cluster.

Los 9 genes que analizaremos de este cluster están reverenciados en la tabla 4.5 y su co-expresión se muestra en la figura 6.1, donde podemos apreciar una estructura completamente conectada y muy coherente con el concepto de co-expresión.

Análisis desde la perspectiva la co-expresión

Dentro del cluster de transporte de la maltosa y en concordancia con el concepto de co-expresión se identificaron varios grupos de genes que según la base de datos regulonDB Santos-Zavaleta y col. 2019, figuran como una unidad genética funcional (malEFG) capaz de ejercer una regulación de su propia expresión por medio de los sustratos con los que interactúan las proteínas codificadas por ellos, este concepto es conocido como *operón*, introducido por primera vez por Jacob y Monod en su trabajo Jacob y Monod 1961.

El primer operón (malEFG) esta compuesto de los genes malE, malF y malG. Dando una mirada más profunda al operón malEFG, vemos a través de las funciones génicas de acuerdo a Boos y Shuman en su trabajo Boos y Shuman 1998, que tenemos una proteína de unión de maltosa (MBP), malE, la cual interactuó con dos sub-unidades de membrana, malG y malF, lo cual, es coherente con el trabajo de Boos y Shuman donde afirman que esta proteína tiene dos lóbulos, donde se une maltosa y que interactúan cada uno con los componentes de membrana malF y malG. Esta unidad funcional corresponde a una familia de sistemas de transporte compuesto por una proteína de unión periplásmica, dos sub-unidades de membrana y una sub-unidad de unión de ATP (del inglés Adenosine Triphosphate) conocidos como transportadores ABC o *ABC transporters* (del inglés ATP-Binding Cassete), se puede consultar un mayor detalle de estos sistemas en Hardin s.f.

Otros grupos de genes en el cluster de transporte de maltosa que identificamos son el grupos malPQ, correspondiente a las enzimas del sistema de maltosa compuesto por


los genes malP y malQ, además, se identifica el grupo malK-lamB que corresponde a la maltoporina encargada de la difusión de maltosa/maltodextrina por la membrana exterior.

Los grupos: malEFG, malPQ y malK-lamB que según los resultados del capítulo 4 fueron detectados en los resultados presentados anteriormente y que a luz del relacionamiento de co-expresión representan genes expresados coordinadamente y codificando proteínas que se necesitan en concentraciones similares en la célula es coherente con el concepto de operón, especialmente para los casos malEFG, malPQ y malK-lamB incluidos en el cluster en mención.

Análisis desde la perspectiva de las redes Bayesianas

En el ejemplo de red Bayesiana minimal del capítulo 5, habíamos presentado el resultado del cluster relacionado con transporte de maltosa, ahora centramos la atención hacia a los genes malE, malF y malG, como se muestra en la figura 6.2 y que como mencionamos hacen parte del sistema de transporte de lactosa, pero además, esta red nos da luces de la regulación entre el gen malT y malEFG, dada la relación de causalidad que se observa en el gráfico. En este punto es donde una red Bayesiana puede ayudarnos a entender mejor las interacciones génicas dadas las relaciones de causalidad representadas en las aristas de la red.

Figura 6.2: Resultados de la experimentación con el cluster de genes relacionado con el transporte de Maltosa. Las etiquetas en la figura corresponden al orden en que la arista fue seleccionada seguido de la frecuencia de ocurrencia en el conjunto de redes Bayesianas dentro del rango del nivel óptimo.



De los resultados presentados en la figura 6.2 y considerando las funciones génicas de los grupos involucrados, vemos que el gen regulador malT está relacionado con una función de activación y lo vemos en la estructura a un nivel superior de malEFG en la jerarquía, como lo ilustramos en la figura 6.3

Las figuras 6.4 y 6.5 muestran los grupos de genes malPQ y malK-lamB, respectivamente, dentro de la red Bayesiana minimal correspondiente al cluster de transporte de maltosa.

Los resultados que encontramos sobre el sistema de transporte de maltosa malEFG son coherentes con el concepto de transportadores ABC, como ilustra la figura 6.6, donde vemos

Figura 6.3: Causalidad encontrada en el resultado del modelo de red Bayesiana del cluster asociado con transporte de maltosa.




Figura 6.4: Identificación del operón malPQ en el cluster relacionado con transporte de maltosa.






Figura 6.5: Identificación del operón malK-lamB en el cluster relacionado con transporte de maltosa




una proteína de unión de maltosa (MBP), malE, que interactuá con dos sub-unidades de membrana, malG y malF.

Figura 6.6: Resultado sub-red del operón malEFG y malK y sus funciones génicas.



Dentro del marco Bayesiano consideramos también las redes Bayesianas reducidas. La red reducida para el cluster del transporte de la maltosa se muestra en la figura 5.5, como se observa en la red reducida desaparecen por ejemplo la relación que representa la interacción de regulación $\text{malT} \rightarrow \text{malF}$ y la interacción metabólica $\text{malE} \rightarrow \text{malF}$, relevantes para describir el comportamiento de algunos componentes biológicos. esto indica que el uso de las redes reducidas, aunque parecen ser una compactación de la información computacionalmente valida, puede resultar problemático para el análisis biológico.

Figura 6.7: Cluster de transporte de L-arabinosa en la red de co-expresión de *E.coli*.



6.2.2. Transporte de L-arabinosa

Descripción del cluster

El cluster de transporte de L-arabinosa (81-salmon2) consiste de 4 genes co-expresados (ver la tabla 4.3) y tiene una conectividad media de 1,37.

Los genes que componen este cluster son referenciados en la tabla 4.5. El cluster de co-expresión correspondiente se muestra en la figura 6.7 y podemos observar una estructura completamente conectada en el cluster co-expresado.

Análisis desde la perspectiva la co-expresión

Dentro del cluster de transporte de L-arabinosa y en concordancia con el concepto de co-expresión se identificó un grupo de genes que según la base de datos regulonDB Santos-Zavaleta y col. 2019, figuran como una unidad genética funcional (araFGH) capaz de ejercer una regulación de su propia expresión por medio de los sustratos con los que interactúan las proteínas codificadas por ellos, y que al igual que el cluster de transporte de maltosa es coherente con el concepto de *operón*.

El operón (araFGH) esta compuesto de los genes araF, araG y araH y se encuentra relacionado con el transporte de L-arabinosa.

Análisis desde la perspectiva de las redes Bayesianas

Discusión de aspectos relacionados con el transporte de sustratos dentro de grupos de genes. En cuanto al mecanismo de transporte de sustratos, el mismo resultado que vimos en el operón de transporte de maltosa se hace visible con el operón de transporte de L-arabinosa, ver la figura 6.8, ya que tenemos a la proteína de unión periplásmica, araF,

Figura 6.8: Identificación del operón araFGH en el cluster relacionado con transporte de arabinosa.





Figura 6.9: Regulación del operón araFGH por parte del gen araC.



interactuando entre la sub-unidad de membrana araH y la sub-unidad de unión de ATP araG.

Discusión de algunos aspectos relacionados con la regulación entre grupos de genes.

Con el grupo de genes de transporte de L-arabinosa (ver figura 6.9) ocurre lo mismo que con el grupo de transporte de maltosa , y en este caso el operón araFGH apareció por debajo del nivel de jerarquía del gen regulador araC, relacionado con una función de represión.


Probablemente existan otros casos similares, sin embargo, en este capítulo no ahondaremos en ellos, ya que solo el alcance aquí es validar el uso del marco de trabajo de redes Bayesianas propuesto.

6.2.3. Transporte de lactosa

Descripción del cluster

El cluster de transporte de Lactosa (0-gray) consiste de 3 genes y se encuentra dentro del grupo co-expresado sin clasificar de 69 genes (ver la tabla 4.3) dado que tiene una conectividad media de 0,836 menor que 1 y por tal motivo no se visualizará este cluster.

Figura 6.10: Identificación del operón lacZYA en el cluster relacionado con metabolismo y transporte de lactosa.



Análisis desde la perspectiva la co-expresión

El cluster de transporte de lactosa en concordancia con el concepto de co-expresión corresponde a un grupo de genes que según la base de datos regulonDB Santos-Zavaleta y col. 2019, figuran como una unidad genética funcional (lacZYA) capaz de ejercer una regulación de su propia expresión por medio de los sustratos con los que interactúan las proteínas codificadas por ellos, y que al igual que el cluster de transporte de maltosa y el cluster de transporte de L-arabinosa es coherente con el concepto de *operón*.

El operón (lacZYA) esta compuesto de los genes lacZ, lacY y lacA y se encuentra relacionado con el metabolismo y transporte de lactosa.

Análisis desde la perspectiva de las redes Bayesianas

Discusión de aspectos relacionados con el metabolismo dentro de grupos de genes

Pasando a aspectos de metabolismo hemos re-creado la experimentación con el módulo de transporte de lactosa estudiado en una estancia doctoral en el laboratorio de biología de sistemas del centro de ciencias genómicas de UNAM (Universidad Nacional Autónoma de México), a cargo del doctor Julio Augusto Freyre Gonzalez. El metabolismo de lactosa inicia con el ingreso de la misma a través de una proteína llamada galactósido permeasa, lacY, cuya función es facilitar el transporte de la lactosa al interior de la bacteria, después, por medio de la enzima β -galactosidasa, lacZ, la enzima tiogalactósido transferasa, lacA, convierten lactosa en alolactosa y esta a su vez se convierte en glucosa catalizada por la enzima β -galactosidasa, lacZ. Al revisar la jerarquía de la red Bayesiana minimal de este modulo en la figura 6.10, vemos que la dicha jerarquía guarda coherencia con esta importante vía metabólica.


6.2.4. Ensamble de hierro-azufre

Descripción del cluster

El cluster de ensamble de hierro-azufre (35-sienna3) consiste de 13 genes co-expresados (ver la tabla 4.3) y tiene una conectividad media de 18,15.

Los genes que componen este cluster son referenciados en la tabla 4.5. Al cruzar la información de los genes del cluster con la base de datos regulonDB Santos-Zavaleta y col. 2019 y el atlas bacteriano ABASY Ibarra-Arellano y col. 2016, encontramos relación con

Figura 6.11: Identificación del operón iscRSUA en el cluster relacionado con ensamble de hierro-azufre.



6 genes de interés entre los 13 del cluster, y específicamente 4 genes correspondientes al operón iscRSUA. Por esta razón, no se visualizará el cluster completo.

Análisis desde la perspectiva la co-expresión

Dentro del cluster de ensamble de hierro-azufre y en concordancia con el concepto de co-expresión se identificó un grupo de genes que según la base de datos regulonDB Santos-Zavaleta y col. 2019, figuran como una unidad genética funcional (iscRSUA) capaz de ejercer una regulación de su propia expresión por medio de los sustratos con los que interactúan las proteínas codificadas por ellos, y que al igual que el cluster de transporte de maltosa, el cluster de transporte de L-arabinosa y el cluster de transporte de lactosa es coherente con el concepto de *operón*.

El operón (iscRSUA) esta compuesto de los genes iscR, iscS, iscU e iscA y se encuentra relacionado con el ensamble de hierro-azufre.

Análisis desde la perspectiva de las redes Bayesianas

Discusión de algunos aspectos relacionados con la regulación entre grupos de genes.

En el grupo de genes de ensamble de hierro-azufre que mostramos en la figura 6.11, vemos como el gen regulador iscR con función de regulación dual, es decir, activación y/o represión, presenta una relación causal con los demás genes del operón iscRSUA, situación similar a la que ocurre en el cluster de transporte de maltosa y el cluster de transporte de L-arabinosa.

Discusión de aspectos relacionados con el metabolismo dentro de grupos de genes

Para terminar con los casos de validación, como un aspecto de metabólico hablaremos específicamente del ensamble de hierro-azufre, conocido como biogénesis del cluster hierro-azufre, que ocurre cuando una proteína de andamio (del inglés scaffold protein, recibe azufre de una enzima llamada cisteína desulfurasa y hierro de alguna fuente no identificada, y entonces, el hierro-azufre preformado se transfiere a una proteína portadora, la cual libera el hierro-azufre, para más detalle consultar Hardin s.f., y vemos en los resultados presentados

Figura 6.12: Tiempos de ejecución de las simulaciones para los clusters analizados. Se agregó el número de modelos en el rango del nivel óptimo que se encontraron en cada experimento.

Cluster	Tamaño	Iteraciones	Tiempo (Seg.)	Log(Tiempo)	Nro. Modelos
Lactosa	3	2 de 1000	314	5.23	5
Arabinosa	4	6 de 1000	742	6.02	4
Hierro-Azufre	6	9 de 1000	4752	7.71	38
Maltosa	9	11 de 1000	64367	10.08	102

en la figura 6.11, donde las interacciones entre el gen *iscS*, responsable de la enzima de cisteína desulfuraza, *iscU* responsable de la proteína de andamio (scaffold protein) e *iscA* responsable de la proteína de ensamble de hierro-azufre, igualmente guardan coherencia con esta vía metabólica, dado el orden en la jerarquía de causalidad de la red Bayesiana minimal del modulo en mención.

6.3. Resumen aspectos computacionales

Como mencionamos en el capítulo 5, la tarea de encontrar una estructura de red que optimice la función de *scoring* es un problema de optimización combinatoria, y es conocido como un problema de complejidad computacional NP-hard D. Chickering 1996 (ver sección 5.3.4) y precisamente este aspecto se torna crítico exponencialmente con el número de variables o nodos de la red (genes). Para ilustrar este tema presentamos una relación de las simulaciones iterativas de cada experimento realizado para obtener los resultados, como vemos la figura 6.12, el crecimiento del tiempo de ejecución conforme pasamos de clusters de menor a mayor tamaño, es aprox. exponencial con respecto al número de nodos, ver la columna con el logaritmo del tiempo (Log), el cual da un valor aproximado a el tamaño del cluster.

6.4. Comentarios concluyentes

Podemos notar en los resultados del caso de estudio, algunos aspectos comunes entre los grupos de genes analizados, por ejemplo: en los módulos relacionados con transporte de sustratos (maltosa, arabinosa, lactosa) en las respectivas jerarquías de la red Bayesiana se observa en común el siguiente orden: una proteína de unión periplásmica interactuando con uno o dos componentes de sub-unidad membrana, y en el último nivel de la jerarquía, una sub-unidad de unión de ATP; que como vimos anteriormente, estos módulos son coherentes con la estructura de los transportadores ABC.

Así como podemos encontrar escenarios comunes como el de los sistemas de transporte de sustratos, existen casos que se deben analizar particularmente como es el de la biogénesis de hierro-azufre o el metabolismo de maltosa, que como vimos participan enzimas catalizadoras y sustratos muy propios de cada vía metabólica, por lo tanto no se puede generalizar, ni encontrar puntos comunes en las estructuras de estos módulos. No obstante, si se observa que el orden de las jerarquías de las redes Bayesianas en estos casos dan algunas luces sobre las reacciones en cada vía metabólica particular.

De acuerdo a los puntos anteriores podemos decir que este marco de trabajo de redes Bayesianas nos permite por medio de su metodología realizar análisis de datos de expresión de micro-arreglos y analizar con ayuda de conocimiento biológico ciertas interacciones que den luces con respecto a la regulación de grupos de genes co-expresados y algunas rutas

metabólicas inherentes en las interacciones de dichos grupos y en ese sentido la construcción de dicho marco presenta un balance exitoso.

Como limitación del marco se anota que no es práctico, ni posible explicar todas las interacciones encontradas en las redes, por ejemplo: volviendo al cluster relacionado con el transporte de maltosa, en la red Bayesiana vemos al gen *malM*, el cual tiene relación con una proteína periplásmica pero su función aun no es clara en la biología o al menos en el sistema de transporte de maltosa.

Con respecto a la red Bayesiana reducida que presentamos en el capítulo 5 reportamos que para efectos de los análisis bioinformático no presentan mayor utilidad debido a que en el proceso de poda de aristas se pueden perder algunas interacciones relevantes tanto de regulación (por ejemplo, entre *malT* y algunos genes del sistema de transporte) como de metabolismo (por ejemplo, en el cluster de transporte y metabolismo de lactosa), razones por las cuales no fueron tenidas en cuenta en los análisis de este capítulo.

De acuerdo a los tiempos de ejecución que presentamos en el capítulo, confirmamos que la construcción de los modelos de redes Bayesianas son prácticos solo para análisis entre 4-16 variables o nodos, dados los tiempos de procesamiento que arroja la experimentación.

Los resultados presentados aquí fueron socializados con expertos en biología y bioquímica quienes coincidieron que el hecho de encontrar algunas interacciones que permiten concluir sobre grupos de genes asociados a proteínas que se necesitan en concentraciones similares y que trabajan coordinadamente en vías metabólicas, hace pertinente y plausible el marco de trabajo y a futuro promete aplicaciones como diseño de fármacos. No obstante, se reitera la necesidad de conocimiento biológico (como bases de datos de anotaciones GO) y acompañamiento de expertos para sacar mejor provecho de los resultados.

7 Conclusiones y trabajo futuro

7.1. Conclusiones

- Se desarrolló un **marco de trabajo de redes Bayesianas** que consta de cuatro componentes: El constructor de redes de co-expresión génica, El detector de clusters co-expresados, el constructor de redes Bayesianas minimales y el componente identificador de genes de interés biológico. Como se valida en estudio de casos, sirve para facilitar el análisis bioinformática de grupos co-expresados de genes, haciendo énfasis en la detección de causalidades entre ellos.
- Con el desarrollo del marco de trabajo Bayesiano y su respectiva validación por los casos de estudio hemos **cumplido todos los objetivos** del proyecto.
- Se revisó y adaptó computacionalmente **la construcción y visualización de redes de co-expresión de genes**. Fue posible corroborar la coherencia desde la función biológica para los cluster seleccionados con respecto a la literatura y bases de datos de anotaciones, al menos con los 8 clusters seleccionados aleatoriamente entre los 90 detectados en *E. coli*. Se validó exitosamente el concepto de co-expresión, comparándolos clusters detectados con la anotación de módulos encontrados en el atlas bacteriano ABASY. Más aun, se pudieron identificar algunos regulones y operones relacionados con el transporte y metabolismos de carbohidratos dentro de un mismo cluster alineado al concepto de co-expresión.
- Se logró **automatizar la construcción de la arquitectura de una red bayesiana óptima y sus parámetros** a partir de los datos de expresión de genes. Al remplazar la función de evaluación en la simulación MCMC por la PDF de la posterior fue posible obtener resultados de modelos Bayesianos pese al limitado número de muestras disponibles en la basa de datos de microarrays. En resumen esto es la adopción de la inferencia Bayesiana dentro del proceso de aprendizaje.
- **Algunas modificaciones introducidos al algoritmo MH y a la simulación MCMC** han permitido refinar el proceso de aprendizaje obteniendo un gran número de modelos óptimos de manera más eficiente. Sin embargo, la complejidad exponencial impide el procesamiento de grupos grandes de genes.
- El método que propusimos para obtener **la red Bayesiana minimal** se basa en la red (no Bayesiana) ponderada y entrega una red Bayesiana que consolida el conjunto de redes óptimas. Es importante resaltar que la red minimal es basada en la frecuencia de las aristas, de manera que se seleccionan las aristas más probables sobre aquellas que aparecen solo pocas veces.
- Inherente al aprendizaje de redes Bayesianas es **la tendencia a sobre-entrenar** (overfitting). El algoritmo MH busca optimizar la función score (likelihood), la cual mejora cuando se agregan nuevas aristas. Sin embargo, la simplicidad de un modelo (optimo) es deseable. Con la introducción de las **redes Bayesianas minimales reducidas** mitigamos este efecto ya que este procedimiento hace una poda sobre las

arista menos frecuentes en el conjunto de redes óptimas. Sin embargo, en los casos de estudio no encontramos mucha utilidad en estas redes reducidas debido a la pérdida de información biológicamente interesante.

- **Las redes Bayesianas y las redes de co-expresión tienen un alcance distinto**, como se mencionó en el estado del arte. Las redes Bayesianas son más descriptivas que las redes de co-expresión ya que inherentemente asumen relaciones causales entre los genes. Una red Bayesiana por ende ofrece la posibilidad de un análisis causal (por las dependencias modeladas entre sus nodos, soportadas en el concepto de probabilidad condicional) que de la red de co-expresión génica no se puede derivar. Es decir, la red Bayesiana puede indicar porque algunos genes se están co-expresando.
- **En la experimentación con E.coli**, las redes Bayesianas cuyos nodos corresponden a algún componente modular de su sistema regulatorio sus predicciones guardan coherencia, es decir, que estas redes pueden ayudarnos a entender algunos componentes del sistema regulatorio bacteriano, específicamente los componentes modulares. Sin embargo, el aprendizaje de la red Bayesiana desde datos de expresión génica de micro-arreglos no puede decirnos mucho acerca de otros componentes como los reguladores globales, reguladores intermodulares o maquinaria basal.
- **Las redes Bayesianas de interacción de genes** empleadas para modelar componentes de una red regulatoria bacteriana pueden mostrarnos en sus nodos raíz (por su carácter jerárquico) genes reguladores de interés biológico responsables de la activación o inhibición de un conjunto de genes que en una red de co-expresión génica solo se aprecian co-expresados.
- Se concluye que no es suficiente aplicar sólo el procedimiento para obtener una red Bayesiana minimal, sino que se debe **apoyar en las anotaciones GO** para obtener resultados coherentes. Además la **ayuda de biólogos** fue un factor de éxito para enfocar la interpretación de los resultados sobre los clusters de la maltosa, arabinosa, lactosa y hierro-azufre.

7.2. Trabajo futuro

- **Considerar Redes dinámicas**: Los sistemas regulatorios en general pueden incluir ciclos, dado que un producto del gen como un transcriptoma (RNA) o una proteína podrían adherirse al citoplasma y posteriormente a una región del ADN que impacte al mismo gen que generó dicho producto (dogma central de la biología). Especialmente en organismos bacterianos, este ciclo puede ser mucho más acelerado que en un eucariota. Una red bayesiana estática no puede describir este fenómeno al ser esta un grafo acíclico. Como trabajo futuro se podría incorporar al marco de trabajo el modelamiento de redes Bayesianas dinámicas para dar tratamiento en esta situación.
- **Paralelizar el procesamiento**: Por la naturaleza exploratoria de la caminata aleatoria realizada en la simulación MCMC durante el proceso de aprendizaje de una red Bayesiana, podríamos tener el caso de una red de N nodos, donde un nodo n tiene a los demás $N - 1$ como padres en la topología de esta red. Supongamos que se trata de una red con variables binarias, así que tendremos para el nodo n , 2^{N-1} entradas en la tabla de probabilidad condicional asociada; para efectos del cálculo del criterio de aceptación del algoritmo MH, deberemos evaluar 2^{N-1} funciones de distribución

de probabilidad (Dirichlet). Nos enfrentamos a una complejidad computacional exponencial, esta situación limita a que las redes Bayesianas sólo puedan ser utilizadas para analizar un conjunto de genes de un par de decenas a lo más correspondientes a algún componente modular pequeño del sistema regulatorio bacteriano (el cual puede ser del orden de varios miles de genes). Como trabajo futuro se podría implementar en el marco de trabajo técnicas computacionales como la computación paralela a través de sistemas distribuidos (MPI-Message Procesing Interface) para paralelizar la evaluación de las PDF dentro del criterio de evaluación del algoritmo MH, ya que para el caso del modelo Multinomial-Dirichlet se trata de una sumatoria apta de ser paralelizada.

- **Explorar un enfoque diferente para el aprendizaje de redes Bayesianas minimales:** Las redes minimales que se obtuvieron en el estudio de caso tenían todas la forma de red Bayesiana completa, en donde solo el orden secuencial de los nodos (del nodo con el máximo número de aristas salientes al nodo sin aristas salientes) determina la estructura de una red bayesiana completa. Como trabajo futuro podría ser interesante explorar la variación del aprendizaje de redes Bayesianas buscando redes Bayesianas completas óptimas.

Bibliografía

- Allen, Jeffrey D., Yang Xie, Min Chen, Luc Girard y Guanghua Xiao (ene. de 2012). “Comparing Statistical Methods for Constructing Large Scale Gene Networks”. En: *PLoS ONE* 7.1. Ed. por Petter Holme, e29348. DOI: 10.1371/journal.pone.0029348. URL: <http://dx.plos.org/10.1371/journal.pone.0029348> (vid. pág. 48).
- Arneson, Douglas, Anindya Bhattacharya, Le Shu, Ville-Petteri Mäkinen y Xia Yang (sep. de 2016). “Mergeomics: a web server for identifying pathological pathways, networks, and key regulators via multidimensional data integration”. En: *BMC Genomics* 17.1, pág. 722. DOI: 10.1186/s12864-016-3057-8. URL: <https://doi.org/10.1186/s12864-016-3057-8> (vid. pág. 36).
- Babu, M. (2004). “An introduction to Microarray Data Analysis”. En: *Computational Genomics: Theory and Applications*. Ed. por R. Grant. Horizont Press. Cap. 11 (vid. págs. 2, 5, 9-14).
- Babu, M. M., N. M. Luscombe, L. Aravind, M. Gerstein y S. A. Teichmann (2004). “Structure and evolution of transcriptional regulatory networks”. En: *Curr. Opin. Struct. Biol.* 14.3, págs. 283-291 (vid. pág. 35).
- Barabási, Albert László y Zoltán N. Oltvai (2004). *Network biology: Understanding the cell's functional organization*. DOI: 10.1038/nrg1272 (vid. pág. 47).
- Barrett, Tanya y col. (ene. de 2013). “NCBI GEO: archive for functional genomics data sets—update”. En: *Nucleic Acids Research* 41.Database issue, págs. D991-D995. DOI: 10.1093/nar/gks1193. URL: <http://www.ncbi.nlm.nih.gov/pmc/articles/PMC3531084/> (vid. pág. 48).
- Bernardo, J.M. y A.F.M. Smith (2006). *Bayesian Theory*. Wiley Series in Probability and Statistics. John Wiley & Sons Canada, Limited. URL: <https://books.google.com.ar/books?id=c16nAAAAAAAJ> (vid. pág. 64).
- Blair, R. H., D. J. Kliebenstein y G. A. Churchill (2012). “What can causal networks tell us about metabolic pathways?” En: *PLoS Comput. Biol.* 8.4, e1002458-e1002458 (vid. págs. 2-4).
- Boos, W y H Shuman (mar. de 1998). “Maltose/maltodextrin system of Escherichia coli: transport, metabolism, and regulation”. eng. En: *Microbiology and molecular biology reviews : MMBR* 62.1, págs. 204-229. URL: <https://www.ncbi.nlm.nih.gov/pubmed/9529892> <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC98911/> (vid. pág. 79).
- Bouckaert, Remco Ronaldus (1995). “Bayesian belief networks: from construction to inference Bayesiaanse belief netwerken: van constructie tot inferentie”. Thesis (vid. pág. 33).
- Campos, Luis M. de y Juan F. Huete (2000). “A new approach for learning belief networks using independence criteria”. En: *International Journal of Approximate Reasoning* 24.1, págs. 11-37. DOI: [http://dx.doi.org/10.1016/S0888-613X\(99\)00042-0](http://dx.doi.org/10.1016/S0888-613X(99)00042-0). URL: <http://www.sciencedirect.com/science/article/pii/S0888613X99000420> (vid. págs. 32, 33).
- Cheng, Y. y G. M. Church (2000). “Biclustering of expression data”. En: *Proc Int Conf Intell Syst Mol Biol* 8, págs. 93-103. URL: <http://www.ncbi.nlm.nih.gov/pubmed/10977070> (vid. pág. 19).
- Chickering, DavidMaxwell (1996). “Learning Bayesian Networks is NP-Complete”. En: *Learning from Data*. Ed. por Doug Fisher y Hans- J. Lenz. Vol. 112. Lecture Notes

- in Statistics. Springer New York. Cap. 12, págs. 121-130. DOI: 10.1007/978-1-4612-2404-4_12. URL: http://dx.doi.org/10.1007/978-1-4612-2404-4_12 (vid. págs. 33, 66, 87).
- Cooper, Gregory F y Edward Herskovits (1992). "A Bayesian method for the induction of probabilistic networks from data". En: *Machine Learning* 9.4, págs. 309-347. DOI: 10.1007/BF00994110. URL: <http://dx.doi.org/10.1007/BF00994110> (vid. págs. 32, 33).
- Cowell, Robert (s.f.). "Introduction to Inference for Bayesian Networks". En: Kluwer Academic Publishers, págs. 9-26. URL: <http://dl.acm.org/citation.cfm?id=299068.299070> (vid. pág. 1).
- Darwiche, Professor Adnan (2009). *Modeling and Reasoning with Bayesian Networks*. Cambridge University Press, pág. 560 (vid. pág. 32).
- Davidson, Rebecca M. y col. (2011a). "Utility of RNA Sequencing for Analysis of Maize Reproductive Transcriptomes". En: *The Plant Genome* 4.3. DOI: 10.3835/plantgenome2011.05.0015. URL: <http://dx.doi.org/10.3835/plantgenome2011.05.0015> (vid. pág. 19).
- (2011b). "Utility of RNA Sequencing for Analysis of Maize Reproductive Transcriptomes". En: *The Plant Genome* 4.3. DOI: 10.3835/plantgenome2011.05.0015. URL: <http://dx.doi.org/10.3835/plantgenome2011.05.0015> (vid. pág. 21).
- Dey, D.K. and Ghosh, S. and Mallick, B.K. (2010). *Bayesian Modeling in Bioinformatics*. Chapman & Hall/CRC Biostatistics Series. CRC Press. URL: <https://books.google.com.co/books?id=A00vLpr6mn4C%7D> (vid. págs. 1, 2, 45).
- Dong, J. y S. Horvath (2007). "Understanding network concepts in modules". En: *BMC Syst Biol* 1, pág. 24. DOI: 10.1186/1752-0509-1-24. URL: <http://www.ncbi.nlm.nih.gov/pubmed/17547772> (vid. pág. 18).
- Ellis, Byron y Wing Hung Wong (2008). "Learning Causal Bayesian Network Structures From Experimental Data". En: *Journal of the American Statistical Association* 103.482, págs. 778-789. DOI: 10.1198/016214508000000193. eprint: <http://dx.doi.org/10.1198/016214508000000193> (vid. págs. 36, 63).
- Faith, Jeremiah J, Michael E Driscoll, Vincent A Fusaro, Elissa J Cosgrove, Boris Hayete, Frank S Juhn, Stephen J Schneider y Timothy S Gardner (ene. de 2008). "Many Microbe Microarrays Database: uniformly normalized Affymetrix compendia with structured experimental metadata". En: *Nucleic Acids Research* 36.Database issue, págs. D866-D870. DOI: 10.1093/nar/gkm815. URL: <http://www.ncbi.nlm.nih.gov/pmc/articles/PMC2238822/> (vid. pág. 48).
- Faming, Liang (2010). "Learning Bayesian Networks for Gene Expression Data". En: *Bayesian Modeling in Bioinformatics*. Chapman And Hall/CRC Biostatistics Series. Chapman y Hall/CRC, págs. 271-291. DOI: doi : 10.1201/EBK1420070170-1210.1201/EBK1420070170-12. URL: <http://dx.doi.org/10.1201/EBK1420070170-12> (vid. págs. 22, 33, 34).
- Fielding, Roy T. y Richard N. Taylor (2000). "Principled Design of the Modern Web Architecture". En: *Proceedings of the 22Nd International Conference on Software Engineering*. ICSE '00. Limerick, Ireland: ACM, págs. 407-416. DOI: 10.1145/337180.337228. URL: <http://doi.acm.org/10.1145/337180.337228> (vid. pág. 40).
- Friedman, N y D Koller (2003). "Being Bayesian about network structure. A Bayesian approach to structure discovery in Bayesian networks". En: *MACHINE LEARNING* 50.1-2, págs. 95-125. DOI: 10.1023/A:1020249912095 (vid. págs. 59, 61).
- Friedman, Nir y Daphne Koller (2003a). "Being Bayesian About Network Structure. A Bayesian Approach to Structure Discovery in Bayesian Networks". En: *Machine Learning*

- 50.1-2, págs. 95-125. DOI: 10.1023/A:1020249912095. URL: <http://dx.doi.org/10.1023/A:1020249912095> (vid. págs. 33, 34).
- Friedman, Nir y Daphne Koller (2003b). “Being Bayesian About Network Structure. A Bayesian Approach to Structure Discovery in Bayesian Networks”. English. En: *Machine Learning* 50.1-2, págs. 95-125. DOI: 10.1023/A:1020249912095. URL: <http://dx.doi.org/10.1023/A:1020249912095> (vid. pág. 36).
- Gardner, T. S., D. di Bernardo, D. Lorenz y J. J. Collins (2003). “Inferring genetic networks and identifying compound mode of action via expression profiling”. En: *Science* 301.5629, págs. 102-105 (vid. pág. 35).
- Gelman, Andrew, John B. Carlin, Hal S. Stern y Donald B. Rubin (jul. de 2003). *Bayesian Data Analysis, Second Edition (Chapman & Hall/CRC Texts in Statistical Science)*. 2.^a ed. Chapman y Hall/CRC. URL: <http://www.amazon.com/exec/obidos/redirect?tag=citeulike07-20%5C&path=ASIN/158488388X> (vid. pág. 64).
- Gene Ontology, Consortium (2015a). “Gene Ontology Consortium: going forward”. En: *Nucleic acids research* 43.Database issue, págs. D1049-D1056. DOI: 10.1093/nar/gku1179. URL: <https://www.ncbi.nlm.nih.gov/pmc/PMC4383973/> (vid. pág. 7).
- (2015b). “Gene Ontology Consortium: going forward”. En: *Nucleic acids research* 43.Database issue, págs. D1049-D1056. DOI: 10.1093/nar/gku1179. URL: <https://www.ncbi.nlm.nih.gov/pmc/PMC4383973/> (vid. págs. 39, 40, 50, 52).
- Giudici, P y PJ Green (1999). “Decomposable graphical Gaussian model determination”. En: *Biometrika* 86.4, págs. 785-801. DOI: 10.1093/biomet/86.4.785. URL: <http://biomet.oxfordjournals.org/content/86/4/785.abstract> (vid. pág. 33).
- Hardin, Jeff (s.f.). *Becker’s world of the cell*. Eighth edition. Boston : Benjamin Cummings, [2012] ©2012. URL: <https://search.library.wisc.edu/catalog/9910124626502121> (vid. págs. 79, 86).
- Hastings, W. K. (abr. de 1970). “Monte Carlo sampling methods using Markov chains and their applications”. En: *Biometrika* 57.1, págs. 97-109. DOI: 10.1093/biomet/57.1.97. URL: <https://academic.oup.com/biomet/article/57/1/97/284580> (vid. págs. 33, 34, 59, 62).
- Heckerman, David, Dan Geiger y David M. Chickering (sep. de 1995). “Learning Bayesian Networks: The Combination of Knowledge and Statistical Data”. En: *Machine Learning* 20.3, págs. 197-243. DOI: 10.1023/A:1022623210503. URL: <https://doi.org/10.1023/A:1022623210503> (vid. pág. 33).
- Herskovits, Edward y Gregory F. Cooper (2013). “Kutato: An Entropy-Driven System for Construction of Probabilistic Expert Systems from Databases”. En: *CoRR* abs/1304.1088. URL: <http://arxiv.org/abs/1304.1088> (vid. pág. 33).
- Hollender, C. A., C. Kang, O. Darwish, A. Geretz, B. F. Matthews, J. Slovin, N. Alkharouf y Z. Liu (2014a). “Floral Transcriptomes in Woodland Strawberry Uncover Developing Receptacle and Anther Gene Networks”. En: *Plant Physiol* 165.3, págs. 1062-1075. DOI: 10.1104/pp.114.237529. URL: <http://www.ncbi.nlm.nih.gov/pubmed/24828307> (vid. pág. 19).
- (2014b). “Floral Transcriptomes in Woodland Strawberry Uncover Developing Receptacle and Anther Gene Networks”. En: *Plant Physiol* 165.3, págs. 1062-1075. DOI: 10.1104/pp.114.237529. URL: <http://www.ncbi.nlm.nih.gov/pubmed/24828307> (vid. pág. 21).
- Horvath, S. y J. Dong (2008). “Geometric interpretation of gene coexpression network analysis”. En: *PLoS Comput Biol* 4.8, e1000117. DOI: 10.1371/journal.pcbi.1000117. URL: <http://www.ncbi.nlm.nih.gov/pubmed/18704157> (vid. pág. 18).

- Ibarra-Arellano, Miguel A., A. I. Campos-G., Luis G. T.-Quintanilla, Andreas Tauch y Julio A. Freyre-G. (2016). "Abasy Atlas: a comprehensive inventory of systems, global network properties and systems-level elements across bacteria". En: *Database* 2016, baw089. DOI: 10.1093/database/baw089. eprint: /oup/backfile/content_public/journal/database/2016/10.1093_database_baw089/2/baw089.pdf. URL: +%20http://dx.doi.org/10.1093/database/baw089 (vid. págs. 45, 50, 52, 56, 57, 68, 79, 85).
- Jacob, François y Jacques Monod (jun. de 1961). "Genetic regulatory mechanisms in the synthesis of proteins". En: *Journal of Molecular Biology* 3.3, págs. 318-356. DOI: 10.1016/S0022-2836(61)80072-7. URL: <https://linkinghub.elsevier.com/retrieve/pii/S0022283661800727> (vid. pág. 79).
- Jang, Yeongjun, Namhee Yu, Jihae Seo, Sun Kim y Sanghyuk Lee (2016). "MONGKIE: An integrated tool for network analysis and visualization for multi-omics data". En: *Biology Direct*. DOI: 10.1186/s13062-016-0112-y (vid. pág. 21).
- Kim, Hanhae, Jung Eun Shim, Junha Shin e Insuk Lee (ene. de 2015). "EcoliNet: a database of cofunctional gene network for Escherichia coli". En: *Database* 2015. DOI: 10.1093/database/bav001. URL: <https://academic.oup.com/database/article/doi/10.1093/database/bav001/2433133> (vid. pág. 21).
- Kolesnikov, Nikolay y col. (ene. de 2015). "ArrayExpress update—simplifying data submissions". En: *Nucleic Acids Research* 43.Database issue, págs. D1113-D1116. DOI: 10.1093/nar/gku1057. URL: <http://www.ncbi.nlm.nih.gov/pmc/articles/PMC4383899/> (vid. pág. 48).
- Koller, Daphne y Nir Friedman (2009). *Probabilistic graphical models : principles and techniques*. Adaptive computation and machine learning. Cambridge, MA: MIT Press, xxi, 1231 p. (Vid. págs. 2, 28, 30, 31, 33).
- Korb, Kevin B. y Ann E. Nicholson (2010). *Bayesian Artificial Intelligence, Second Edition*. 2nd. Boca Raton, FL, USA: CRC Press, Inc. (vid. págs. 22-24).
- Lam, Wai y Fahiem Bacchus (1994). "LEARNING BAYESIAN BELIEF NETWORKS: AN APPROACH BASED ON THE MDL PRINCIPLE". En: *Computational Intelligence* 10.3, págs. 269-293. DOI: 10.1111/j.1467-8640.1994.tb00166.x. URL: <http://dx.doi.org/10.1111/j.1467-8640.1994.tb00166.x> (vid. pág. 33).
- Langfelder, Peter y Steve Horvath (dic. de 2008). "WGCNA: an R package for weighted correlation network analysis". En: *BMC Bioinformatics* 9.1, pág. 559. DOI: 10.1186/1471-2105-9-559. URL: <https://doi.org/10.1186/1471-2105-9-559> (vid. págs. 3, 40, 48-51).
- Langfelder, Peter, Bin Zhang y Steve Horvath (nov. de 2007). "Defining clusters from a hierarchical cluster tree: the Dynamic Tree Cut package for R". En: *Bioinformatics* 24.5, págs. 719-720. DOI: 10.1093/bioinformatics/btm563. eprint: <http://oup.prod.sis.lan/bioinformatics/article-pdf/24/5/719/16885227/btm563.pdf>. URL: <https://doi.org/10.1093/bioinformatics/btm563> (vid. pág. 48).
- Liang, Faming, Chuanhai Liu y Raymond J. Carroll (2007). "Stochastic Approximation in Monte Carlo Computation". En: *Journal of the American Statistical Association* 102.477, págs. 305-320. DOI: 10.1198/016214506000001202. URL: <http://dx.doi.org/10.1198/016214506000001202> (vid. pág. 33).
- Liang, Faming y Jian Zhang (2009a). "Learning Bayesian networks for discrete data". En: *Computational Statistics And Data Analysis* 53.4, págs. 865-876. DOI: <http://dx.doi.org/10.1016/j.csda.2008.10.007>. URL: <http://www.sciencedirect.com/science/article/pii/S0167947308004805> (vid. pág. 33).
- (2009b). "Learning Bayesian networks for discrete data". En: *Computational Statistics and Data Analysis* 53.4, págs. 865-876. DOI: <http://dx.doi.org/10.1016/j.csda.2008.10.007>.

- csda.2008.10.007. URL: <http://www.sciencedirect.com/science/article/pii/S0167947308004805> (vid. pág. 36).
- Liu, Jun S., Faming Liang y Wing Hung Wong (2001). “A Theory for Dynamic Weighting in Monte Carlo Computation”. En: *Journal of the American Statistical Association* 96.454, págs. 561-573. DOI: 10.1198/016214501753168253. URL: <http://dx.doi.org/10.1198/016214501753168253> (vid. pág. 34).
- Liu, Wei, Li Li, Xuhe Long, Weixin You, Yuexian Zhong, Menglin Wang, Huan Tao, Shoukai Lin y Huaqin He (mar. de 2018). “Construction and Analysis of Gene Co-Expression Networks in Escherichia coli”. En: *Cells* 7.3, pág. 19. DOI: 10.3390/cells7030019. URL: <http://www.mdpi.com/2073-4409/7/3/19> (vid. págs. 21, 56).
- Madigan, David y Adrian E Raftery (1994). “Model selection and accounting for model uncertainty in graphical models using Occam’s window”. En: *Journal of the American Statistical Association* 89.428, págs. 1535-1546 (vid. pág. 33).
- Madigan, David, Jeremy York y Denis Allard (1995). “Bayesian graphical models for discrete data”. En: *International Statistical Review/Revue Internationale de Statistique*, págs. 215-232 (vid. pág. 33).
- Mardis, E. R. (2013). “Next-generation sequencing platforms”. En: *Annu Rev Anal Chem (Palo Alto Calif)* 6, págs. 287-303 (vid. pág. 14).
- Metzker, M. L. (2010). “Sequencing technologies - the next generation”. En: *Nat. Rev. Genet.* 11.1, págs. 31-46 (vid. pág. 14).
- Moretto, Marco y col. (ene. de 2016). “COLOMBOS v3.0: leveraging gene expression compendia for cross-species analyses”. En: *Nucleic Acids Research* 44.Database issue, págs. D620-D623. DOI: 10.1093/nar/gkv1251. URL: <http://www.ncbi.nlm.nih.gov/pmc/articles/PMC4702885/> (vid. pág. 48).
- Murphy, Kevin P. (2012). *Machine Learning: A Probabilistic Perspective*. The MIT Press, pág. 1096 (vid. págs. 22, 34).
- Neapolitan, Richard E. (2009a). *Probabilistic Methods for Bioinformatics: With an Introduction to Bayesian Networks*. San Francisco, CA, USA: Morgan Kaufmann Publishers Inc. (vid. págs. 32, 35).
- (2009b). *Probabilistic Methods for Bioinformatics: With an Introduction to Bayesian Networks*. San Francisco, CA, USA: Morgan Kaufmann Publishers Inc. (vid. pág. 36).
- Neiland, JulianR y KeinB Korb (1999). “The Evolution of Causal Models: A Comparison of Bayesian Metrics and Structure Priors”. En: *Methodologies for Knowledge Discovery and Data Mining*. Ed. por Ning Zhong y Lizhu Zhou. Vol. 1574. Lecture Notes in Computer Science. Springer Berlin Heidelberg. Cap. 57, págs. 433-438. DOI: 10.1007/3-540-48912-6_57. URL: http://dx.doi.org/10.1007/3-540-48912-6_57 (vid. pág. 33).
- Nguyen, Danh V., A. Bulak Arpat, Naisyin Wang y Raymond J. Carroll (2002). “DNA Microarray Experiments: Biological and Technological Aspects”. En: *Biometrics* 58.4, págs. 701-717. DOI: 10.1111/j.0006-341X.2002.00701.x. URL: <http://dx.doi.org/10.1111/j.0006-341X.2002.00701.x> (vid. pág. 5).
- Pearl, Judea (1988). *Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference*. San Francisco, CA, USA: Morgan Kaufmann Publishers Inc. (vid. págs. 1, 36).
- Prestat, E., S. R. de Morais, J. A. Vendrell, A. Thollet, C. Gautier, P. A. Cohen y A. Aussem (mayo de 2013). “Learning the local Bayesian network structure around the ZNF217 oncogene in breast tumours”. En: *Comput. Biol. Med.* 43.4, págs. 334-341 (vid. pág. 35).
- Prestat, Emmanuel, Sérgio Rodrigues de Morais, Julie A. Vendrell, Aurélie Thollet, Christian Gautier, Pascale A. Cohen y Alex Aussem (2013). “Learning the local Bayesian net-

- work structure around the ZNF217 oncogene in breast tumours”. En: *Computers in Biology And Medicine* 43.7, págs. 334-341. DOI: 10.1016/j.compbiomed.2012.12.002. URL: <http://search.ebscohost.com/login.aspx?direct=true&db=a9h&AN=88239087%E3%80%88=es&site=ehost-live> (vid. págs. 1, 28).
- Prifti, E., J. D. Zucker, K. Clément y C. Henegar (2010). “Interactional and functional centrality in transcriptional co-expression networks”. En: *Bioinformatics* 26.24, págs. 3083-9. DOI: 10.1093/bioinformatics/btq591. URL: <http://www.ncbi.nlm.nih.gov/pubmed/20959383> (vid. pág. 18).
- Raiffa, H. y R. Schlaifer (1961). *Applied statistical decision theory*. Studies in managerial economics. Division of Research, Graduate School of Business Administration, Harvard University. URL: <https://books.google.com.ar/books?id=wPBLAAAAAAAJ> (vid. pág. 64).
- Roy, S., D. K. Bhattacharyya y J. K. Kalita (2014). “Reconstruction of gene co-expression network from microarray data using local expression patterns”. En: *BMC Bioinformatics* 15 Suppl 7, S10. DOI: 10.1186/1471-2105-15-S7-S10. URL: <http://www.ncbi.nlm.nih.gov/pubmed/25079873> (vid. págs. 21, 35).
- Rozanski, Nick y Eóin Woods (2005). *Software Systems Architecture: Working With Stakeholders Using Viewpoints and Perspectives*. Addison-Wesley Professional (vid. pág. 42).
- Santos-Zavaleta, Alberto y col. (ene. de 2019). “RegulonDB v 10.5: tackling challenges to unify classic and high throughput knowledge of gene regulation in E. coli K-12”. En: *Nucleic Acids Research* 47.D1, págs. D212-D220. DOI: 10.1093/nar/gky1077. URL: <https://academic.oup.com/nar/article/47/D1/D212/5160972> (vid. págs. 57, 79, 83, 85, 86).
- Segal, E., M. Shapira, A. Regev, D. Pe’er, D. Botstein, D. Koller y N. Friedman (2003). “Module networks: identifying regulatory modules and their condition-specific regulators from gene expression data”. En: *Nat. Genet.* 34.2, págs. 166-176 (vid. pág. 35).
- Shannon, Paul (nov. de 2003). “Cytoscape: A Software Environment for Integrated Models of Biomolecular Interaction Networks”. En: *Genome Research* 13.11, págs. 2498-2504. DOI: 10.1101/gr.1239303. URL: <http://www.genome.org/cgi/doi/10.1101/gr.1239303> (vid. pág. 48).
- Spirtes, P., C. Glymour y R. Scheines (2012). *Causation, Prediction, and Search*. Springer New York. URL: <https://books.google.com.co/books?id=oUjxBwAAQBAJ> (vid. pág. 32).
- The Gene Ontology, Consortium (2008). “The Gene Ontology project in 2008”. En: *Nucleic Acids Research* 36.Database issue, págs. D440-D444. DOI: 10.1093/nar/gkm883. URL: <http://www.ncbi.nlm.nih.gov/pmc/articles/PMC2238979/> (vid. págs. 2, 5, 67).
- (2014). *Gene Ontology - Browse Files at SourceForge.net*. URL: <https://sourceforge.net/projects/geneontology/files/> (visitado 07-04-2019) (vid. pág. 7).
 - (2018). *AmiGO 2: Term Details for 'lactase activity' (GO:0000016)*. URL: <http://amigo.geneontology.org/amigo/term/GO:0000016> (visitado 07-04-2019) (vid. pág. 6).
- Tözeren, A. y S. W. Byers (2004). *New Biology for Engineers and Computer Scientists*. Pearson Prentice Hall bioengineering. Pearson/Prentice Hall. URL: <https://books.google.com.co/books?id=gqVpQgAACAAJ> (vid. pág. 5).
- Treviño, Santiago, Yudong Sun, Tim F. Cooper y Kevin E. Bassler (feb. de 2012). “Robust Detection of Hierarchical Communities from Escherichia coli Gene Expression Data”. En: *PLoS Computational Biology* 8.2. Ed. por Satoru Miyano, e1002391. DOI: 10.1371/journal.pcbi.1002391. URL: <http://dx.plos.org/10.1371/journal.pcbi.1002391> (vid. págs. 21, 48).

- Vinh, Nguyen Xuan, Madhu Chetty, Ross Coppel y Pramod P. Wangikar (2011). "Global-MIT: learning globally optimal dynamic bayesian network with the mutual information test criterion". En: *Bioinformatics* 27.19, págs. 2765-2766. DOI: 10.1093/bioinformatics/btr457. eprint: /oup/backfile/content_public/journal/bioinformatics/27/19/10.1093/bioinformatics/btr457/2/btr457.pdf. URL: <http://dx.doi.org/10.1093/bioinformatics/btr457> (vid. pág. 36).
- Vital-Lopez, Francisco G., Vesna M. y Bhaskar Dutta (2012). "Tutorial on biological networks". En: *Wiley Interdisciplinary Reviews: Data Mining and Knowledge Discovery* 2.4, págs. 298-325. DOI: 10.1002/widm.1061. URL: <http://dx.doi.org/10.1002/widm.1061> (vid. pág. 47).
- Wang, Juexin, Trupti Joshi, Babu Valliyodan, Haiying Shi, Yanchun Liang, Henry T. Nguyen, Jing Zhang y Dong Xu (nov. de 2015). "A Bayesian model for detection of high-order interactions among genetic variants in genome-wide association studies". En: *BMC Genomics* 16.1, pág. 1011. DOI: 10.1186/s12864-015-2217-6. URL: <https://doi.org/10.1186/s12864-015-2217-6> (vid. pág. 36).
- Warde-Farley, D. y col. (2010). "The GeneMANIA prediction server: biological network integration for gene prioritization and predicting gene function". En: *Nucleic Acids Res.* 38.Web Server issue, W214-220 (vid. pág. 2).
- Watson, J. D., T. A. Baker, S. P. Bell, A. Gann, M. Levine y R. Losick (2013). *Molecular Biology of the Gene*. Pearson Education. URL: <https://books.google.com.co/books?id=aRUtAAAAQBAJ> (vid. pág. 5).
- Watts, Duncan J y Steven H Strogatz (jun. de 1998). "Collective dynamics of 'small-world' networks". En: *Nature* 393.6684, págs. 440-442. DOI: 10.1038/30918. arXiv: 0803.0939v1. URL: <http://www.nature.com/articles/30918> (vid. pág. 49).
- Weirauch, Matthew T. (abr. de 2011). "Gene Coexpression Networks for the Analysis of DNA Microarray Data". En: *Applied Statistics for Network Biology*. Weinheim, Germany: Wiley-VCH Verlag GmbH & Co. KGaA, págs. 215-250. DOI: 10.1002/9783527638079.ch11. URL: <http://doi.wiley.com/10.1002/9783527638079.ch11> (vid. pág. 49).
- Wermuth, N. y S Lauritzen (1983). "Graphical and recursive models for contingency tables". En: *Biometrika* 70.3, págs. 537-552. DOI: 10.1093/biomet/70.3.537. URL: <http://biomet.oxfordjournals.org/content/70/3/537.abstractN2> (vid. pág. 32).
- Wong, Wing Hung y Faming Liang (1997). "Dynamic weighting in Monte Carlo and Optimization". En: *Proceedings of the National Academy of Sciences of the United States of America* 94.26, págs. 14220-14224. URL: <http://www.ncbi.nlm.nih.gov/pmc/articles/PMC24914/> (vid. pág. 34).
- Xue, Z. y col. (2013a). "Genetic programs in human and mouse early embryos revealed by single-cell RNA sequencing". En: *Nature* 500.7464, págs. 593-7. DOI: 10.1038/nature12364. URL: <http://www.ncbi.nlm.nih.gov/pubmed/23892778> (vid. pág. 19).
- (2013b). "Genetic programs in human and mouse early embryos revealed by single-cell RNA sequencing". En: *Nature* 500.7464, págs. 593-7. DOI: 10.1038/nature12364. URL: <http://www.ncbi.nlm.nih.gov/pubmed/23892778> (vid. pág. 21).
- Young, MatthewD, DavisJ McCarthy, MatthewJ Wakefield, GordonK Smyth, Alicia Oshlack y MarkD Robinson (2012). "Differential Expression for RNA Sequencing (RNA-Seq) Data: Mapping, Summarization, Statistical Analysis, and Experimental Design". En: *Bioinformatics for High Throughput Sequencing*. Ed. por Naiara Rodríguez-Ezpeleta, Michael Hackenberg y Ana M. Aransay. Springer New York. Cap. 10, págs. 169-190. DOI: 10.1007/978-1-4614-0782-9_10. URL: http://dx.doi.org/10.1007/978-1-4614-0782-9_10 (vid. pág. 14).

Bibliografía

- Yu, H., N. M. Luscombe, J. Qian y M. Gerstein (2003). “Genomic analysis of gene expression relationships in transcriptional regulatory networks”. En: *Trends Genet* 19.8, págs. 422-7. DOI: 10.1016/S0168-9525(03)00175-6. URL: <http://www.ncbi.nlm.nih.gov/pubmed/12902159> (vid. pág. 19).
- Zhang, B. y S. Horvath (2005a). “A general framework for weighted gene co-expression network analysis”. En: *Stat Appl Genet Mol Biol* 4, Article17. DOI: 10.2202/1544-6115.1128. URL: <http://www.ncbi.nlm.nih.gov/pubmed/16646834> (vid. pág. 19).
- (2005b). “A general framework for weighted gene co-expression network analysis”. En: *Stat Appl Genet Mol Biol* 4, Article17. DOI: 10.2202/1544-6115.1128. URL: <http://www.ncbi.nlm.nih.gov/pubmed/16646834> (vid. págs. 40, 47, 49).

Declaración

Esta tesis es enviada para optar al título de Doctor en ingeniería, énfasis énfasis en ciencias de la computación de la Escuela de Ingeniería de Sistemas y Computación in the Facultad de Ingeniería de la Universidad del Valle.

Santiago de Cali, Noviembre - 2019

Diego M. Garcia J.